



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ

ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ

ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ
ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Για την απόκτηση του Διπλώματος Μηχανικού
Ηλεκτρονικών Υπολογιστών και Πληροφορικής

Secure Decentralized Federated Learning

Πειραματική αξιολόγηση μηχανισμών προστασίας και επαλήθευσης
σε αποκεντρωμένη ομοσπονδιακή μάθηση

Μυλωνάς Διονύσιος

Αριθμός Μητρώου 1093449

Επιβλέπων
Κωνσταντίνος Μπερμπερίδης

Πάτρα, Νοέμβριος 2026

Περίληψη

Αντικείμενο και ερευνητικός στόχος

Η εκπαίδευση σύγχρονων μοντέλων Μηχανικής Μάθησης προϋποθέτει πρόσβαση σε επαρκή και αντιπροσωπευτικά δεδομένα. Στην πράξη, όμως, τα δεδομένα συχνά βρίσκονται κατανεμημένα σε διαφορετικούς οργανισμούς, συσκευές ή διοικητικά domains. Νοσοκομεία διατηρούν ανεξάρτητους φακέλους ασθενών, τηλεπικοινωνιακοί κόμβοι παρατηρούν διαφορετικά τμήματα του δικτύου, βιομηχανικές εγκαταστάσεις συλλέγουν ιδιόκτητη τηλεμετρία και προσωπικές συσκευές παράγουν δεδομένα που δεν είναι επιθυμητό να συγκεντρώνονται σε έναν εξωτερικό server. Η παραδοσιακή προσέγγιση της κεντρικής συλλογής δημιουργεί επομένως τεχνικές, νομικές και οργανωτικές δυσκολίες.

Το Federated Learning προσεγγίζει το πρόβλημα από διαφορετική κατεύθυνση: αντί να μεταφέρονται τα δεδομένα προς το μοντέλο, μεταφέρεται η γνώση που αποκτάται από το μοντέλο κοντά στα δεδομένα. Κάθε client εκπαιδεύει τοπικά ένα αντίγραφο κοινής αρχιτεκτονικής και αποστέλλει model parameters ή model updates για συνάθροιση. Η αρχική διατύπωση του Federated Averaging έδειξε ότι αυτή η συνεργασία μπορεί να επιτευχθεί με επαναλαμβανόμενα local optimization steps και περιοδική σύνθεση των μοντέλων [9]. Η ιδέα εξελίχθηκε σε ευρύτερο ερευνητικό πεδίο με εφαρμογές σε cross-device και cross-silo περιβάλλοντα [10].

Η αποκεντρωμένη εκδοχή του FL αφαιρεί και τον κεντρικό aggregation server. Η επικοινωνία πραγματοποιείται peer-to-peer σύμφωνα με μία τοπολογία δικτύου και η κοινή γνώση διαδίδεται σταδιακά μέσω τοπικών aggregations [1]. Η επιλογή αυτή είναι ελκυστική σε σενάρια όπου δεν υπάρχει καθολικά έμπιστος συντονιστής ή όπου το single point of failure ενός κεντρικού server θεωρείται ανεπιθύμητο. Παράλληλα, η αποκέντρωση μεταφέρει μέρος της πολυπλοκότητας στους ίδιους τους clients: η σύγκλιση, η ασφάλεια της ανταλλαγής και η επαληθευσιμότητα του ιστορικού πρέπει να επιτευχθούν χωρίς έναν μοναδικό trusted authority.

Στόχος είναι ο σχεδιασμός, η υλοποίηση και η πειραματική αποτίμηση ενός Secure Decentralized Federated Learning prototype με ελεγχόμενη κλιμάκωση των μηχανισμών προστασίας. Το έργο ξεκινά από baseline DFL ώστε να υπάρχει καθαρό σημείο αναφοράς και προσθέτει διαδοχικά simple masking, pairwise-canceling masking, Selective CKKS HE, Adaptive Hybrid security και δύο επίπεδα audit. Η σειρά αυτή επιτρέπει να παρατηρείται χωριστά το κόστος και η αριθμητική συμπεριφορά κάθε μηχανισμού.

Η αξιολόγηση εξετάζει μαθησιακή συμπεριφορά, κόστος και αριθμητική ορθότητα σε ελεγχόμενες διαμορφώσεις. Κάθε αντιστοιχισμένη σύγκριση κρατά ίδιο dataset, seed, πλήθος clients, τοπολογία, split και υπερπαραμέτρους. Η αρχική σειρά καλύπτει τρία datasets, δύο μεγέθη δικτύου και δύο τοπολογίες. Το heuristic risk score οργανώνει το κρυπτογραφικό budget, χωρίς να αποτελεί ανιχνευτή επιθέσεων ή απόδειξη ιδιωτικότητας.

Παράλληλα, η εργασία εξετάζει την ακεραιότητα και την ιχνηλασιμότητα ως διαφορετική διάσταση από το confidentiality. Το audit layer δεν αντικαθιστά το masking ή το HE. Αντίθετα, καταγράφει hashes, metadata, υπογραφές και Merkle proofs ώστε να μπορεί να ελεγχθεί εκ των υστέρων εάν τα αποθηκευμένα artifacts αλλοιώθηκαν. Με αυτό τον διαχωρισμό, η αρχιτεκτονική αντιμετωπίζει δύο διαφορετικά ερωτήματα: «ποιος μπορεί να δει το update κατά την ανταλλαγή;» και «μπορώ να ελέγξω αν το ιστορικό που αποθηκεύτηκε παραμένει αυθεντικό;».

Σχεδιασμός του πρωτοτύπου και μηχανισμοί προστασίας

Για MNIST και Fashion-MNIST χρησιμοποιείται MLP 784 → 128 → 10, με ReLU μεταξύ των γραμμικών επιπέδων. Το πρώτο επίπεδο έχει 784×128 βάρη και 128 biases. Για CIFAR-10 χρησιμοποιείται MLP 3072 → 128 → 10, καθώς 32×32×3 = 3072 τιμές εισόδου. Και στις δύο περιπτώσεις το τελικό επίπεδο έχει 128×10 + 10 = 1.290 παραμέτρους.

Στο DFL, το μοντέλο κάθε client ενημερώνεται από local contributors που ορίζονται από την τοπολογία. Εάν αυτή η διαδικασία επαναλαμβάνεται και το communication graph παραμένει συνδεδεμένο, η πληροφορία μπορεί να διαχυθεί σε ολόκληρο το δίκτυο. Η έννοια consensus περιγράφει την τάση των local models να γίνονται περισσότερο παρόμοια, όχι απαραίτητα απόλυτα ταυτόσημα σε κάθε χρονική στιγμή [1].

Στο pairwise masking, κάθε ζεύγος contributors παράγει deterministic mask από κοινό seed. Με σταθερό convention, ο client με μικρότερο ID προσθέτει το mask και ο client με μεγαλύτερο ID το αφαιρεί. Όταν η πλήρης contributor set αθροιστεί, κάθε pairwise term εμφανίζεται μία φορά με + και μία με − και επομένως ακυρώνεται [3].

Η Homomorphic Encryption επιτρέπει υπολογισμούς σε ciphertexts. Το CKKS σχεδιάστηκε για approximate arithmetic πραγματικών και μιγαδικών αριθμών [4]. Η approximate φύση είναι κατάλληλη για machine-learning parameters, όπου μικρά floating-point errors είναι συνήθως αποδεκτά. Στην υλοποίηση χρησιμοποιείται TenSEAL [6], poly_modulus_degree 8192, global scale 2^40 και coefficient modulus bits 60,40,40,60.

Η πλήρης κρυπτογράφηση όλων των parameters θα αύξανε δραστικά το κόστος. Για αυτό η υλοποίηση εντοπίζει το final floating-point weight και matching bias και εφαρμόζει CKKS μόνο σε αυτά. Στο MLP πρόκειται για output.weight και output.bias, δηλαδή 1.280 + 10 = 1.290 values ανά model. Τα μη επιλεγμένα tensors αθροίζονται σε plaintext.

Η Adaptive Hybrid λογική επεκτείνει το Selective HE σε δεύτερη διάσταση επιλογής. Δεν αποφασίζει μόνο ποια tensors κρυπτογραφούνται, αλλά και ποια target neighborhoods θα εκτελέσουν HE σε έναν round. Για κάθε client υπολογίζεται L2 norm της μεταβολής στα selected parameters. Για κάθε target neighborhood συνδυάζεται το maximum και το mean των contributor norms.

Η default topk_risk policy ταξινομεί τα target risk scores. Με ratio 0.4 και πέντε targets επιλέγονται ceil(5×0.4)=2 neighborhoods για HE. Τα υπόλοιπα τρία χρησιμοποιούν pairwise masking. Με αυτό τον τρόπο το encrypted traffic και ο HE processing time κλιμακώνονται με το target ratio.

Οι hash functions χρησιμοποιούνται για integrity, όχι confidentiality. Ένα hash λειτουργεί ως fixed-size fingerprint των input bytes. Εάν αλλάξει ακόμη και μικρό τμήμα ενός record, το νέο hash αναμένεται να διαφέρει. Η μονόδρομη ιδιότητα σημαίνει ότι δεν είναι πρακτικό να ανακτηθεί το αρχικό μήνυμα από το digest, αλλά είναι εύκολο να υπολογιστεί νέο digest για νέα δεδομένα.

Πειραματική μεθοδολογία και αναπαραγωγιμότητα

Η καμπάνια της 14ης Οκτωβρίου 2026 ολοκλήρωσε όλα τα προγραμματισμένα runs χωρίς αποτυχία. Οι 360 validation εκτελέσεις προκύπτουν από 3 datasets επί 3 seeds επί 2 πλήθη clients επί 2 τοπολογίες επί 2 splits επί 5 security modes. Τα 30 sensitivity runs προκύπτουν από 3 datasets επί 2 splits επί 5 HE ratios. Τα 12 network demos καλύπτουν 3 datasets, 2 splits και baseline ή masking.

Τα MNIST και Fashion-MNIST χρησιμοποιούν 60.000 training και 10.000 test εικόνες, ενώ το CIFAR-10 50.000 training και 10.000 test εικόνες. Διατηρήθηκαν MLP 128 με ReLU, 20 communication rounds, ένα local epoch, batch size 32 και SGD learning rate 0,01. Η επιλογή περιορίζει τους συνδυασμούς ρυθμίσεων και διατηρεί ολόκληρα τα datasets. Η accuracy είναι ο μέσος όρος των client accuracies στο κοινό πλήρες test set, μετά τον 20ό γύρο.

Οι εκτελέσεις έγιναν σε Windows με NVIDIA GeForce RTX 5070 Laptop GPU, PyTorch 2.11.0 με CUDA 12.8 και TenSEAL 0.3.16. Το environment.txt καταγράφει τις εκδόσεις εξαρτήσεων. Στα validation και sensitivity η εκπαίδευση και η αξιολόγηση χρησιμοποιούν CUDA, ενώ η CKKS και μέρος του orchestration εκτελούνται στην CPU. Οι clients εκτελούνται σειριακά στην ίδια διεργασία. Στη συμπληρωματική σειρά δύο workers εκτελούν ανεξάρτητα runs ταυτόχρονα, διατηρώντας σειριακούς clients μέσα σε κάθε run.

Η τελική accuracy είναι ο μέσος όρος των client accuracies στο κοινό test split, στον τελευταίο γύρο. Κάθε γραμμή αναφοράς με mean και sample standard deviation συγκεντρώνει μόνο ίδιες διαμορφώσεις και ανεξάρτητα seeds. Η επικοινωνία των validation είναι υπολογισμένος όγκος model states, masks, seed material και ciphertexts. Στα network είναι το άθροισμα πραγματικών σταλμένων και ληφθέντων bytes. Ο χρόνος γύρου περιλαμβάνει training, aggregation και global evaluation, καθώς και HTTP στα network demos.

Η αναφορά συνδυάζει τα προφίλ μόνο για τις ελεγμένες μη χρονικές μετρικές. Οι χρόνοι legacy και cached_gpu παραμένουν χωριστοί. Η καταγραφή execution_profile σε CSV και manifest επιτρέπει έλεγχο της σύγκρισης. Οι μετρήσεις περιγράφουν το συγκεκριμένο laptop και δεν αποτελούν απομονωμένο CPU έναντι GPU benchmark. Για τη νέα σειρά διαχωρίζονται επιπλέον τα sessions και το περιβάλλον parallel_2_workers. Δεν συγχωνεύονται οι αρχικοί serial χρόνοι με τους χρόνους των δύο workers.

Κάθε validation διαμόρφωση επαναλαμβάνεται με τρία seeds. Η sample SD αποτυπώνει τη διασπορά μεταξύ αυτών των επαναλήψεων. Το μικρό πλήθος seeds περιορίζει τους ισχυρισμούς στατιστικής σημαντικότητας. Οι χρόνοι παρουσιάζονται χωριστά ανά execution profile και αναφέρουν το n κάθε κελιού.

Οι 12 network εκτελέσεις χρησιμοποίησαν 3 τοπικές διεργασίες με HTTP, 2 γύρους, 1.500 training και 500 test εικόνες, batch size 64 και learning rate 0,05. Κάθε εκτέλεση ολοκλήρωσε 6 node-round finalizations και κατέγραψε μηδενικές αποτυχημένες αποστολές. Τα σύνολα train και test και οι υπερπαράμετροι διαφέρουν από τα πλήρη validation runs.

Ευρήματα της αρχικής αξιολόγησης

Η non-IID κατανομή μειώνει την accuracy σε όλες τις δοκιμασμένες διαμορφώσεις. Με 5 clients και ring, το baseline πέφτει από 92,51% σε 65,62% στο MNIST, από 83,17% σε 48,37% στο Fashion-MNIST και από 43,93% σε 23,30% στο CIFAR-10. Η διαφορά αφορά το συγκεκριμένο label-skew partition με δύο shards ανά client.

Στις 288 αντιστοιχισμένες συγκρίσεις των τεσσάρων protected modes με baseline, η μεγαλύτερη απόλυτη διαφορά τελικής accuracy είναι 0,23 ποσοστιαίες μονάδες. Το εύρημα υποστηρίζει μικρή μαθησιακή επίδραση των μηχανισμών στις δοκιμασμένες συνθήκες. Δεν συνιστά έλεγχο στατιστικής ισοδυναμίας ή τυπική απόδειξη ασφάλειας.

Στο παραπάνω MNIST reference, οι μέσες τιμές είναι 3,882 MiB ανά γύρο για baseline, 7,764 για simple masking, 3,883 για pairwise masking, 7,021 για selective HE και 5,138 για adaptive hybrid. Η διπλάσια επικοινωνία του simple masking αφορά τη συγκεκριμένη λογιστική μεταφοράς πλήρους mask στη simulation. Το HTTP masking του network demo χρησιμοποιεί διαφορετικό μηχανισμό διανομής και καταγραφής, επομένως οι όγκοι των δύο workflows ερμηνεύονται ξεχωριστά.

Τα 30 sensitivity runs χρησιμοποιούν seed 42, 5 clients, ring, πλήρη datasets, 20 γύρους και HE target ratios 0,2 έως 1,0 με βήμα 0,2. Για κάθε dataset και split μεταβάλλεται μόνο το ratio. Τα δεδομένα περιγράφουν ένα διερευνητικό cost trade-off και δεν τεκμηριώνουν βέλτιστη επιλογή ratio για όλες τις συνθήκες.

Ο ειδικός χρόνος HE μεταβάλλεται με το target ratio. Κάθε καμπύλη αντιστοιχεί σε ένα dataset και split με seed 42. Η αύξηση του χρόνου είναι συμβατή με περισσότερα HE targets, χωρίς να τεκμηριώνει αντίστοιχο μαθησιακό ή security κέρδος.

Τα τρία benchmarks συμφώνησαν ακριβώς στα μη χρονικά πεδία όλων των γύρων. Οι υπολογισμοί training διατήρησαν ίδιο model, batches, seeds, precision και optimizer. Οι μετρημένοι λόγοι χρόνων είναι περίπου 2,95 έως 3,22. Οι τιμές αφορούν τα συγκεκριμένα baseline runs και δεν εγγυώνται ίδια επιτάχυνση για όλα τα security modes ή άλλο hardware.

Baseline και masking δίνουν ίδια τελική accuracy σε κάθε αντιστοιχισμένο dataset και split. Ο μέσος χρόνος γύρου του masking είναι 1,4 έως 2,6 φορές ο αντίστοιχος baseline χρόνος. Το CIFAR-10 καταλήγει κοντά στο 10% σε αυτό το μικρό demo. Τα αποτελέσματα τεκμηριώνουν λειτουργική ανταλλαγή και aggregation στο localhost, με περιορισμένη αξιολόγηση μάθησης και χωρίς πραγματικό WAN ή διαφορετικές φυσικές συσκευές.

Η αρχική σειρά εξετάζει τρία datasets, ring και fully connected και δύο μεγέθη δικτύου. Η συμπληρωματική σειρά προσθέτει Caveman, Barabási–Albert και κατανομές Dirichlet στο ρητά δηλωμένο εύρος των 228 runs. Η αξία της υλοποίησης είναι η ελεγχόμενη σύγκριση μαθησιακής συμπεριφοράς και λειτουργικού κόστους. Το risk score παραμένει heuristic που οργανώνει το HE budget.

Συμπληρωματική αξιολόγηση και συμπεράσματα

Η συμπληρωματική σειρά περιλαμβάνει 228 επιτυχείς εκτελέσεις σε 76 διαμορφώσεις με seeds 1, 2 και 3. Επαναχρησιμοποιήθηκαν 119 ολοκληρωμένα runs και προστέθηκαν 109. Μαζί με την αρχική σειρά των 402 runs προκύπτουν 630 διακριτές ολοκληρωμένες εκτελέσεις. Πρόκειται για επιλεγμένο υποσύνολο του ευρύτερου σχεδιασμού των 1.440 runs, με 1.212 εκτελέσεις αναβληθείσες λόγω διαθέσιμου υπολογιστικού χρόνου [20], [21].

Ο βασικός συμπληρωματικός σχεδιασμός καλύπτει Dirichlet α=0,5, τρία datasets, 5 και 10 clients, Caveman και Barabási–Albert και πέντε security modes, με τρία seeds ανά συνδυασμό. Οι πρόσθετες συγκρίσεις α=0,1/1,0, IID και shards στις νέες τοπολογίες αφορούν μόνο το CIFAR-10 baseline. Διατηρούνται τα πλήρη datasets, το MLP με 128 κρυφές μονάδες, οι 20 γύροι, το ένα local epoch, το batch size 32 και το learning rate 0,01.

Στη Dirichlet, μικρότερο α παράγει κατά κανόνα εντονότερο label skew και μεταβάλλει τα πλήθη δειγμάτων ανά client. Η Caveman χρησιμοποιεί δύο συνδεδεμένες κοινότητες με ισορροπημένα μεγέθη, ενώ η Barabási–Albert χρησιμοποιεί preferential attachment με m=2. Στις έξι baseline συγκρίσεις για α=0,5, η διαφορά Barabási–Albert μείον Caveman κυμαίνεται από −1,60 έως +1,54 ποσοστιαίες μονάδες. Η κατάταξη αλλάζει ανά dataset και πλήθος clients, επομένως δεν προκύπτει γενική υπεροχή μίας τοπολογίας.

Στο CIFAR-10, η αύξηση του α από 0,1 σε 1,0 συνδέεται με βελτίωση baseline accuracy κατά 11,41 έως 14,61 ποσοστιαίες μονάδες. Η απόσταση IID από shards είναι 18,44 έως 21,25 μονάδες. Η πτώση εμφανίζεται ήδη στο baseline και δεν αποδίδεται αποκλειστικά στον μηχανισμό προστασίας. Επειδή το α μεταβάλλει τόσο τη σύνθεση labels όσο και τα μεγέθη των τοπικών συνόλων, η σύγκριση δεν απομονώνει έναν μόνο τύπο ετερογένειας.

Στα 144 νέα αντιστοιχισμένα ζεύγη προστατευμένης μεθόδου και baseline, η μέγιστη απόλυτη διαφορά τελικής accuracy είναι 0,198 ποσοστιαίες μονάδες. Στα 35 adaptive/selective ζεύγη του ίδιου χρονικού περιβάλλοντος και session, η μέση ποσοστιαία μείωση του ειδικού χρόνου HE είναι 58,7%. Ένα από τα 36 δυνατά ζεύγη αποκλείστηκε από τη χρονική σύγκριση επειδή προέρχεται από διαφορετικά sessions. Το όφελος αφορά μόνο την επεξεργασία HE και δεν ισοδυναμεί με ίδια μείωση ολόκληρου του training time ή με απόδειξη ισοδύναμης ιδιωτικότητας.

Η εργασία υποστηρίζει την ελεγχόμενη σύγκριση μαθησιακής συμπεριφοράς, λειτουργικού κόστους και ακεραιότητας καταγραφών. Το μικρό πλήθος seeds, οι μικροί γράφοι και το σταθερό MLP περιορίζουν τη γενίκευση. Μελλοντική επέκταση είναι η κάλυψη των αναβληθέντων συνδυασμών, περισσότερα seeds στο sensitivity, μεγαλύτερα μοντέλα ή training budgets, ανεξάρτητες φυσικές συσκευές και πειράματα επιθέσεων, collusion και dropout. Η παρούσα αξιολόγηση διατηρεί ρητή τη διάκριση μεταξύ υλοποιημένης λειτουργικότητας και μη αποδεδειγμένων εγγυήσεων ασφάλειας.

Λέξεις κλειδιά: αποκεντρωμένη ομοσπονδιακή μάθηση, CKKS, pairwise masking, προσαρμοστική προστασία, ακεραιότητα καταγραφών, Dirichlet, Caveman, Barabási–Albert, MNIST, Fashion-MNIST, CIFAR-10.

Abstract

This thesis implements and evaluates a decentralized federated learning prototype with five aggregation modes: plaintext baseline, simple additive masking, pairwise masking, selective CKKS homomorphic encryption, and adaptive hybrid protection. The adaptive policy allocates homomorphic encryption to selected target neighborhoods using a heuristic score derived from model updates. Separate hash-chain and signed Merkle audit demonstrations address stored-record integrity.

The evaluation contains 630 completed runs in two distinct series. The original series comprises 360 validation runs, 30 sensitivity runs, and 12 local HTTP network demonstrations. A supplementary series contains 228 runs in 76 configurations with seeds 1, 2, and 3. It covers Dirichlet alpha 0.5 on Caveman and Barabási–Albert topologies across all three datasets, plus baseline CIFAR-10 comparisons under additional partitions. Full datasets, the MLP with 128 hidden units, and the 20-round training budget are retained. The wider 1,440-run design remains incomplete.

In the supplementary series, the largest absolute final accuracy difference from matched baseline is 0.198 percentage points across 144 pairs. Adaptive hybrid reduces HE processing time by a mean of 58.7% across 35 same-session adaptive/selective pairs. The ranking of Caveman and Barabási–Albert changes across datasets and client counts. On CIFAR-10, increasing Dirichlet alpha from 0.1 to 1.0 is associated with an 11.41 to 14.61 percentage-point improvement in baseline accuracy. These descriptive findings do not establish privacy equivalence or the same reduction in end-to-end training time.

Timing results remain separate by execution profile, serial or parallel environment, and execution session. Two workers run independent supplementary experiments concurrently, with clients trained serially within each run. Local HTTP demonstrations use smaller data subsets. Means and sample standard deviations are descriptive estimates from three seeds; the original sensitivity study has one seed. Attack resistance, collusion, dropouts, and distributed key management require separate evaluation.

Keywords: decentralized federated learning, homomorphic encryption, pairwise masking, adaptive protection, auditability, MNIST, Fashion-MNIST, CIFAR-10.

Περιεχόμενα

Περίληψη i
Abstract vi
Κατάλογος βασικών σχημάτων viii
Κατάλογος βασικών πινάκων ix
Συντομογραφίες και βασικοί όροι x
1. Εισαγωγή 1
2. Θεωρητικό υπόβαθρο Μηχανικής Μάθησης και Federated Learning 5
3. Ασφάλεια, ιδιωτικότητα και threat model στο Federated Learning 16
4. Σχεδιασμός συστήματος και end-to-end αρχιτεκτονική 22
5. Πειραματική μεθοδολογία και κοινές ρυθμίσεις 27
6. Μηχανισμοί προστασίας στο πειραματικό πρωτότυπο 28
7. Πειραματική μεθοδολογία και ακεραιότητα αποτελεσμάτων 33
8. Συγκριτικά αποτελέσματα 35
9. Ανάλυση IID έναντι non-IID 40
10. Ανάλυση ευαισθησίας Adaptive Hybrid 42
11. Εκτεταμένη επικύρωση πολλαπλών seeds 44
12. Lightweight Blockchain Audit Layer 53
13. Advanced Audit Layer με Ed25519 και Merkle proofs 58
14. Ενοποιημένη αποτίμηση της συνεισφοράς 64
15. Περιορισμοί και απειλές εγκυρότητας 65
16. Συμπεράσματα και επόμενα βήματα 66
Παράρτημα Α — Αναπαραγωγιμότητα 68
Παράρτημα Β Προγενέστεροι έλεγχοι πλατφόρμας και Docker 70
Παράρτημα Γ — Χαρτογράφηση λογισμικού και modules 74
Παράρτημα Δ — Αναλυτικά αποτελέσματα και validation tables 77
Παράρτημα Ε Έλεγχος και αντιστοίχιση πειραματικών τεκμηρίων 84
Παράρτημα ΣΤ — Αναλυτικός τεχνικός οδηγός υλοποίησης 85
Παράρτημα Ζ — Threat-model matrix και ασφαλής ερμηνεία αποτελεσμάτων 91
Παράρτημα Η — Γλωσσάριο, συμβολισμοί και ερμηνευτικές σημειώσεις 94
Βιβλιογραφία 98

Κατάλογος βασικών σχημάτων

Σχήμα 1 Εννοιολογική ροή του DFL prototype: κατανομή dataset, local training, neighborhood aggregation και επανάληψη rounds. 4
Σχήμα 2 Επεξηγηματικό διάγραμμα του MLP 784→128→10 και της ροής προς μία τελική πρόβλεψη. 7
Σχήμα 3 Softmax probability όταν ένα output score αυξάνεται και τα υπόλοιπα εννέα παραμένουν σταθερά. 9
Σχήμα 4 Βασικός κύκλος optimization μέσα στο local training. 10
Σχήμα 5 Ενδεικτική σχέση model capacity, training accuracy και accuracy σε unseen data. 12
Σχήμα 6 Ring topology πέντε clients. Κάθε target κάνει aggregation με τον εαυτό του και τους δύο γείτονές του. 14
Σχήμα 7 Απλοποιημένο παράδειγμα pairwise-canceling masking για δύο contributions. 18
Σχήμα 8 Η Adaptive Hybrid απόφαση: update norms, risk ranking και επιλογή μεταξύ Selective CKKS και pairwise masking. 20
Σχήμα 9 Μέγιστο cancellation error στην τελική validation καμπάνια 29
Σχήμα 10 Μείωση ειδικού χρόνου HE σε αντιστοιχισμένα ζεύγη cached GPU 30
Σχήμα 11 Επιλεγμένα HE targets στο παράδειγμα MNIST IID με ratio 0,4 31
Σχήμα 12 Ενδεικτικό heuristic risk score για MNIST με seed 42 32
Σχήμα 13 Baseline accuracy στα τρία datasets για IID και non-IID 36
Σχήμα 14 Καμπύλες baseline και adaptive hybrid στο MNIST με μέση accuracy από τρία seeds 37
Σχήμα 15 Καμπύλες baseline και adaptive hybrid στο Fashion-MNIST με μέση accuracy από τρία seeds 38
Σχήμα 16 Καμπύλες baseline και adaptive hybrid στο CIFAR-10 με μέση accuracy από τρία seeds 38
Σχήμα 17 Υπολογισμένη επικοινωνία στο MNIST IID με 5 clients και ring 39
Σχήμα 18 Επίδραση της τοπολογίας στη non-IID baseline accuracy με 5 clients 40
Σχήμα 19 Τελική accuracy ανά HE ratio με ένα seed και πλήρη datasets 42
Σχήμα 20 Ειδικός χρόνος HE ανά target ratio στα 30 sensitivity runs 43
Σχήμα 21 Accuracy των τοπικών HTTP demos μετά από δύο γύρους 47
Σχήμα 22 Baseline accuracy με Dirichlet α=0,5 και 3 seeds ανά συνδυασμό με μπάρες sample SD 49
Σχήμα 23 CIFAR-10 baseline ανά κατανομή και τοπολογία με mean και sample SD από 3 seeds 50
Σχήμα 24 Ειδικός χρόνος HE στο CIFAR-10 και Barabási–Albert στο ίδιο session με mean και sample SD από 3 seeds 51
Σχήμα 25 Accuracy που καταγράφηκε ανά blockchain round. 55
Σχήμα 26 Communication bytes ανά blockchain round. 55
Σχήμα 27 Χρόνος δημιουργίας block. 56
Σχήμα 28 Μέγεθος block ανά round. 56
Σχήμα 29 Κατανομή των hash prefixes. 57
Σχήμα 30 Συνολική κατάσταση blockchain verification. 57
Σχήμα 31 Accuracy trace του audited experiment. 60
Σχήμα 32 Communication bytes ανά audited round. 61
Σχήμα 33 Χρόνος δημιουργίας audit record. 61
Σχήμα 34 Μέγεθος audit record ανά round. 62
Σχήμα 35 Adaptive HE targets που καταγράφηκαν στο ledger. 62
Σχήμα 36 Προγενέστερο operator dashboard με τρεις online κόμβους και pairwise masking 72
Σχήμα 37 Σύνοψη επαλήθευσης των προγενέστερων Docker audit artifacts 72
Σχήμα 38 Κατάσταση ανεξάρτητου κόμβου στο προγενέστερο Docker demo 73

Κατάλογος βασικών πινάκων

Πίνακας 1 Συντομογραφίες που χρησιμοποιούνται στην εργασία. x
Πίνακας 2 Διάκριση batch, epoch και communication round. 11
Πίνακας 3 Εννοιολογική σύγκριση IID και non-IID partitions. 13
Πίνακας 4 Βασική configuration του experiment runner. 22
Πίνακας 5 Μετρικές που καταγράφονται από το prototype. 25
Πίνακας 6 Σχεδιασμός της τελικής πειραματικής αξιολόγησης 27
Πίνακας 7 Σύνοψη εκτελέσεων 33
Πίνακας 8 Τελική test accuracy επί τοις εκατό 35
Πίνακας 9 Τελικό test loss στην ίδια διαμόρφωση 36
Πίνακας 10 Adaptive hybrid ratio 0,4 σε σχέση με selective HE 39
Πίνακας 11 Baseline non-IID accuracy ανά τοπολογία και πλήθος clients 40
Πίνακας 12 Εύρος accuracy και μεταβολή χρόνου HE στο sensitivity 42
Πίνακας 13 Αρχική εκτέλεση χρόνοι γύρου σε s για 5 clients και ring 44
Πίνακας 14 Γρήγορη εκτέλεση χρόνοι γύρου σε s για 5 clients και ring 45
Πίνακας 15 Πλήρη baseline benchmarks 20 γύρων 45
Πίνακας 16 Αποτελέσματα network demos 46
Πίνακας 17 Εύρος της επιλεγμένης συμπληρωματικής σειράς 48
Πίνακας 18 Baseline accuracy στη συμπληρωματική σειρά με Dirichlet α=0,5 49
Πίνακας 19 CIFAR-10 baseline accuracy ως mean ± sample SD 50
Πίνακας 20 Χρόνος HE ανά γύρο στο συγκεκριμένο παράδειγμα 51
Πίνακας 21 Βασικά πεδία του lightweight blockchain block. 53
Πίνακας 22 Αποτελέσματα επαλήθευσης του blockchain_polish_3r. 54
Πίνακας 23 Περιεχόμενο και κατάσταση των τεσσάρων blocks. 54
Πίνακας 24 Modules του Advanced Audit Layer. 58
Πίνακας 25 Όρια και περιεχόμενο του audit package. 58
Πίνακας 26 Συνοπτικά στοιχεία του Advanced Audit demo. 59
Πίνακας 27 Round-level audit summary. 59
Πίνακας 28 Αποτελέσματα των ελεγχόμενων tampering demonstrations. 60
Πίνακας 29 Σύγκριση των δύο audit επιπέδων. 63
Πίνακας 30 Σύνοψη προγενέστερων ελέγχων Docker 71
Πίνακας 31 Χαρτογράφηση βασικών modules. 74
Πίνακας 32 Κύριες παραδοχές ασφαλείας. 76
Πίνακας 33 Πλήρη validation αποτελέσματα MNIST 77
Πίνακας 34 Πλήρη validation αποτελέσματα Fashion-MNIST 79
Πίνακας 35 Πλήρη validation αποτελέσματα CIFAR-10 80
Πίνακας 36 Sensitivity MNIST 82
Πίνακας 37 Sensitivity Fashion-MNIST 82
Πίνακας 38 Sensitivity CIFAR-10 83
Πίνακας 39 Βασικά invariants ανά layer. 90
Πίνακας 40 Threat-model matrix και evidence. 91
Πίνακας 41 Γλωσσάριο βασικών όρων. 94
Πίνακας 42 Συμβολισμοί που χρησιμοποιούνται στις εξισώσεις. 96

Συντομογραφίες και βασικοί όροι

Ο Πίνακας 1 συγκεντρώνει τις συντομογραφίες που χρησιμοποιούνται στο σύγγραμμα.

Πίνακας 1 Συντομογραφίες που χρησιμοποιούνται στην εργασία.

Συντομογραφία	Επεξήγηση
AI	Artificial Intelligence / Τεχνητή Νοημοσύνη
ML	Machine Learning / Μηχανική Μάθηση
FL	Federated Learning
DFL	Decentralized Federated Learning
IID	Independent and Identically Distributed
non-IID	Μη ομοιογενής / ετερογενής κατανομή δεδομένων
MLP	Multi-Layer Perceptron
SGD	Stochastic Gradient Descent
HE	Homomorphic Encryption
CKKS	Cheon–Kim–Kim–Song approximate HE scheme
SA	Secure Aggregation
DP	Differential Privacy
PKI	Public Key Infrastructure
SHA-256	Secure Hash Algorithm 256-bit
Ed25519	Edwards-curve Digital Signature Algorithm
MVP	Minimum Viable Prototype
MiB	Mebibyte, 2^20 bytes
API	Application Programming Interface
JSONL	JSON Lines
GPU	Graphics Processing Unit
CPU	Central Processing Unit

1. Εισαγωγή

Η συνολική αλληλουχία κατανομής δεδομένων, τοπικής εκπαίδευσης και συνάθροισης αποτυπώνεται στο Σχήμα 1.

1.1 Κίνητρο και γενικό πλαίσιο

Η εκπαίδευση σύγχρονων μοντέλων Μηχανικής Μάθησης προϋποθέτει πρόσβαση σε επαρκή και αντιπροσωπευτικά δεδομένα. Στην πράξη, όμως, τα δεδομένα συχνά βρίσκονται κατανεμημένα σε διαφορετικούς οργανισμούς, συσκευές ή διοικητικά domains. Νοσοκομεία διατηρούν ανεξάρτητους φακέλους ασθενών, τηλεπικοινωνιακοί κόμβοι παρατηρούν διαφορετικά τμήματα του δικτύου, βιομηχανικές εγκαταστάσεις συλλέγουν ιδιόκτητη τηλεμετρία και προσωπικές συσκευές παράγουν δεδομένα που δεν είναι επιθυμητό να συγκεντρώνονται σε έναν εξωτερικό server. Η παραδοσιακή προσέγγιση της κεντρικής συλλογής δημιουργεί επομένως τεχνικές, νομικές και οργανωτικές δυσκολίες.

Το Federated Learning προσεγγίζει το πρόβλημα από διαφορετική κατεύθυνση: αντί να μεταφέρονται τα δεδομένα προς το μοντέλο, μεταφέρεται η γνώση που αποκτάται από το μοντέλο κοντά στα δεδομένα. Κάθε client εκπαιδεύει τοπικά ένα αντίγραφο κοινής αρχιτεκτονικής και αποστέλλει model parameters ή model updates για συνάθροιση. Η αρχική διατύπωση του Federated Averaging έδειξε ότι αυτή η συνεργασία μπορεί να επιτευχθεί με επαναλαμβανόμενα local optimization steps και περιοδική σύνθεση των μοντέλων [9]. Η ιδέα εξελίχθηκε σε ευρύτερο ερευνητικό πεδίο με εφαρμογές σε cross-device και cross-silo περιβάλλοντα [10].

Η αποκεντρωμένη εκδοχή του FL αφαιρεί και τον κεντρικό aggregation server. Η επικοινωνία πραγματοποιείται peer-to-peer σύμφωνα με μία τοπολογία δικτύου και η κοινή γνώση διαδίδεται σταδιακά μέσω τοπικών aggregations [1]. Η επιλογή αυτή είναι ελκυστική σε σενάρια όπου δεν υπάρχει καθολικά έμπιστος συντονιστής ή όπου το single point of failure ενός κεντρικού server θεωρείται ανεπιθύμητο. Παράλληλα, η αποκέντρωση μεταφέρει μέρος της πολυπλοκότητας στους ίδιους τους clients: η σύγκλιση, η ασφάλεια της ανταλλαγής και η επαληθευσιμότητα του ιστορικού πρέπει να επιτευχθούν χωρίς έναν μοναδικό trusted authority.

1.2 Γιατί η τοπική παραμονή των δεδομένων δεν αρκεί

Η βασική υπόσχεση του FL είναι ότι τα πρωτογενή δεδομένα δεν εγκαταλείπουν τον ιδιοκτήτη τους. Αυτό αποτελεί ουσιαστικό πλεονέκτημα, αλλά δεν συνεπάγεται αυτόματα πλήρη ιδιωτικότητα. Τα gradients και οι μεταβολές των παραμέτρων παράγονται ακριβώς επειδή το μοντέλο εκτέθηκε στα local data. Επομένως, τα updates μπορούν να φέρουν στατιστικό αποτύπωμα της τοπικής κατανομής. Η βιβλιογραφία έχει δείξει ότι υπό κατάλληλες συνθήκες είναι δυνατές membership inference, property inference και gradient inversion επιθέσεις, οι οποίες επιχειρούν να εξαγάγουν πληροφορία από την ίδια τη διαδικασία εκπαίδευσης [2], [11], [12].

Η προστασία των updates απαιτεί πρόσθετους μηχανισμούς. Το secure aggregation επιδιώκει να επιτρέψει τον υπολογισμό ενός αθροίσματος ή μέσου όρου χωρίς να αποκαλύπτονται οι επιμέρους συνεισφορές. Το pairwise masking είναι μία ελαφριά προσέγγιση στην οποία οι clients προσθέτουν αντίθετες μάσκες που ακυρώνονται κατά τη συνάθροιση [3]. Η Homomorphic Encryption επιτρέπει ακόμη ισχυρότερη απόκρυψη, καθώς οι πράξεις πραγματοποιούνται πάνω σε ciphertexts [4]. Το μειονέκτημα είναι ότι τα ciphertexts είναι μεγαλύτερα και οι κρυπτογραφικές πράξεις ακριβότερες από το plaintext arithmetic.

Το πρόβλημα της παρούσας εργασίας δεν αντιμετωπίζεται ως δίλημμα «ασφάλεια ή απόδοση», αλλά ως πρόβλημα σχεδιασμού trade-off. Η κεντρική ερώτηση είναι εάν η ισχυρότερη και ακριβότερη προστασία χρειάζεται να εφαρμόζεται ομοιόμορφα σε κάθε neighborhood και σε κάθε γύρο. Η Adaptive Hybrid προσέγγιση εξετάζει έναν ενδιάμεσο σχεδιασμό: pairwise masking ως default προστασία και Selective CKKS HE μόνο σε neighborhoods που κατατάσσονται υψηλότερα από έναν δυναμικό update-based δείκτη.

1.3 Στόχος της εργασίας

Στόχος είναι ο σχεδιασμός, η υλοποίηση και η πειραματική αποτίμηση ενός Secure Decentralized Federated Learning prototype με ελεγχόμενη κλιμάκωση των μηχανισμών προστασίας. Το έργο ξεκινά από baseline DFL ώστε να υπάρχει καθαρό σημείο αναφοράς και προσθέτει διαδοχικά simple masking, pairwise-canceling masking, Selective CKKS HE, Adaptive Hybrid security και δύο επίπεδα audit. Η σειρά αυτή επιτρέπει να παρατηρείται χωριστά το κόστος και η αριθμητική συμπεριφορά κάθε μηχανισμού.

Η αξιολόγηση εξετάζει μαθησιακή συμπεριφορά, κόστος και αριθμητική ορθότητα σε ελεγχόμενες διαμορφώσεις. Κάθε αντιστοιχισμένη σύγκριση κρατά ίδιο dataset, seed, πλήθος clients, τοπολογία, split και υπερπαραμέτρους. Η αρχική σειρά καλύπτει τρία datasets, δύο μεγέθη δικτύου και δύο τοπολογίες. Το heuristic risk score οργανώνει το κρυπτογραφικό budget, χωρίς να αποτελεί ανιχνευτή επιθέσεων ή απόδειξη ιδιωτικότητας.

Παράλληλα, η εργασία εξετάζει την ακεραιότητα και την ιχνηλασιμότητα ως διαφορετική διάσταση από το confidentiality. Το audit layer δεν αντικαθιστά το masking ή το HE. Αντίθετα, καταγράφει hashes, metadata, υπογραφές και Merkle proofs ώστε να μπορεί να ελεγχθεί εκ των υστέρων εάν τα αποθηκευμένα artifacts αλλοιώθηκαν. Με αυτό τον διαχωρισμό, η αρχιτεκτονική αντιμετωπίζει δύο διαφορετικά ερωτήματα: «ποιος μπορεί να δει το update κατά την ανταλλαγή;» και «μπορώ να ελέγξω αν το ιστορικό που αποθηκεύτηκε παραμένει αυθεντικό;».

1.4 Ερευνητικά ερωτήματα

1. RQ1 — Διατηρείται η μαθησιακή συμπεριφορά του baseline όταν προστίθενται masking και Selective HE;
2. RQ2 — Ποιο communication και computational overhead εισάγει κάθε security mode;
3. RQ3 — Ακυρώνονται αριθμητικά σωστά τα pairwise masks ώστε το decentralized aggregation να παραμένει ισοδύναμο με το plaintext average;

4. RQ4 — Μπορεί η HE να κατανέμεται επιλεκτικά με βάση update-derived risk score ώστε να μειώνεται το κόστος σε σχέση με ευρύτερη χρήση Selective HE;
5. RQ5 — Πώς διαφοροποιείται η συμπεριφορά μεταξύ IID και label-skewed non-IID partitions;
6. RQ6 — Μπορεί το training experiment να συνοδευτεί από επαληθεύσιμο audit trail χωρίς να αλλάζει ο μηχανισμός μάθησης;

1.5 Κύριες τεχνικές συνεισφορές

Η εργασία είναι κυρίως συνδυαστική και συστημική. Η αξία του prototype βρίσκεται στην ενοποίηση αποκεντρωμένου training, πολλαπλών security modes, μετρήσιμου adaptive policy και auditability σε κοινό reproducible pipeline. Το implementation επιτρέπει να αλλάζει το security mode από command line χωρίς να μεταβάλλεται το MLP, το data partition ή η τοπολογία, γεγονός που διευκολύνει άμεσες συγκρίσεις.

Η Adaptive Hybrid πολιτική εφαρμόζει risk-aware κατανομή κρυπτογραφικού κόστους στο επίπεδο aggregation neighborhood. Τα update norms του επιλεγμένου final layer υπολογίζονται μετά το local training. Για κάθε target neighborhood συνδυάζονται το μέγιστο και το μέσο norm και, στην non-IID περίπτωση, χρησιμοποιείται conservative multiplier. Τα neighborhoods ταξινομούνται και μόνο το καθορισμένο ποσοστό λαμβάνει Selective HE. Η υλοποίηση αυτή δεν παρουσιάζεται ως formal privacy guarantee· παρουσιάζεται ως ελεγχόμενος μηχανισμός resource allocation που επιτρέπει sensitivity experiments.

Η δεύτερη συστημική συνεισφορά είναι ο διαχωρισμός privacy protection και integrity verification. Το lightweight blockchain παρέχει εκπαιδευτική hash-chain καταγραφή, ενώ το advanced audit package χρησιμοποιεί πραγματικές Ed25519 υπογραφές, Merkle proofs και append-only ledger. Το Docker MVP μεταφέρει αυτές τις ιδέες σε τρεις ανεξάρτητους networked nodes με πραγματικά deployment keys και verifiable logs.

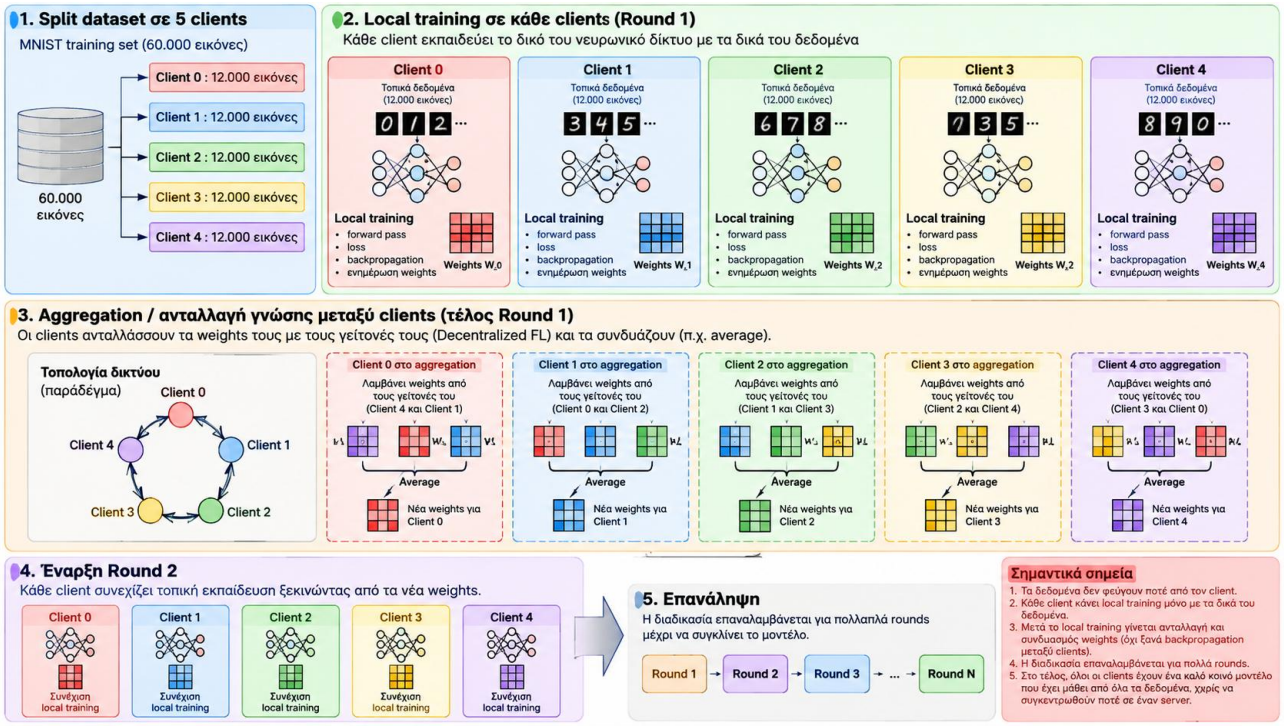
1.6 Μεθοδολογία και εύρος της αξιολόγησης

Η αξιολόγηση περιλαμβάνει δύο διακριτές σειρές με 630 ολοκληρωμένες εκτελέσεις. Η αρχική σειρά περιλαμβάνει 360 validation, 30 sensitivity και 12 τοπικά HTTP demos. Η συμπληρωματική σειρά περιλαμβάνει 228 runs σε 76 συνδυασμούς με seeds 1, 2 και 3. Καλύπτει Dirichlet α=0,5, Caveman και Barabási–Albert στα τρία datasets, με πρόσθετες baseline συγκρίσεις κατανομών στο CIFAR-10. Διατηρούνται τα πλήρη datasets, το MLP με 128 κρυφές μονάδες και οι 20 γύροι. Το ευρύτερο πλάνο 1.440 runs παραμένει μερικώς εκτελεσμένο. Τα προηγούμενα audit και Docker demos αποτελούν χωριστά τεκμήρια λειτουργικότητας [20], [21].

Οι συγκρίσεις learning utility χρησιμοποιούν τελική accuracy και loss, ενώ οι συγκρίσεις κόστους διαχωρίζουν υπολογισμένο model traffic, συνολικό χρόνο γύρου και ειδικό χρόνο HE. Οι χρόνοι διατηρούνται χωριστοί ανά execution profile, σειριακό ή παράλληλο περιβάλλον και execution session. Τα raw round-level CSV, το manifest και τα summaries επιτρέπουν την αντιστοίχιση κάθε αποτελέσματος με τις ακριβείς παραμέτρους του [20].

1.7 Δομή της διπλωματικής

Το Κεφάλαιο 2 παρουσιάζει το απαραίτητο θεωρητικό υπόβαθρο για supervised learning, MLP, gradients, optimization, IID/non-IID δεδομένα, Federated Learning και decentralized consensus. Το Κεφάλαιο 3 αναλύει το threat model και τις βασικές οικογένειες προστασίας. Το Κεφάλαιο 4 περιγράφει αναλυτικά την προτεινόμενη αρχιτεκτονική και το end-to-end pipeline. Τα Κεφάλαια 5 και 6 ορίζουν το πειραματικό περιβάλλον και τις security modes. Τα επόμενα κεφάλαια παρουσιάζουν μεθοδολογία, αποτελέσματα, validation, blockchain/audit layers, περιορισμούς και συμπεράσματα. Τα παραρτήματα συγκεντρώνουν εντολές αναπαραγωγής, platform evidence και τεχνική χαρτογράφηση του κώδικα.



Σχήμα 1 Εννοιολογική ροή του DFL prototype: κατανομή dataset, local training, neighborhood aggregation και επανάληψη rounds.

2. Θεωρητικό υπόβαθρο Μηχανικής Μάθησης και Federated Learning

Η αρχιτεκτονική του MLP παρουσιάζεται στο Σχήμα 2, η Softmax στο Σχήμα 3 και ο κύκλος εκπαίδευσης στο Σχήμα 4. Το Σχήμα 5 διακρίνει εννοιολογικά προσαρμογή και γενίκευση, ενώ το Σχήμα 6 ορίζει τη ring γειτονιά. Ο Πίνακας 2 αποσαφηνίζει batch, epoch και round και ο Πίνακας 3 τις κατανομές IID και non-IID.

2.1 Επιβλεπόμενη μάθηση και πρόβλημα ταξινόμησης

Στην επιβλεπόμενη μάθηση, το dataset αποτελείται από ζεύγη (x, y), όπου x είναι η είσοδος και y η επιθυμητή έξοδος. Στην ταξινόμηση εικόνων, x μπορεί να είναι ένας πίνακας pixels και y μία διακριτή κατηγορία. Το μοντέλο fθ(x), με παραμέτρους θ, υπολογίζει scores για τις διαθέσιμες κλάσεις. Η εκπαίδευση αναζητά τιμές των παραμέτρων που μειώνουν μία loss function σε πολλά παραδείγματα, με την προσδοκία ότι η συμπεριφορά θα γενικεύεται και σε unseen data.

Η έννοια της γενίκευσης είναι κρίσιμη. Ένα μοντέλο που απλώς απομνημονεύει τα training samples μπορεί να έχει υψηλή training accuracy χωρίς να επιτυγχάνει αντίστοιχη test accuracy. Για αυτό η αξιολόγηση της διπλωματικής χρησιμοποιεί κοινό test set που δεν συμμετέχει στο local optimization. Κάθε client αξιολογείται στο ίδιο test loader και οι metrics μέσοι όροι χρησιμοποιούνται για να περιγραφεί η συνολική συμπεριφορά του decentralized συστήματος.

Στο DFL η επιβλεπόμενη μάθηση δεν αλλάζει μαθηματικά· αλλάζει το πού βρίσκονται τα samples και πώς συνδυάζονται οι parameters μετά το local optimization. Κάθε client εκτελεί κανονικό neural-network training πάνω στο δικό του subset. Η federated διάσταση εμφανίζεται μετά, όταν οι local model states ανταλλάσσονται ή προστατεύονται και συντίθενται.

2.2 Τα datasets MNIST Fashion MNIST και CIFAR 10

Το MNIST περιέχει εικόνες χειρόγραφων ψηφίων 28×28 σε grayscale, με δέκα κλάσεις, 60.000 training και 10.000 test εικόνες [19]. Το Fashion-MNIST διατηρεί τις ίδιες διαστάσεις και μεγέθη splits, αλλά αντικαθιστά τα ψηφία με δέκα κατηγορίες ενδυμάτων [17]. Το CIFAR-10 περιλαμβάνει έγχρωμες εικόνες 32×32, δέκα κλάσεις, 50.000 training και 10.000 test εικόνες [18].

Η χρήση τριών datasets επιτρέπει να εξεταστεί αν η συμπεριφορά των aggregation modes διατηρείται όταν αλλάζει η δυσκολία ταξινόμησης και η διάσταση εισόδου. Η τελική καμπάνια χρησιμοποιεί ολόκληρα τα train και test splits στα validation και sensitivity. Τα μικρά υποσύνολα των HTTP demos περιγράφονται χωριστά, ώστε οι accuracies τους να μην συγκρίνονται απευθείας με τα πλήρη runs.

Στο IID split των MNIST και Fashion-MNIST, οι πέντε clients λαμβάνουν από 12.000 training δείγματα ή οι δέκα από 6.000. Για CIFAR-10 τα αντίστοιχα μεγέθη είναι 10.000 και 5.000. Κάθε client αξιολογείται στο κοινό πλήρες test split. Η ισορροπία του πλήθους δειγμάτων δεν συνεπάγεται ίδια κατανομή labels στο non-IID σενάριο.

2.3 Από την εικόνα στο διάνυσμα εισόδου

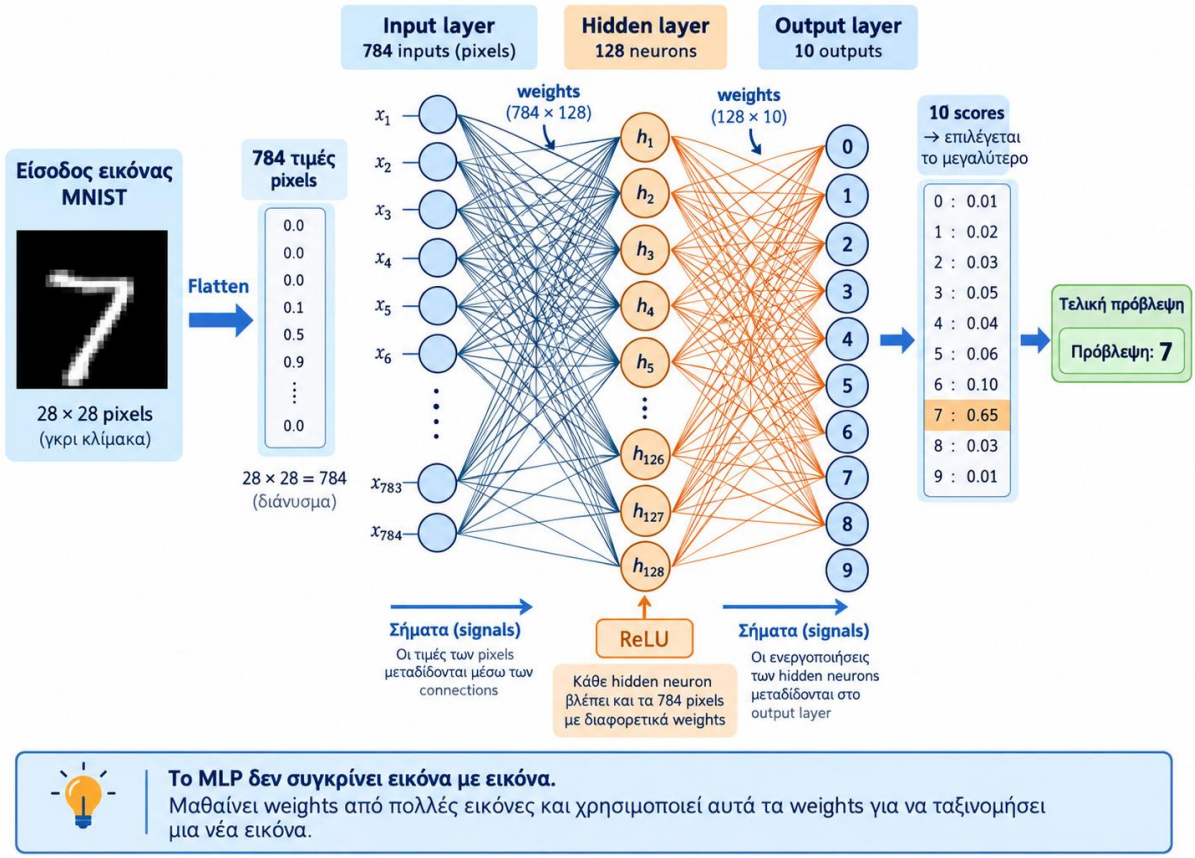
Το SimpleMLP ξεκινά με Flatten. Η λειτουργία δεν «κόβει» την εικόνα σε semantic περιοχές· απλώς αναδιατάσσει τον πίνακα 28×28 σε vector 784 στοιχείων. Κάθε θέση του vector αντιστοιχεί σε συγκεκριμένη θέση pixel. Οι τιμές των pixels λειτουργούν ως αριθμητικές είσοδοι για το πρώτο Linear layer.

Αυτή η διάκριση είναι σημαντική για την κατανόηση των weights. Ένα weight δεν αποτελεί αποθηκευμένη εικόνα ούτε πιθανότητα. Είναι παράμετρος μίας συγκεκριμένης σύνδεσης μεταξύ εισόδου και neuron. Ένας hidden neuron διαθέτει 784 διαφορετικά weights, ένα για κάθε input dimension, καθώς και bias. Επομένως μπορεί να ανταποκρίνεται σε διαφορετικό συνδυασμό φωτεινών και σκοτεινών pixels από έναν άλλο hidden neuron.

2.4 Αρχιτεκτονική MLP με 128 κρυφές μονάδες

Για MNIST και Fashion-MNIST χρησιμοποιείται MLP 784 → 128 → 10, με ReLU μεταξύ των γραμμικών επιπέδων. Το πρώτο επίπεδο έχει 784×128 βάρη και 128 biases. Για CIFAR-10 χρησιμοποιείται MLP 3072 → 128 → 10, καθώς 32×32×3 = 3072 τιμές εισόδου. Και στις δύο περιπτώσεις το τελικό επίπεδο έχει 128×10 + 10 = 1.290 παραμέτρους. Το ακόλουθο διάγραμμα δείχνει την εκδοχή grayscale.

Το πλήθος 128 hidden units δεν προκύπτει από θεωρητικό optimum. Αποτελεί πρακτική επιλογή χωρητικότητας. Με πολύ μικρό hidden layer το δίκτυο μπορεί να μην έχει αρκετή εκφραστική δύναμη, ενώ η υπερβολική αύξηση της χωρητικότητας αυξάνει υπολογιστικό κόστος και μπορεί να ενισχύσει overfitting. Σε πραγματικά projects το κατάλληλο μέγεθος επιλέγεται εμπειρικά μέσω validation και hyperparameter search.



Σχήμα 2 Επεξηγηματικό διάγραμμα του MLP 784→128→10 και της ροής προς μία τελική πρόβλεψη.

2.5 Weights, biases και learned representations

Για έναν hidden neuron j, μία απλοποιημένη γραμμική πράξη γράφεται ως $z_j = \Sigma_i w_{ji}x_i + b_j$. Η τιμή w_{ji} ρυθμίζει πόσο επηρεάζει το input i τη συγκεκριμένη hidden activation. Το bias b_j επιτρέπει μετατόπιση του activation threshold ανεξάρτητα από το input. Τα weights αρχικοποιούνται με μικρές διαφορετικές τιμές, ώστε οι neurons να μην ξεκινούν απολύτως συμμετρικά.

Κατά την εκπαίδευση οι hidden neurons δεν λαμβάνουν explicit labels όπως «πάνω καμπύλη» ή «κάθετη γραμμή». Οι αναπαραστάσεις προκύπτουν έμμεσα επειδή διαφορετικές παράμετροι λαμβάνουν διαφορετικά gradients. Ένας neuron που συμβάλλει σε σωστές ταξινομήσεις ενισχύει χρήσιμους συνδυασμούς, ενώ άλλες κατευθύνσεις αποδυναμώνονται. Για λόγους διαίσθησης μπορούμε να μιλάμε για learned patterns, αλλά δεν πρέπει να θεωρείται ότι κάθε neuron αντιστοιχεί απαραίτητα σε μία καθαρά ανθρώπινα ερμηνεύσιμη έννοια.

Στο output layer, οι 128 hidden activations συνδυάζονται ξανά με διαφορετικό matrix weights για κάθε μία από τις δέκα κλάσεις. Επομένως ένα hidden pattern μπορεί να υποστηρίζει περισσότερα από ένα digits και η τελική ταξινόμηση προκύπτει από τη συνολική στάθμιση όλων των hidden activations.

2.6 ReLU και μη γραμμικότητα

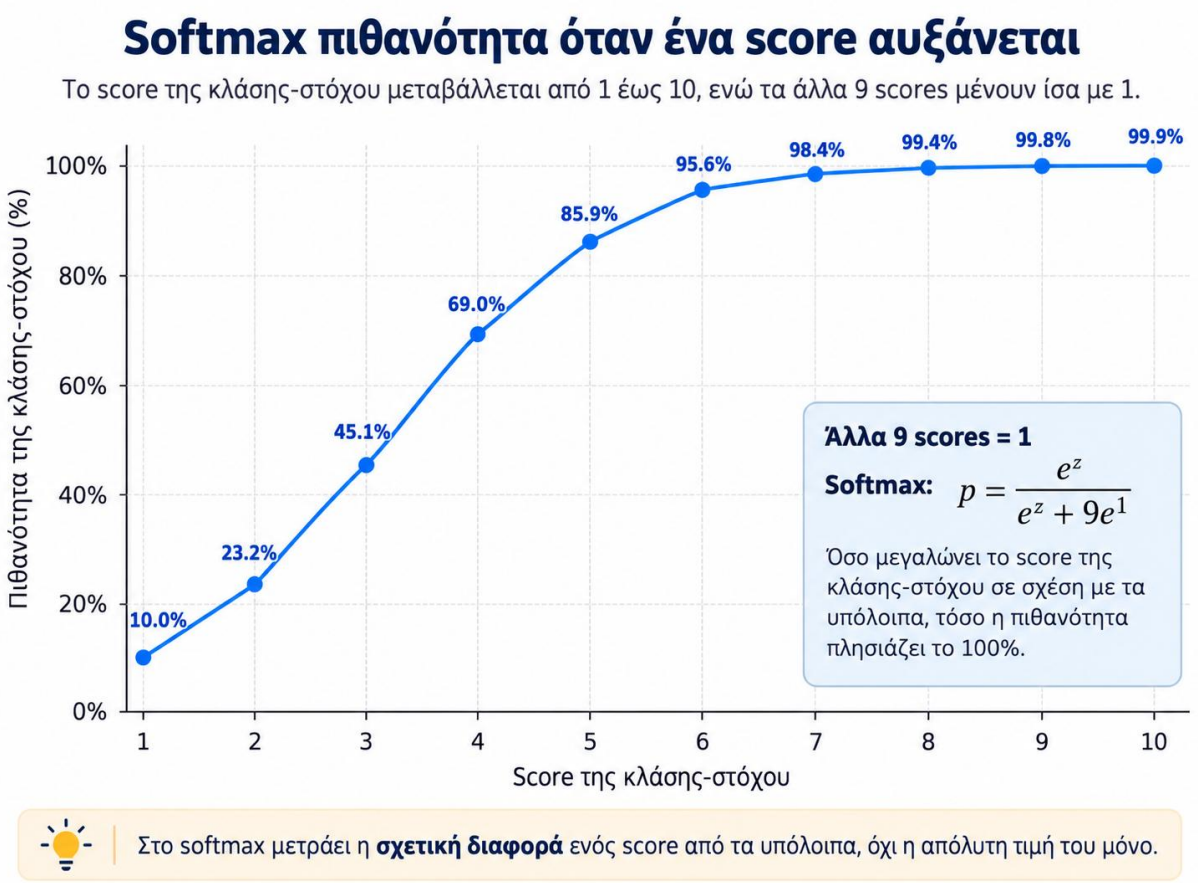
Μεταξύ hidden και output layer εφαρμόζεται ReLU. Η ReLU ορίζεται ως max(0, z) και εισάγει μη γραμμικότητα. Χωρίς activation function, η διαδοχή δύο linear layers θα μπορούσε να αναχθεί σε έναν μόνο γραμμικό μετασχηματισμό, περιορίζοντας δραστικά την εκφραστική ικανότητα του μοντέλου. Η ReLU επιτρέπει στο δίκτυο να σχηματίζει piecewise-linear representations και αποτελεί κοινή επιλογή σε μικρά και μεγάλα neural networks.

Η χρήση ReLU επηρεάζει και το gradient flow. Για θετικές pre-activations η παράγωγος είναι 1, ενώ για αρνητικές είναι 0. Στο μικρό MLP της εργασίας αυτή η συμπεριφορά είναι επαρκής και κρατά την αρχιτεκτονική απλή, ώστε η έμφαση να παραμένει στο decentralized security pipeline.

2.7 Logits και Softmax

Το output layer επιστρέφει δέκα raw scores, συχνά αποκαλούμενα logits. Τα logits δεν είναι weights και δεν είναι ποσοστά. Μπορούν να πάρουν οποιαδήποτε πραγματική τιμή. Η κλάση με το μεγαλύτερο logit είναι η argmax πρόβλεψη. Για ερμηνεία ως probability distribution μπορεί να εφαρμοστεί Softmax.

Η Softmax υπολογίζει $p_i = \exp(z_i) / \Sigma_j \exp(z_j)$. Αυτό σημαίνει ότι η πιθανότητα εξαρτάται από τη σχετική διαφορά μεταξύ των logits και όχι από μία απόλυτη αντιστοιχία «score 10 = 100%». Εάν όλα τα logits είναι ίσα σε πρόβλημα δέκα κλάσεων, κάθε κλάση λαμβάνει 10%. Εάν ένα logit αυξάνεται ενώ τα άλλα παραμένουν σταθερά, η πιθανότητά του πλησιάζει ασυμπτωτικά το 100%.



Σχήμα 3 Softmax probability όταν ένα output score αυξάνεται και τα υπόλοιπα εννέα παραμένουν σταθερά.

2.8 Cross-Entropy Loss

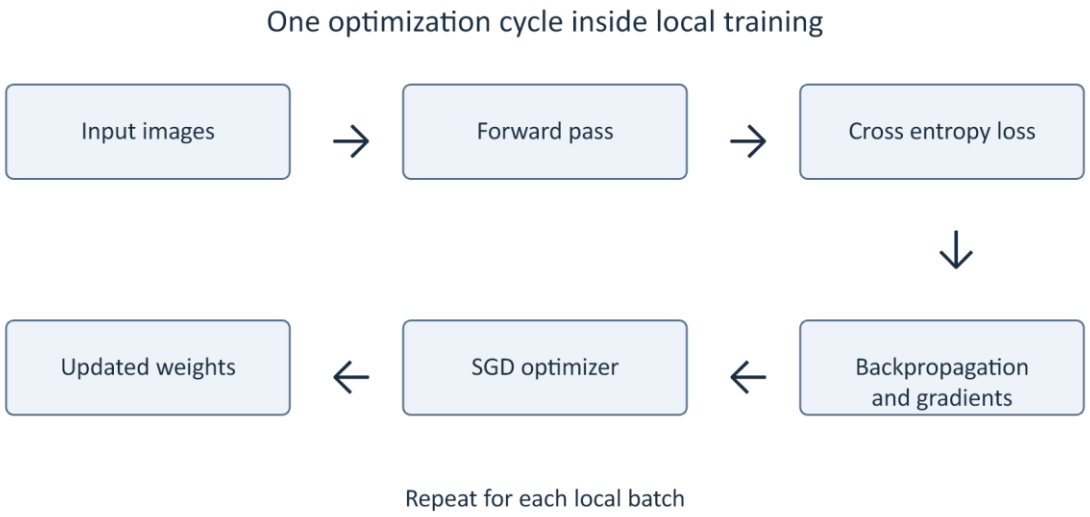
Η υλοποίηση χρησιμοποιεί CrossEntropyLoss της PyTorch. Η συνάρτηση δέχεται απευθείας τα logits και το σωστό class index, εφαρμόζοντας εσωτερικά την κατάλληλη log-softmax διατύπωση. Διαισθητικά, επιβάλλει μεγάλη ποινή όταν το model αποδίδει χαμηλή πιθανότητα στη σωστή κλάση και μικρότερη ποινή όταν η σωστή κλάση κυριαρχεί.

Το loss είναι scalar μέτρηση της ασυμφωνίας prediction και label. Δεν πρέπει να συγχέεται με το gradient. Το loss απαντά «πόσο κακή ήταν η πρόβλεψη;», ενώ το gradient απαντά «πώς πρέπει να μεταβληθεί μία παράμετρος για να αλλάξει το loss;». Η διάκριση αυτή είναι θεμελιώδης τόσο για το local training όσο και για την κατανόηση των model updates που αργότερα ανταλλάσσονται μεταξύ clients.

2.9 Backpropagation και gradients

Το backpropagation εφαρμόζει τον κανόνα αλυσίδας ώστε να υπολογίσει ∂L/∂w για κάθε trainable parameter. Το gradient έχει πρόσημο και μέγεθος. Το πρόσημο δείχνει την κατεύθυνση στην οποία αυξάνεται το loss, ενώ το μέγεθος εκφράζει την τοπική ευαισθησία του loss ως προς μικρή μεταβολή της παραμέτρου. Ο optimizer χρησιμοποιεί αυτή την πληροφορία για να κινηθεί προς την αντίθετη κατεύθυνση.

Στο implementation, για κάθε batch εκτελείται optimizer.zero_grad(), forward pass, υπολογισμός loss, loss.backward() και optimizer.step(). Η ακολουθία αυτή επαναλαμβάνεται για όλα τα batches της local epoch. Μετά το local training, το σύνολο των weights έχει αλλάξει. Η διαφορά W_after − W_before είναι το model update που ενδιαφέρει το Adaptive Hybrid risk calculation.



Σχήμα 4 Βασικός κύκλος optimization μέσα στο local training.

2.10 SGD και learning rate

Ο Client class χρησιμοποιεί Stochastic Gradient Descent με learning rate 0.01. Στην απλούστερη μορφή, η ενημέρωση γράφεται $w_{t+1} = w_t - \eta \nabla L(w_t)$, όπου η είναι το learning rate. Πολύ μεγάλο η μπορεί να προκαλέσει αστάθεια ή overshooting, ενώ πολύ μικρό η οδηγεί σε αργή σύγκλιση. Η τιμή 0.01 αποτελεί σταθερή experimental επιλογή και παραμένει ίδια σε όλα τα security modes.

Η σταθερότητα του optimizer είναι σημαντική για δίκαιη σύγκριση. Εάν κάθε security mode χρησιμοποιούσε διαφορετικό optimizer ή learning rate, μία διαφορά accuracy θα μπορούσε να προέρχεται από το optimization και όχι από τον μηχανισμό προστασίας. Η παρούσα μελέτη κρατά το learning pipeline κοινό και αλλάζει μόνο τον τρόπο με τον οποίο προστατεύονται και συντίθενται τα model states.

2.11 Batch, epoch και communication round

Το batch είναι μικρή ομάδα samples που χρησιμοποιείται για έναν optimization step. Με batch size 32, ο client που διαθέτει περίπου 12.000 IID samples εκτελεί περίπου 375 batches ανά local epoch. Μία epoch ολοκληρώνεται όταν όλα τα local samples έχουν χρησιμοποιηθεί μία φορά. Το communication round είναι μεγαλύτερη federated μονάδα: περιλαμβάνει local training, snapshot των model states, security processing, neighborhood aggregation και evaluation.

Η διάκριση είναι κρίσιμη. Batch και epoch περιγράφουν το local neural-network optimization. Round περιγράφει τον κύκλο συνεργασίας μεταξύ clients. Στα κύρια experiments χρησιμοποιείται local_epochs =

1 και num_rounds = 20. Συνεπώς κάθε client βλέπει μία φορά το local partition του ανά round και στη συνέχεια ανταλλάσσεται/συντίθεται η αποκτηθείσα γνώση.

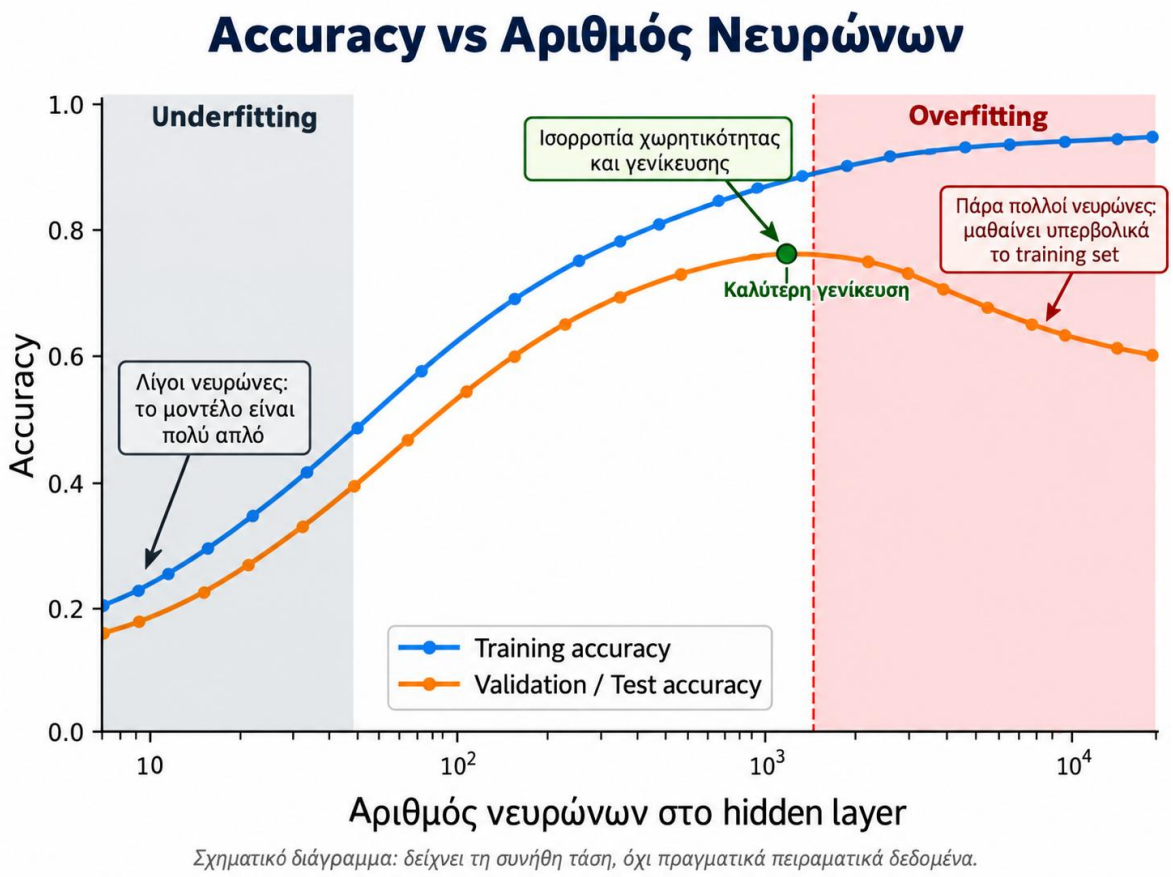
Πίνακας 2 Διάκριση batch, epoch και communication round.

Έννοια	Τι περιγράφει	Στο κύριο experiment
Batch	Μικρή ομάδα samples πριν από optimizer update	32 samples
Epoch	Ένα πλήρες πέρασμα από το local dataset	1 local epoch/round
Round	Local training + security + aggregation + evaluation	20 rounds

2.12 Overfitting, capacity και generalization

Η αύξηση της model capacity δεν εγγυάται μονοτονική βελτίωση της test accuracy. Ένα μεγαλύτερο μοντέλο μπορεί να μειώσει το training error, αλλά μετά από ένα σημείο να προσαρμόζεται υπερβολικά στις ιδιαιτερότητες του training set. Το overfitting παρατηρείται όταν η training performance συνεχίζει να βελτιώνεται ενώ η validation/test performance σταθεροποιείται ή υποχωρεί.

Στη διπλωματική δεν πραγματοποιείται εκτεταμένο neural-architecture search, επειδή ο στόχος δεν είναι να βρεθεί το καλύτερο classifier για MNIST. Το MLP λειτουργεί ως σταθερό computational substrate πάνω στο οποίο συγκρίνονται οι security mechanisms. Η επιλογή αυτή μειώνει τον αριθμό των ανεξάρτητων μεταβλητών και διευκολύνει την ερμηνεία των αποτελεσμάτων.



Σχήμα 5 Ενδεικτική σχέση model capacity, training accuracy και accuracy σε unseen data.

2.13 IID δεδομένα

Στην IID περίπτωση, τα training indices ανακατεύονται με seeded random permutation και χωρίζονται σε ισορροπημένα partitions. Επειδή το MNIST είναι συνολικά σχετικά ισορροπημένο ανά digit, κάθε client λαμβάνει κατά προσέγγιση παρόμοια class distribution. Τα local optimization directions επομένως τείνουν να είναι περισσότερο συμβατά μεταξύ clients.

Η IID περίπτωση λειτουργεί ως καθαρό benchmark για το αν ένας security mechanism μεταβάλλει αριθμητικά το aggregation. Εάν pairwise masking και HE έχουν υλοποιηθεί σωστά, το τελικό learning curve θα πρέπει να παραμένει πολύ κοντά στο baseline, με τις κυριότερες διαφορές να εμφανίζονται στο communication και processing overhead.

2.14 non-IID δεδομένα και label skew

Το non-IID partition δημιουργείται με sorted shards. Τα samples ταξινομούνται κατά label, χωρίζονται σε num_clients × shards_per_client shards και κάθε client λαμβάνει δύο shards μετά από seeded permutation. Η διαδικασία παράγει έντονο label skew: ένας client μπορεί να δει κυρίως δύο κατηγορίες αντί για αντιπροσωπευτικό μίγμα όλων των digits.

Το αποτέλεσμα είναι client drift. Κάθε local optimizer προσαρμόζει το μοντέλο προς διαφορετική υποκατανομή, επομένως τα local updates μπορούν να αποκλίνουν περισσότερο. Η ring topology επιτρέπει τη σταδιακή διάχυση αυτής της γνώσης, αλλά με είκοσι rounds η non-IID accuracy παραμένει αισθητά

χαμηλότερη. Η διαφορά δεν αποτελεί αποτυχία του security layer· είναι χαρακτηριστικό του πιο δύσκολου learning problem.

Η ετερογένεια έχει ιδιαίτερη σημασία για την Adaptive Hybrid πολιτική, επειδή το risk score βασίζεται στο μέγεθος των selected-layer updates. Για αυτό η prototype συνάρτηση εφαρμόζει multiplier 1.2 στο non-IID split. Η επιλογή είναι heuristic και πρέπει να αντιμετωπίζεται ως σχεδιαστική παραδοχή, όχι ως θεωρητικά αποδεδειγμένος privacy factor.

Πίνακας 3 Εννοιολογική σύγκριση IID και non-IID partitions.

Χαρακτηριστικό	IID	non-IID
Κατανομή labels	Παρόμοια μεταξύ clients	Label-skewed, διαφορετική ανά client
Client drift	Συνήθως μικρότερο	Ισχυρότερο
Σύγκλιση	Ευκολότερη	Δυσκολότερη
Χρήση στην εργασία	Reference benchmark	Stress test ετερογένειας

2.15 Κλασικό Federated Learning και FedAvg

Στο κλασικό server-based FL, ο coordinator διανέμει το global model, επιλέγει clients, συλλέγει local updates και υπολογίζει νέο global model. Στο FedAvg η συνάθροιση μπορεί να είναι weighted average με βάση το πλήθος local samples [9]. Η κεντρική αρχιτεκτονική είναι απλή και πρακτική, αλλά ο server αποτελεί σημείο συγκέντρωσης εμπιστοσύνης και traffic.

Στην παρούσα εργασία δεν υπάρχει central aggregation server. Ο όρος «global test set» αφορά μόνο κοινό evaluation dataset, όχι server που συντονίζει το training. Για reporting μπορεί να υπολογιστεί virtual average όλων των client models, αλλά αυτό δεν χρησιμοποιείται για να επιβληθεί νέα κατάσταση στους clients. Η learning dynamics προκύπτει από neighbor-to-neighbor aggregation.

2.16 Decentralized Federated Learning και consensus

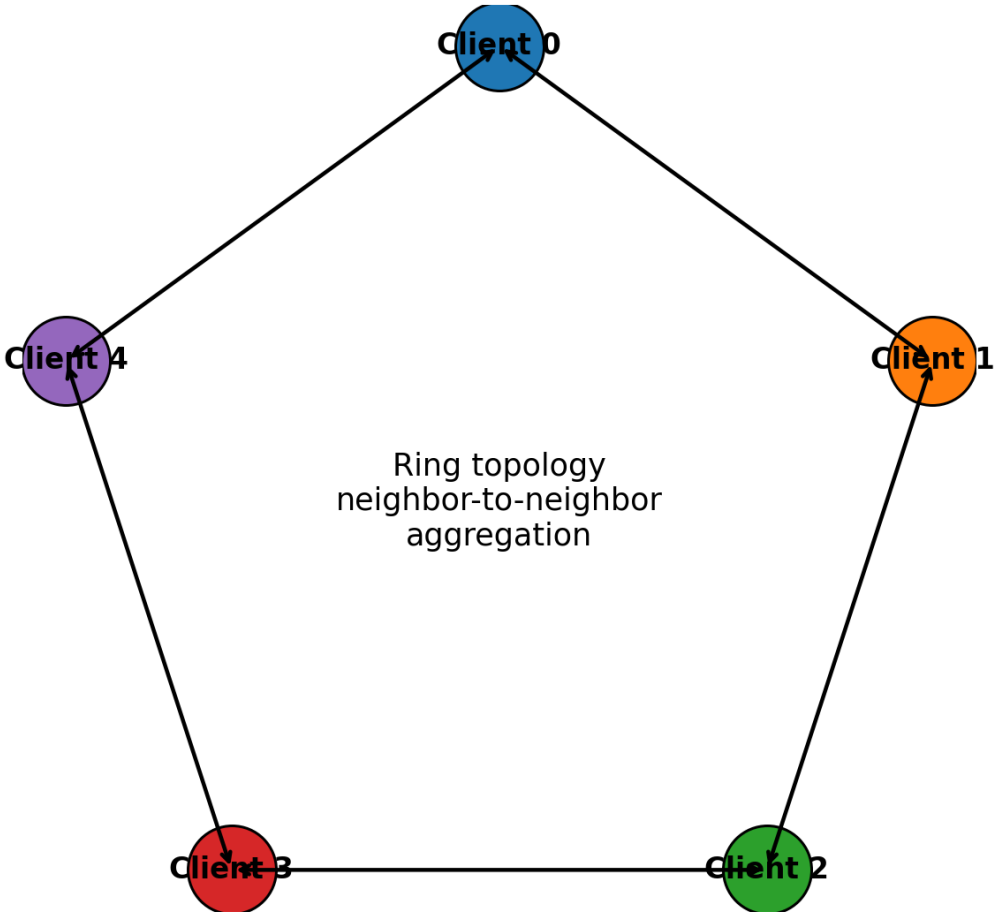
Στο DFL, το μοντέλο κάθε client ενημερώνεται από local contributors που ορίζονται από την τοπολογία. Εάν αυτή η διαδικασία επαναλαμβάνεται και το communication graph παραμένει συνδεδεμένο, η πληροφορία μπορεί να διαχυθεί σε ολόκληρο το δίκτυο. Η έννοια consensus περιγράφει την τάση των local models να γίνονται περισσότερο παρόμοια, όχι απαραίτητα απόλυτα ταυτόσημα σε κάθε χρονική στιγμή [1].

Η αποκέντρωση δημιουργεί διαφορετικές απαιτήσεις από το centralized FL. Δεν υπάρχει μοναδικός server για key management, participant selection ή provenance. Ο client πρέπει να γνωρίζει τους γείτονές του, να διαχειρίζεται contributors και να εφαρμόζει aggregation με deterministic semantics. Οι security mechanisms πρέπει επίσης να προσαρμόζονται στη neighborhood structure.

2.17 Ring topology

Η ring topology είναι ένας απλός connected graph όπου κάθε client έχει δύο γείτονες. Για πέντε clients, ο Client 0 συνδέεται με τους Clients 1 και 4, ο Client 1 με 0 και 2, και ούτω καθεξής. Κάθε target neighborhood στην υλοποίηση περιλαμβάνει τον ίδιο τον target και τους δύο γείτονές του, άρα τρεις contributors.

Το ring μειώνει τον αριθμό άμεσων links σε σχέση με fully connected topology και καθιστά ευκολότερη την παρακολούθηση του aggregation. Παράλληλα απαιτεί περισσότερα rounds για διάδοση πληροφορίας σε απομακρυσμένους peers. Η επιλογή είναι κατάλληλη για ελεγχόμενο thesis prototype, αλλά δεν παρουσιάζεται ως καθολικά βέλτιστη topology.



Σχήμα 6 Ring topology πέντε clients. Κάθε target κάνει aggregation με τον εαυτό του και τους δύο γείτονές του.

2.18 Neighborhood averaging και synchronous semantics

Το aggregation εφαρμόζεται parameter-by-parameter. Για κάθε tensor στο state_dict, οι αντίστοιχες τιμές των contributors αθροίζονται και διαιρούνται με το πλήθος τους. Δεν γίνεται «ένας μέσος όρος όλων των weights». Αντίθετα, το weight που συνδέει συγκεκριμένο input με συγκεκριμένο neuron αντιστοιχίζεται με το ίδιο weight στα άλλα model replicas.

Η υλοποίηση ακολουθεί synchronous semantics. Μετά το local training λαμβάνονται snapshots όλων των client states. Όλα τα neighborhood aggregations του round χρησιμοποιούν αυτά τα snapshots, ώστε ο Client 1 να μην εκμεταλλευτεί ήδη-updated κατάσταση του Client 0 μέσα στο ίδιο round. Μόνο αφού υπολογιστούν τα νέα states πραγματοποιείται commit στους clients. Αυτό αποτρέπει order-dependent behavior.

2.19 Communication cost ως πειραματική διάσταση

Στα distributed learning systems η accuracy δεν είναι το μοναδικό metric. Ένα security mechanism μπορεί να διατηρεί την ποιότητα του μοντέλου αλλά να διπλασιάζει ή να πολλαπλασιάζει τον όγκο δεδομένων που μεταδίδεται. Η παρούσα εργασία λογίζει τα transmitted model bytes, τα pairwise seed bytes και τα CKKS ciphertext bytes ανά round.

Το baseline communication αποτελεί τη βάση σύγκρισης. Το simple masking διπλασιάζει σχεδόν τον όγκο επειδή το prototype λογίζει ολόκληρο mask. Το pairwise masking προσθέτει μόνο seed material. Το Selective HE αυξάνει το traffic λόγω ciphertext expansion. Το Adaptive Hybrid βρίσκεται ενδιάμεσα επειδή μόνο μέρος των neighborhoods χρησιμοποιεί HE.

2.20 Αναπαραγωγιμότητα και random seeds

Η stochastic φύση του training απαιτεί έλεγχο reproducibility. Η set_seed() ρυθμίζει Python, NumPy και PyTorch seeds, ενώ σε CUDA ενεργοποιούνται deterministic cuDNN settings. Επιπλέον, οι DataLoaders χρησιμοποιούν seeded generators. Η ίδια experimental configuration μπορεί έτσι να επαναληφθεί με ελεγχόμενο random state.

Ωστόσο, reproducibility δεν σημαίνει ότι κάθε διαφορετικό seed θα παράγει ίδιο accuracy. Για αυτό η validation καμπάνια χρησιμοποιεί τρία seeds και αναφέρει mean ± standard deviation. Η μικρή variance στο IID και η αισθητά μεγαλύτερη variance στο non-IID αποτελούν χρήσιμη πληροφορία για τη σταθερότητα του συστήματος.

3. Ασφάλεια, ιδιωτικότητα και threat model στο Federated Learning

Το Σχήμα 7 εξηγεί την αλληλοακύρωση των pairwise masks και το Σχήμα 8 τη ροή επιλογής προστασίας του Adaptive Hybrid.

3.1 Model-update leakage

Η τοπική παραμονή των raw data περιορίζει την άμεση έκθεση, αλλά οι παράμετροι που μεταδίδονται είναι αποτέλεσμα optimization πάνω στα ίδια δεδομένα. Ένα update μπορεί να θεωρηθεί συμπιεσμένο στατιστικό αποτύπωμα της local training process. Η ποσότητα πληροφορίας που μπορεί να εξαχθεί εξαρτάται από το model, το batch size, το είδος του update, τον αριθμό παρατηρήσεων του adversary και τις δυνατότητες του attacker [2].

Στη διπλωματική, η απειλή αυτή αποτελεί κίνητρο για protection-in-transit/aggregation. Δεν πραγματοποιείται formal information-theoretic privacy proof. Αντίθετα, συγκρίνονται πρακτικοί μηχανισμοί που αποκρύπτουν individual values πριν ή κατά τη συνάθροιση και μετράται το λειτουργικό τους κόστος.

3.2 Membership inference

Σε membership inference attack ο adversary προσπαθεί να αποφασίσει αν ένα συγκεκριμένο sample συμμετείχε στο training set. Οι Shokri et al. [12] εξετάζουν black-box πρόσβαση στις εξόδους του μοντέλου και αξιοποιούν διαφορές στη συμπεριφορά πρόβλεψης μεταξύ training και μη training δειγμάτων. Η επιτυχία εξαρτάται από το μοντέλο, τα δεδομένα και τη διαθέσιμη πληροφορία του attacker.

Το masking και το HE μειώνουν την άμεση διαθεσιμότητα των individual updates σε τρίτους που παρατηρούν την ανταλλαγή. Αυτό όμως δεν αποτελεί από μόνο του empirical απόδειξη ανθεκτικότητας σε membership inference. Για αυτό η εργασία διατυπώνει τον μηχανισμό ως privacy-enhancing protection και αφήνει πλήρες attack benchmark για future work.

3.3 Property inference

Property inference επιδιώκει να συμπεράνει χαρακτηριστικά της τοπικής κατανομής και όχι απαραίτητα συγκεκριμένο sample. Για παράδειγμα, ένας attacker θα μπορούσε να αναζητήσει αν οι updates είναι συμβατές με dataset που περιέχει συχνότερα συγκεκριμένες classes ή visual patterns. Διαισθητικά, εντονότερες αλλαγές σε ομάδες parameters μπορούν να δημιουργούν ισχυρότερο observable signal, αν και η πραγματική επίθεση απαιτεί στατιστικό attack model και δεν ανάγεται στην παρατήρηση ενός μόνο weight.

Η Adaptive Hybrid πολιτική χρησιμοποιεί update magnitude μόνο ως heuristic allocation signal. Δεν ισχυρίζεται ότι το υψηλό update norm αποδεικνύει property leakage ή κακόβουλη συμπεριφορά. Αυτή η διάκριση αποτρέπει υπερβολικά security claims.

3.4 Gradient inversion και reconstruction

Gradient inversion attacks επιχειρούν να βρουν input data που παράγουν gradients συμβατά με αυτά που παρατηρήθηκαν. Η εργασία Deep Leakage from Gradients έδειξε ότι gradients μπορούν, υπό συγκεκριμένες συνθήκες, να επιτρέψουν εντυπωσιακή ανακατασκευή training examples [11]. Η ευκολία της ανακατασκευής εξαρτάται ιδιαίτερα από batch size, model architecture και διαθέσιμες gradients.

Η Homomorphic Encryption αντιμετωπίζει διαφορετικό επίπεδο του προβλήματος: εάν ο observer δεν βλέπει plaintext updates, δεν μπορεί να εφαρμόσει άμεσα gradient inversion πάνω στις προστατευμένες values. Παρόλα αυτά, η παρούσα εργασία δεν εκτελεί reconstruction benchmark και επομένως δεν ποσοτικοποιεί attack success rate.

3.5 Model poisoning και Byzantine συμπεριφορά

Σε model poisoning, malicious participant μπορεί να υποβάλει update σχεδιασμένο να μετακινήσει το κοινό μοντέλο προς ανεπιθύμητη κατεύθυνση. Η κρυπτογράφηση δεν λύνει αυτόματα το πρόβλημα: ένα κακόβουλο update μπορεί να κρυπτογραφηθεί απολύτως σωστά. Η αντιμετώπιση poisoning απαιτεί robust aggregation, anomaly detection, clipping, reputation ή άλλες τεχνικές.

Το prototype χρησιμοποιεί απλό average, άρα δεν πρέπει να παρουσιαστεί ως Byzantine-robust DFL. Το audit layer μπορεί να αποδείξει ποιος υπέγραψε ένα καταγεγραμμένο artifact και αν το artifact άλλαξε, αλλά δεν αποδεικνύει ότι το ίδιο το update ήταν semantically benign.

3.6 Backdoor, Sybil, collusion και dropout

Backdoor attacks στοχεύουν σε ειδικό trigger που προκαλεί ελεγχόμενη misclassification χωρίς να καταστρέφει τη γενική accuracy [13]. Sybil attacks αυξάνουν τεχνητά την επιρροή ενός adversary μέσω πολλών identities. Collusion αφορά συνεργασία μεταξύ participants για αποκάλυψη ή χειραγώγηση πληροφορίας. Client dropouts, ακόμη και όταν δεν είναι κακόβουλοι, αποτελούν ιδιαίτερη πρόκληση για pairwise masking επειδή ένα +m μπορεί να παραμείνει χωρίς το αντίστοιχο −m.

Η τρέχουσα έκδοση δεν παρέχει πλήρεις mitigations για αυτές τις κατηγορίες. Το Docker pairwise_masking απαιτεί complete contributor set, ενώ dropout-resilient secret sharing παραμένει future work. Η σαφής καταγραφή αυτών των ορίων είναι σημαντική ώστε το prototype να αξιολογείται με βάση αυτά που πράγματι υλοποιεί.

3.7 Simple additive masking

Η αφαίρεση της μάσκας ανακτά το επιδιωκόμενο model state εντός της ακρίβειας κινητής υποδιαστολής. Η αναμενόμενη μικρή αριθμητική απόκλιση ελέγχεται χωριστά από την τελική μαθησιακή accuracy. Το simple masking προϋποθέτει κατάλληλη διανομή της μάσκας και δεν τεκμηριώνει από μόνο του production secure aggregation.

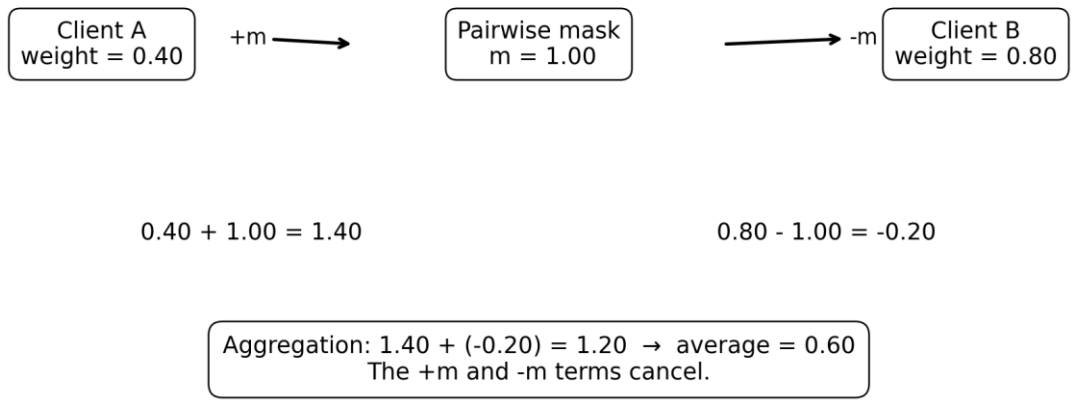
Για αυτό το simple masking χρησιμοποιείται ως ελεγχόμενο ενδιάμεσο βήμα και όχι ως τελικό secure aggregation protocol. Επιτρέπει να ελεγχθούν APIs και timing χωρίς να εισάγεται ακόμη pairwise cancellation.

3.8 Pairwise-canceling masking

Στο pairwise masking, κάθε ζεύγος contributors παράγει deterministic mask από κοινό seed. Με σταθερό convention, ο client με μικρότερο ID προσθέτει το mask και ο client με μεγαλύτερο ID το αφαιρεί. Όταν η πλήρης contributor set αθροιστεί, κάθε pairwise term εμφανίζεται μία φορά με + και μία με − και επομένως ακυρώνεται [3].

Στο παράδειγμα ring με πέντε clients, το seed material λογίζεται ως 480 bytes ανά γύρο. Η τιμή μεταβάλλεται με το contributor set και την τοπολογία. Σε όλες τις σχετικές validation διαμορφώσεις της τελικής καμπάνιας, το μέγιστο cancellation error παραμένει κάτω από 10^{-6}, με συνολικό μέγιστο $6{,}482\times10^{-7}$.

Το pairwise masking προστατεύει individual contributions μέσα στο aggregation pattern υπό τις παραδοχές του πρωτοτύπου. Δεν αποτελεί αυτομάτως λύση σε collusion ή dropout. Στην παραγωγική secure aggregation βιβλιογραφία, secret sharing και recovery protocols χρησιμοποιούνται για να διαχειριστούν clients που αποχωρούν [3].



Σχήμα 7 Απλοποιημένο παράδειγμα pairwise-canceling masking για δύο contributions.

3.9 Homomorphic Encryption και CKKS

Η Homomorphic Encryption επιτρέπει υπολογισμούς σε ciphertexts. Το CKKS σχεδιάστηκε για approximate arithmetic πραγματικών και μιγαδικών αριθμών [4]. Η approximate φύση είναι κατάλληλη για machine-learning parameters, όπου μικρά floating-point errors είναι συνήθως αποδεκτά. Στην υλοποίηση χρησιμοποιείται TenSEAL [6], poly_modulus_degree 8192, global scale 2^40 και coefficient modulus bits 60,40,40,60.

Για κάθε target neighborhood δημιουργείται CKKS context. Οι contributors λαμβάνουν public context και κρυπτογραφούν μόνο τα selected parameters. Τα encrypted vectors αθροίζονται και πολλαπλασιάζονται με 1/n ώστε να σχηματιστεί encrypted average. Η αποκρυπτογράφηση πραγματοποιείται με το target secret key. Επειδή το prototype χρησιμοποιεί μόνο addition και scalar multiplication, δεν απαιτούνται rotations ή ciphertext-ciphertext multiplications.

Η ασφάλεια και η απόδοση του CKKS εξαρτώνται από cryptographic parameters και threat assumptions. Η εργασία μετρά τη λειτουργία της συγκεκριμένης configuration, αλλά δεν επιχειρεί ανεξάρτητη formal cryptanalysis του scheme.

3.10 Selective HE

Η πλήρης κρυπτογράφηση όλων των parameters θα αύξανε δραστικά το κόστος. Για αυτό η υλοποίηση εντοπίζει το final floating-point weight και matching bias και εφαρμόζει CKKS μόνο σε αυτά. Στο MLP πρόκειται για output.weight και output.bias, δηλαδή 1.280 + 10 = 1.290 values ανά model. Τα μη επιλεγμένα tensors αθροίζονται σε plaintext.

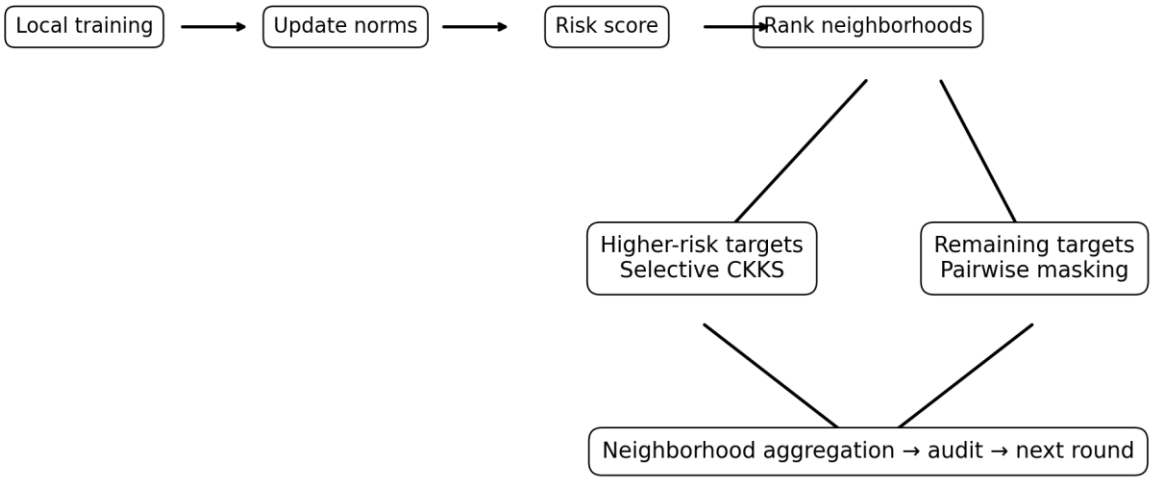
Το selective design είναι trade-off. Μειώνει το encrypted payload αλλά αφήνει μη επιλεγμένα parameters χωρίς HE. Η εργασία δεν ισχυρίζεται ότι το final layer είναι θεωρητικά το μοναδικό ευαίσθητο τμήμα. Η επιλογή είναι πρακτική και επιτρέπει σαφή μέτρηση ciphertext expansion και HE timings.

3.11 Adaptive Hybrid security

Η Adaptive Hybrid λογική επεκτείνει το Selective HE σε δεύτερη διάσταση επιλογής. Δεν αποφασίζει μόνο ποια tensors κρυπτογραφούνται, αλλά και ποια target neighborhoods θα εκτελέσουν HE σε έναν round. Για κάθε client υπολογίζεται L2 norm της μεταβολής στα selected parameters. Για κάθε target neighborhood συνδυάζεται το maximum και το mean των contributor norms.

Η default topk_risk policy ταξινομεί τα target risk scores. Με ratio 0.4 και πέντε targets επιλέγονται ceil(5×0.4)=2 neighborhoods για HE. Τα υπόλοιπα τρία χρησιμοποιούν pairwise masking. Με αυτό τον τρόπο το encrypted traffic και ο HE processing time κλιμακώνονται με το target ratio.

Η πολιτική πρέπει να ερμηνεύεται ως dynamic security-budget allocation. Υψηλό risk score δεν σημαίνει «ανιχνεύτηκε επίθεση». Σημαίνει μόνο ότι, σύμφωνα με τον επιλεγμένο heuristic, το neighborhood εμφανίζει ισχυρότερη selected-layer update activity και λαμβάνει την ακριβότερη προστασία.



Σχήμα 8 Η Adaptive Hybrid απόφαση: update norms, risk ranking και επιλογή μεταξύ Selective CKKS και pairwise masking.

3.12 Hashes, digital signatures και Merkle trees

Οι hash functions χρησιμοποιούνται για integrity, όχι confidentiality. Ένα hash λειτουργεί ως fixed-size fingerprint των input bytes. Εάν αλλάξει ακόμη και μικρό τμήμα ενός record, το νέο hash αναμένεται να διαφέρει. Η μονόδρομη ιδιότητα σημαίνει ότι δεν είναι πρακτικό να ανακτηθεί το αρχικό μήνυμα από το digest, αλλά είναι εύκολο να υπολογιστεί νέο digest για νέα δεδομένα.

Οι Ed25519 ψηφιακές υπογραφές παρέχουν authenticity και integrity [7]. Κάθε client έχει private key για signing και public key για verification. Εάν το payload αλλάξει μετά την υπογραφή, η verification αποτυγχάνει. Η υπογραφή δεν κρυπτογραφεί το μήνυμα· αποδεικνύει ότι συγκεκριμένο private key παρήγαγε τη signature για συγκεκριμένα bytes.

Τα Merkle trees συνοψίζουν πολλά leaf hashes σε ένα root [8]. Για να αποδειχθεί ότι συγκεκριμένο client model hash ανήκει στο recorded set, δεν απαιτείται να μεταφερθεί ολόκληρο το tree. Αρκεί το Merkle proof με sibling hashes κατά μήκος της διαδρομής. Η αλλαγή ενός leaf μεταβάλλει όλα τα ancestors μέχρι το root.

3.13 Privacy, integrity και auditability ως διαφορετικές ιδιότητες

Ένα συχνό εννοιολογικό λάθος είναι η συγχώνευση όλων των security goals. Το masking και το HE στοχεύουν κυρίως στο confidentiality των model values κατά την ανταλλαγή και aggregation. Τα hashes και οι signatures στοχεύουν στην integrity και authenticity. Το append-only ledger και τα Merkle proofs υποστηρίζουν traceability και efficient verification. Κανένας από αυτούς τους μηχανισμούς δεν αντικαθιστά τους υπόλοιπους.

Για παράδειγμα, ένα malicious poisoned update μπορεί να έχει έγκυρη Ed25519 signature. Η signature αποδεικνύει ποιος το υπέγραψε, όχι ότι το περιεχόμενο είναι «καλό». Αντίστροφα, ένα CKKS ciphertext μπορεί να προστατεύει την τιμή αλλά να μην παρέχει από μόνο του audit trail για το ποιος το δημιούργησε. Η layered προσέγγιση της εργασίας προσπαθεί να κρατήσει αυτές τις λειτουργίες διακριτές.

3.14 Σύντομη τοποθέτηση στη βιβλιογραφία

Η βιβλιογραφία του secure FL περιλαμβάνει πολλές οικογένειες λύσεων. Η πρακτική secure aggregation του Bonawitz et al. [3] αποτελεί βασικό σημείο αναφοράς για pairwise masking με dropout handling σε centralized setting. Το CKKS [4] και συστήματα όπως BatchCrypt [5] και TenSEAL [6] διευκολύνουν encrypted arithmetic και efficient packing. Το πεδίο DFL συνοψίζεται σε surveys όπως το [1], ενώ οι privacy και security threats αναλύονται στο [2].

Πιο πρόσφατες προσεγγίσεις συνδυάζουν decentralization, masking, HE ή selective protection. Το GAIN προτείνει decentralized privacy-preserving FL με masking, additive HE και blockchain smart contracts [14]. Το MaskCrypt εφαρμόζει selective homomorphic encryption ώστε να μειώνει overhead σε σχέση με πλήρη encryption [15]. Εργασίες auditable/verifiable DFL αξιοποιούν blockchain, monitoring και signatures για να ενισχύσουν traceability [16]. Η παρούσα διπλωματική δεν στηρίζεται σε ισχυρισμό ότι αυτές οι βασικές τεχνικές είναι νέες· εστιάζει στην ενοποίηση, μετρήσιμη σύγκριση και adaptive orchestration τους σε συγκεκριμένο prototype.

4. Σχεδιασμός συστήματος και end-to-end αρχιτεκτονική

Ο Πίνακας 4 ορίζει την κοινή πειραματική διαμόρφωση και ο Πίνακας 5 τις καταγεγραμμένες μετρικές, ώστε να συνδέεται η αρχιτεκτονική με τα παραγόμενα τεκμήρια.

4.1 Αρχές σχεδιασμού

Η αρχιτεκτονική σχεδιάστηκε με τέσσερις πρακτικές αρχές. Πρώτον, κάθε security mode πρέπει να χρησιμοποιεί το ίδιο learning model και data partition ώστε οι μετρήσεις να είναι συγκρίσιμες. Δεύτερον, το aggregation παραμένει decentralized και topology-driven. Τρίτον, το security overhead πρέπει να καταγράφεται σε χωριστές metrics, όχι να κρύβεται στον συνολικό round time. Τέταρτον, το audit subsystem δεν πρέπει να αλλάζει τα model parameters ή το aggregation αποτέλεσμα.

Οι αρχές αυτές αποτυπώνονται στη διάσπαση του repository σε model/data/client modules, aggregation/security modules, adaptive policy και ανεξάρτητα audit packages. Η modularity επιτρέπει να εκτελείται ο ίδιος experiment runner με διαφορετικό security_mode.

4.2 Κύρια experimental configuration

Πίνακας 4 Βασική configuration του experiment runner.

Ρύθμιση	**Τελική validation καμπάνια**
Datasets	MNIST, Fashion-MNIST, CIFAR-10
Clients	5 ή 10
Topology	Ring ή fully connected
Split	IID ή non-IID δύο shards ανά client
Seeds	1, 2, 3
Γύροι και epochs	20 γύροι, 1 local epoch
Batch size	32
Optimizer	SGD, learning rate 0,01
MLP	784 ή 3072 → 128 → 10
Security modes	none, masking, pairwise_masking, selective_he, adaptive_hybrid
Adaptive ratio	0,4 στα validation
Profiles	legacy ή cached_gpu, χωριστοί χρόνοι

Τα validation και sensitivity χρησιμοποιούν πλήρη MNIST, Fashion-MNIST και CIFAR-10, MLP με 128 hidden units, 20 γύρους, ένα local epoch, batch size 32 και learning rate 0,01. Τα validation μεταβάλλουν

clients, topology, split και security mode με τρία seeds. Το HTTP workflow έχει διαφορετικό μικρό training budget και αποτελεί χωριστό demo. Η συμπληρωματική σειρά προσθέτει Caveman και Barabási–Albert και κατανομές Dirichlet, με το ίδιο training budget [20], [21].

4.3 Lifecycle ενός communication round

Στην αρχή του round αποθηκεύεται snapshot της κατάστασης κάθε client. Κάθε client εκτελεί local training για μία epoch πάνω στον δικό του DataLoader. Μετά το training αποθηκεύεται νέο state και υπολογίζεται train loss. Τα before/after selected-layer states χρησιμοποιούνται για update norms και, στην Adaptive Hybrid mode, για risk scores.

Αφού ολοκληρωθεί το local training όλων των clients, δημιουργείται immutable collection previous_states για το round. Η topology ορίζει για κάθε target ποιοι contributors συμμετέχουν. Ανάλογα με το security mode εφαρμόζεται plaintext average, simple masking, pairwise masking, Selective HE ή hybrid επιλογή. Τα νέα target states υπολογίζονται χωρίς να μεταβάλλονται τα snapshots. Στο τέλος γίνεται commit στα client models, evaluation στο κοινό test set και καταγραφή metrics.

Αυτή η synchronous λογική είναι ουσιώδης για reproducibility: το αποτέλεσμα ενός target δεν εξαρτάται από το εάν το loop της Python επισκέφθηκε πρώτα τον Client 0 ή τον Client 4.

4.4 Υπολογισμός model update norm

Για τα selected parameter names, η compute_selected_update_norm υπολογίζει μία συνολική L2 norm. Για κάθε selected tensor υπολογίζεται η διαφορά after − before σε double precision, αθροίζονται τα τετράγωνα όλων των στοιχείων και στο τέλος λαμβάνεται τετραγωνική ρίζα. Έτσι κάθε client αντιπροσωπεύεται από έναν scalar update magnitude για το επιλεγμένο layer.

$$u_i = \sqrt{\sum_{p \in S} \left\| W_{i,p}^{after} - W_{i,p}^{before} \right\|_2^2}$$

Η norm δεν αποθηκεύει semantic πληροφορία για το ποια digit classes προκάλεσαν την αλλαγή. Αποτελεί συνοπτικό measure intensity. Αυτή η απλότητα είναι πλεονέκτημα για το prototype αλλά ταυτόχρονα περιορισμός: διαφορετικές update directions μπορεί να έχουν ίδια norm.

4.5 Risk score ανά neighborhood

Για target t, οι contributors είναι ο ίδιος ο target και οι γείτονές του. Από τις client update norms υπολογίζονται maximum και arithmetic mean. Το prototype χρησιμοποιεί weighted combination 70% maximum και 30% mean. Το maximum δίνει μεγαλύτερο βάρος στην εντονότερη τοπική μεταβολή, ενώ το mean αποτρέπει η απόφαση να εξαρτάται αποκλειστικά από έναν contributor.

$$R_t = m_split \cdot (0.7 \cdot max(u_i) + 0.3 \cdot mean(u_i)),\ i \in contributors(t)$$

Ο split multiplier είναι 1.0 για IID και 1.2 για non-IID. Η επιλογή 1.2 δεν προκύπτει από formal privacy theorem. Χρησιμοποιείται ως conservative adjustment ώστε τα heterogeneous experiments να παράγουν

υψηλότερο numerical risk scale. Επειδή η top-k policy βασίζεται κυρίως στην κατάταξη, ο κοινός multiplier δεν αλλάζει ποιοι targets είναι top-k μέσα στον ίδιο round· αλλά επηρεάζει την ερμηνεία των absolute risk values και policies τύπου threshold.

4.6 HE target selection policies

Η υλοποίηση υποστηρίζει topk_risk, threshold και periodic policy. Στην κύρια αξιολόγηση χρησιμοποιείται topk_risk. Ο requested target count είναι ceil(N × ratio) και εφαρμόζεται minimum target count. Με N=5 και ratio=0.4 προκύπτουν δύο HE targets. Η επιλογή deterministic sorting χρησιμοποιεί risk descending και client ID ως tie-breaker.

Η threshold policy επιλέγει targets των οποίων το risk υπερβαίνει όριο, ενώ η periodic policy ενεργοποιεί HE σε όλους κάθε n rounds. Οι δύο τελευταίες υπάρχουν ως implementation alternatives, αλλά δεν αποτελούν το επίκεντρο των κύριων result tables.

4.7 Pairwise masking ανά target neighborhood

Το pairwise masking είναι target-specific. Αυτό είναι σημαντικό επειδή ο ίδιος client μπορεί να συμμετέχει σε διαφορετικά neighborhoods. Για κάθε target, τα contributor pairs παράγουν masks με seeds που εξαρτώνται από το experiment context και τα IDs. Τα signed masks αθροίζονται πάνω στις model tensors. Η correctness verification συγκρίνει το masked aggregate με plaintext reference και καταγράφει max absolute cancellation error.

Ο communication accounting δεν χρεώνει πλήρη masks αλλά seed material. Με πέντε clients και ring neighborhoods, η συνολική μέση επιβάρυνση είναι 480 bytes/round, αμελητέα σε σχέση με τα model megabytes. Αυτή η διαφορά εξηγεί γιατί το pairwise masking μένει πολύ κοντά στο baseline communication.

4.8 Selective CKKS flow

Για target που χρησιμοποιεί HE, το final layer flatten γίνεται σε float64 vector μαζί με metadata για shapes, dtypes και element counts. Κάθε contributor κρυπτογραφεί το vector με target public context. Τα ciphertext vectors αθροίζονται και πολλαπλασιάζονται με 1/k. Ο target αποκρυπτογραφεί το averaged selected vector και το reconstruct σε tensors. Τα non-selected parameters συντίθενται με plaintext average.

Για validation υπολογίζεται επίσης plaintext selected average και max reconstruction error. Η metric επιβεβαιώνει ότι η approximate CKKS arithmetic βρίσκεται εντός αποδεκτής numerical απόκλισης για το συγκεκριμένο task. Παράλληλα, αποθηκεύονται encryption, aggregation, decryption times, ciphertext bytes και number of encrypted values.

4.9 Communication accounting

Η επικοινωνία υπολογίζεται ανά round και περιλαμβάνει only remote contributor traffic. Ο target δεν θεωρείται ότι «στέλνει στον εαυτό του» το local state. Για plaintext modes, το model state size προκύπτει

από number of elements × element_size. Για pairwise masking προστίθεται seed overhead. Για HE targets, τα selected plaintext bytes αντικαθίστανται από serialized ciphertext bytes, ενώ τα non-selected parameter bytes παραμένουν plaintext.

Το communication metric των validation προκύπτει από το serialized μέγεθος των model states και των ciphertexts και από τις κατευθυνόμενες αποστολές μεταξύ διαφορετικών clients. Δεν περιλαμβάνει πλήρες transport framing ή κόστος πραγματικού WAN. Τα HTTP demos καταγράφουν χωριστά τα πραγματικά μεταφερθέντα bytes.

4.10 Evaluation metrics

Πίνακας 5 Μετρικές που καταγράφονται από το prototype.

Κατηγορία	Metrics
Learning	train loss, test loss, final accuracy, per-client accuracy
Communication	bytes/round, MiB/round, seed overhead, ciphertext bytes
Masking	masking time, max cancellation error
HE	encryption, aggregation, decryption, total HE time, reconstruction error
Adaptive	risk scores, HE target count, actual target ratio
Audit	record count, signature checks, Merkle proofs, verification status

Ο συνολικός χρόνος γύρου και ο ειδικός χρόνος HE είναι διαφορετικές μετρικές. Το execution_profile συνοδεύει κάθε run και οι χρόνοι legacy και cached_gpu δεν συγχωνεύονται. Οι μαθησιακές μετρικές μπορούν να συνοψιστούν στην κοινή διαμόρφωση, με ρητή αναφορά στον έλεγχο της επιτάχυνσης.

4.11 Core experiment και Platform MVP

Το πρώτο επίπεδο είναι η σειριακή εκτέλεση όλων των clients στην ίδια διεργασία για validation και sensitivity. Το δεύτερο είναι τα 12 τοπικά HTTP demos με τρεις διεργασίες. Τα προγενέστερα Docker και audit demos τεκμηριώνουν επιπλέον λειτουργίες της πλατφόρμας και αναφέρονται χωριστά από την καμπάνια των 402 runs.

Η διάκριση αυτή ορίζει το εύρος κάθε συμπεράσματος: οι πλήρεις μαθησιακές συγκρίσεις προέρχονται από τις σειριακές εκτελέσεις, ενώ οι έλεγχοι HTTP εξετάζουν πραγματική τοπική ανταλλαγή μηνυμάτων. Η συμπεριφορά σε διαφορετικές φυσικές συσκευές, περιορισμένο bandwidth ή απώλειες πακέτων χρειάζεται πρόσθετη αξιολόγηση.

4.12 End-to-end pipeline

Η συνολική διαδικασία μπορεί να συνοψιστεί ως: dataset partition → local training → model snapshots → selected-layer update norms → optional adaptive risk scoring → protection mechanism ανά target → synchronous neighborhood aggregation → model commit → evaluation → audit record → next round. Κάθε στάδιο έχει σαφή είσοδο και έξοδο, ώστε η ροή να είναι ελέγξιμη και αναπαραγώγιμη.

Η αρχιτεκτονική επιτρέπει επίσης καθαρή ερμηνεία όταν παρουσιάζεται προφορικά: τα data δεν κυκλοφορούν, κυκλοφορεί model information· το local training είναι συνηθισμένο neural-network training· η αποκέντρωση αλλάζει μόνο το coordination/aggregation layer· το security layer αλλάζει τον τρόπο μετάδοσης/σύνθεσης· και το audit layer καταγράφει integrity evidence χωρίς να επηρεάζει τη μάθηση.

Η ίδια ροή ενοποιεί εκπαίδευση, προστατευμένο aggregation, καταγραφή μετρικών και προαιρετικό audit, επιτρέποντας αναπαραγωγή ανά manifest ID.

5. Πειραματική μεθοδολογία και κοινές ρυθμίσεις

Ο Πίνακας 6 συνοψίζει τις μεταβλητές και το εύρος της αρχικής αξιολόγησης.

5.1 Ερευνητικά ερωτήματα και μονάδα σύγκρισης

Η αξιολόγηση ελέγχει αν τα προστατευμένα aggregation paths διατηρούν τη μαθησιακή χρησιμότητα του baseline, ποιο κόστος εισάγουν και πώς μεταβάλλεται η συμπεριφορά με το data split, την τοπολογία και το πλήθος clients. Η μονάδα σύγκρισης είναι ένα πλήρως προσδιορισμένο run. Οι αντιστοιχίσεις κρατούν σταθερά dataset, seed, clients, topology, split και training budget. Για χρονικά μεγέθη απαιτείται επιπλέον ίδιο execution profile, περιβάλλον concurrency και execution session.

5.2 Πειραματικές μεταβλητές και μετρικές

Πίνακας 6 Σχεδιασμός της τελικής πειραματικής αξιολόγησης

Μεταβλητή	**Validation**	**Sensitivity**	**Τοπικό HTTP**
Datasets	MNIST, Fashion-MNIST, CIFAR-10	Ίδια τρία datasets	Ίδια τρία datasets
Clients και graph	5 ή 10, ring ή fully connected	5, ring	3, ring
Κατανομή	IID ή non-IID	IID ή non-IID	IID ή non-IID
Μηχανισμοί	Και οι πέντε modes	Adaptive, ratios 0,2 έως 1,0	Baseline και masking
Seeds	1, 2, 3	42	42
Budget	20 γύροι, πλήρη splits	20 γύροι, πλήρη splits	2 γύροι, 1.500/500 εικόνες
Πλήθος runs	360	30	12

Η τελική accuracy είναι ο μέσος όρος των client accuracies στο κοινό test set του run. Η τελική test loss συμπληρώνει την accuracy. Ο όγκος επικοινωνίας, ο χρόνος γύρου, ο ειδικός χρόνος HE και το cancellation error ελέγχουν λειτουργικό κόστος και αριθμητική ορθότητα. Το n των validation summaries είναι τρία ανεξάρτητα seeds ανά διαμόρφωση· τα sensitivity και HTTP demos έχουν ένα seed.

5.3 Κριτήρια ερμηνείας

Τα mean ± sample SD είναι περιγραφικές εκτιμήσεις από τρία seeds. Δεν συνιστούν έλεγχο στατιστικής ισοδυναμίας. Η διατήρηση της accuracy αφορά utility και δεν μετρά προστασία από inference, collusion ή κακόβουλους peers. Η προστασία αποτιμάται εδώ ως υλοποιημένος μηχανισμός με συγκεκριμένες προϋποθέσεις, ενώ η αποτίμηση έναντι επιθέσεων παραμένει χωριστό ερευνητικό βήμα.

6. Μηχανισμοί προστασίας στο πειραματικό πρωτότυπο

Το Σχήμα 9 παρουσιάζει τον αριθμητικό έλεγχο ακύρωσης και το Σχήμα 10 το ειδικό κόστος HE. Τα Σχήματα 11 και 12 συνδέουν το πλήθος επιλεγμένων targets με το heuristic risk score.

6.1 Baseline Decentralized Federated Learning

Στο baseline (security_mode=none) κάθε client εκπαιδεύει το τοπικό του μοντέλο και μοιράζεται απευθείας την κατάσταση με τους γείτονές του. Η νέα κατάσταση κάθε target προκύπτει από απλό μέσο όρο του ίδιου και των γειτονικών contributors. Το baseline ήταν αναγκαίο ως πειραματικός μάρτυρας: προσδιορίζει την ακρίβεια, το loss, την επικοινωνία και τον χρόνο χωρίς κρυπτογραφικό κόστος.

Στο reference παράδειγμα πέντε clients και ring, baseline model traffic είναι 3,882 MiB ανά γύρο για MNIST και Fashion-MNIST και 15,054 MiB για CIFAR-10. Οι τιμές αφορούν τις υπολογισμένες αποστολές μοντέλων στο serial workflow και εξαρτώνται από πλήθος clients και graph.

6.2 Simple Additive Masking

Το simple masking προσθέτει πλήρεις μάσκες και τις αφαιρεί πριν από το aggregation. Στις αντιστοιχισμένες validation εκτελέσεις η accuracy παραμένει πολύ κοντά στο baseline. Μικρές αποκλίσεις κινητής υποδιαστολής μπορούν να επηρεάσουν τη διαδρομή εκπαίδευσης, επομένως δεν υιοθετείται ισχυρισμός απόλυτης αριθμητικής ταυτότητας όλων των modes.

Η προσέγγιση ήταν χρήσιμη ως ενδιάμεσο βήμα επειδή απομόνωσε τις απαιτήσεις ενός masking API: παραγωγή, εφαρμογή, αφαίρεση και μέτρηση overhead. Δεν αποτελεί ολοκληρωμένο secure aggregation protocol, διότι προϋποθέτει προστατευμένο control channel για τη διάθεση του mask στον νόμιμο παραλήπτη. Επιπλέον, επειδή λογίζεται η μετάδοση πλήρους mask, η επικοινωνία στο IID διπλασιάστηκε από **3,882** σε **7,764 MiB/γύρο**.

6.3 Pairwise-Canceling Masking

Η δεύτερη έκδοση masking υλοποιεί target-specific ζεύγη masks. Για κάθε γειτονιά συνάθροισης, κάθε ζεύγος contributors παράγει ντετερμινιστικά το ίδιο mask από κοινό seed. Ο client με το μικρότερο ID το προσθέτει και ο client με το μεγαλύτερο ID το αφαιρεί. Κατά την άθροιση οι όροι αλληλοαναιρούνται, ώστε το masked average να συμπίπτει αριθμητικά με το μη προστατευμένο average.

Το μέγιστο cancellation error στην τελική καμπάνια ήταν $5{,}811\times10^{-7}$ για MNIST, $6{,}482\times10^{-7}$ για Fashion-MNIST και $6{,}431\times10^{-7}$ για CIFAR-10. Τα αποτελέσματα υποστηρίζουν την αριθμητική ορθότητα του aggregate στις δοκιμασμένες contributor sets, χωρίς να αποτελούν δοκιμή ανθεκτικότητας σε dropout.



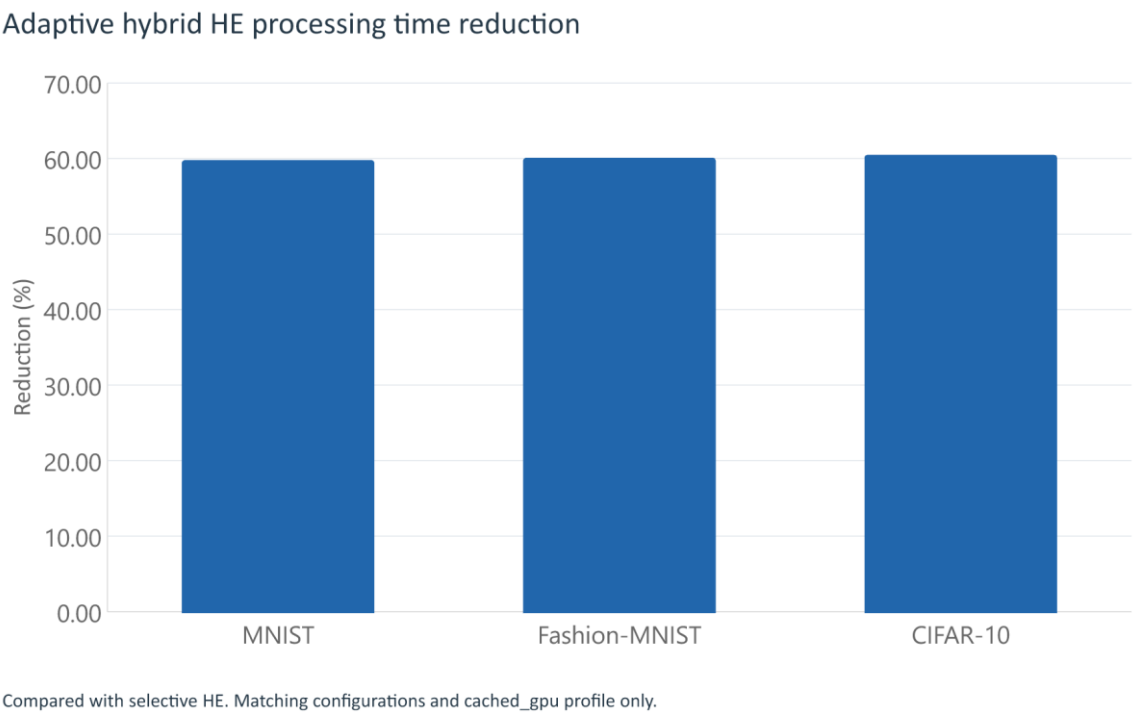
Σχήμα 9 Μέγιστο cancellation error στην τελική validation καμπάνια

Οι τιμές της τάξης 10^{-7} επιβεβαιώνουν ότι η ακύρωση είναι αριθμητικά σταθερή για τη συγκεκριμένη υλοποίηση. Δεν αποδεικνύουν κρυπτογραφική ασφάλεια· αποδεικνύουν ότι το προστατευμένο aggregation ανακατασκευάζει πρακτικά το baseline average.

6.4 Selective Homomorphic Encryption

Η CKKS εφαρμόζεται στα output.weight και output.bias, συνολικά 1.290 παραμέτρους ανά μοντέλο. Το encrypted-values counter ενός γύρου περιλαμβάνει επαναλήψεις του ίδιου layer σε διαφορετικά targets και contributors. Επομένως, ένας μεγαλύτερος αριθμός σε αυτό το counter δεν είναι η διάσταση του classifier.

Η τελική αντιστοιχισμένη σύγκριση adaptive hybrid με ratio 0,4 έναντι selective HE δείχνει μείωση του ειδικού χρόνου HE κατά 59,6% στο MNIST, 59,9% στο Fashion-MNIST και 60,3% στο CIFAR-10. Κάθε dataset έχει 22 ζεύγη με κοινά seed, clients, topology, split και execution profile cached_gpu. Τα ποσοστά είναι μέσοι όροι των επιμέρους ποσοστιαίων μειώσεων.



Σχήμα 10 Μείωση ειδικού χρόνου HE σε αντιστοιχισμένα ζεύγη cached GPU

Το Adaptive Hybrid χρησιμοποιεί HE σε λιγότερες γειτονιές και εμφανίζει χαμηλότερο μέσο κρυπτογραφικό χρόνο από το Selective HE. Η σύγκριση αφορά το καταγεγραμμένο HE processing και όχι όλο τον χρόνο γύρου.

6.5 Adaptive Hybrid Security — κύρια συνεισφορά

6.5.1 Σχεδιαστική λογική

Το Adaptive Hybrid συνδυάζει δύο επίπεδα. Όλες οι γειτονιές χρησιμοποιούν pairwise-canceling masking για τις συνεισφορές τους. Σε κάθε γύρο, ένα υποσύνολο target neighborhoods επιλέγεται επιπλέον για Selective HE στα parameters της τελικής εξόδου. Με αυτόν τον τρόπο υπάρχει μία βασική προστασία παντού και ισχυρότερη, ακριβότερη προστασία εκεί όπου το proxy risk score είναι υψηλότερο.

6.5.2 Υπολογισμός risk score

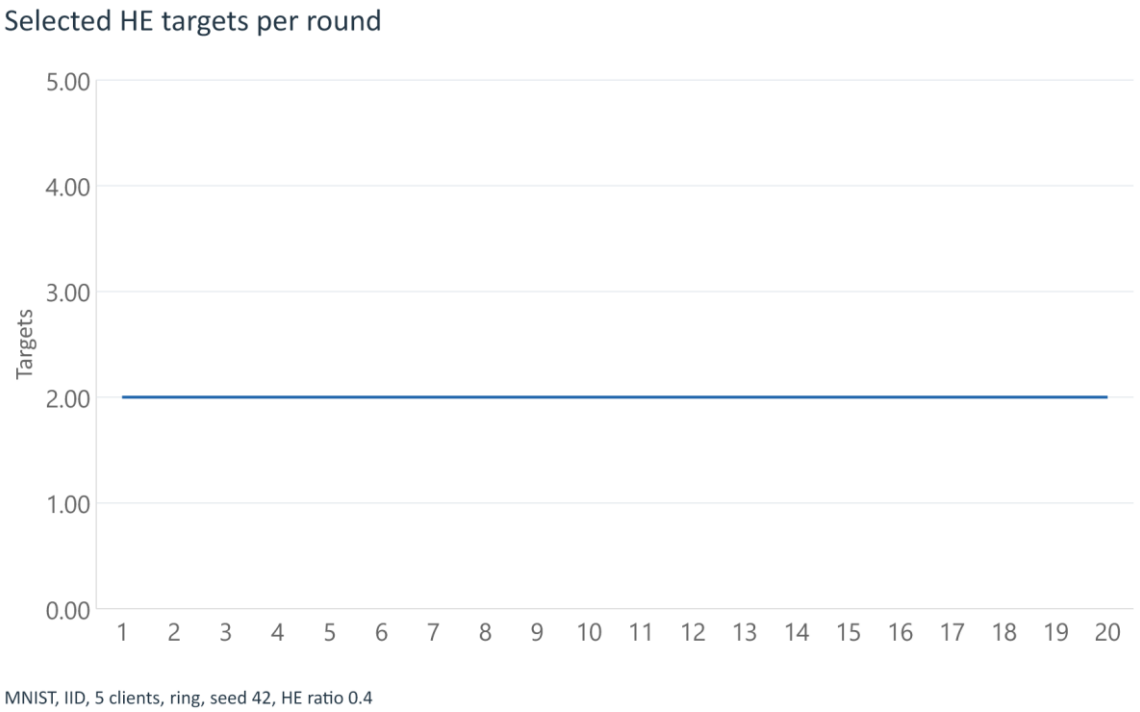
Για κάθε client υπολογίζεται η L2 νόρμα της μεταβολής στα επιλεγμένα parameters της τελικής layer. Για μία target neighborhood λαμβάνονται η μέγιστη και η μέση νόρμα των contributors. Το score ορίζεται ως:

risk(j) = split_multiplier × [0.7 × max(update_norms) + 0.3 × mean(update_norms)]

Ο multiplier είναι 1,0 για IID και 1,2 για non-IID. Το score είναι ελεγχόμενο heuristic για update sensitivity/instability και όχι πιστοποιημένη πιθανότητα επίθεσης ή formal privacy metric. Η σαφής αυτή διάκριση είναι ουσιώδης για να μην αποδοθεί στο prototype ισχυρισμός που δεν έχει αποδειχθεί.

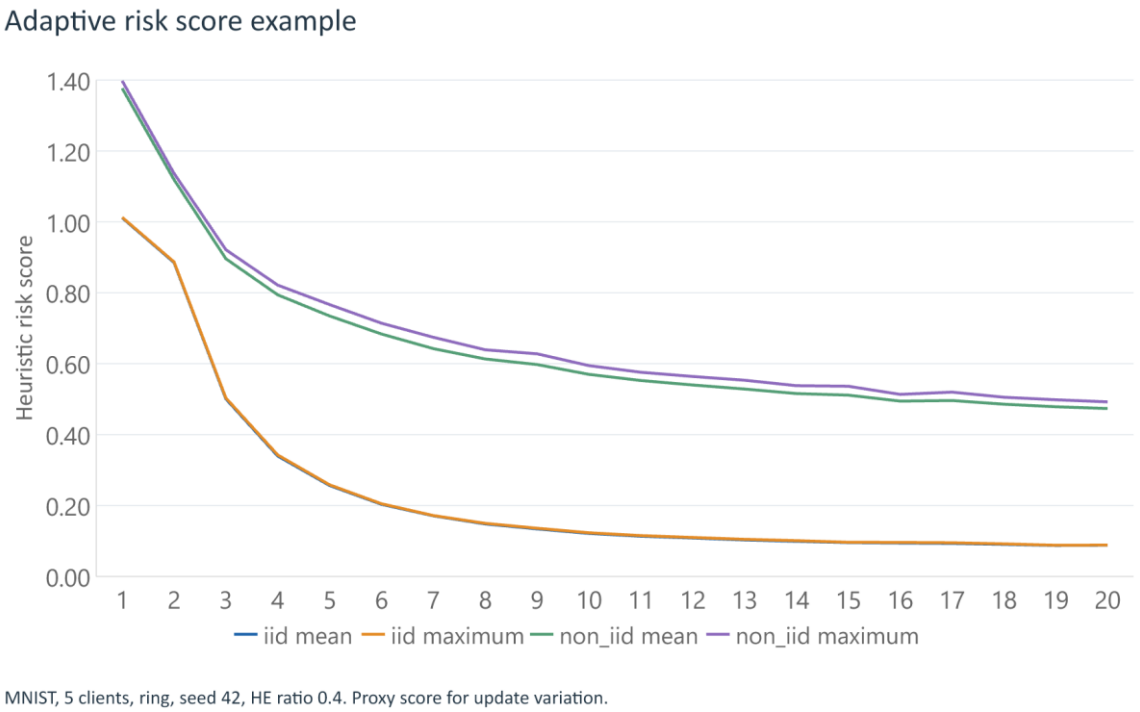
6.5.3 Πολιτική επιλογής

Η βασική πολιτική topk_risk ταξινομεί τις γειτονιές και επιλέγει ceil(num_clients × ratio) targets, με ελάχιστο πλήθος που ορίζεται από παράμετρο. Για ratio 0,4 και πέντε clients επιλέγονται δύο targets ανά γύρο. Υπάρχουν επίσης πολιτικές threshold και periodic, αλλά οι συγκρίσεις της αναφοράς χρησιμοποιούν topk_risk για συνεπή έλεγχο του ποσοστού κάλυψης.



Σχήμα 11 Επιλεγμένα HE targets στο παράδειγμα MNIST IID με ratio 0,4

Η γραμμή επιβεβαιώνει ότι η ρύθμιση 0,4 εφαρμόστηκε ως δύο από τους πέντε targets σε κάθε γύρο. Η σταθερότητα του πλήθους δεν σημαίνει σταθερή ταυτότητα στόχων: η κατάταξη επανυπολογίζεται από τα updates.



Σχήμα 12 Ενδεικτικό heuristic risk score για MNIST με seed 42

Το risk score περιγράφει τη μεταβολή του final layer και τη διασπορά των ενημερώσεων στο neighborhood. Η μεγαλύτερη τιμή δεν μετρά πιθανότητα επίθεσης. Ο κοινός non-IID multiplier αλλάζει την κλίμακα των scores, αλλά δεν αλλάζει από μόνος του την κατάταξη για σταθερή top-k πολιτική.

6.5.4 Συνεισφορά του Adaptive Hybrid στο prototype

Η συνεισφορά δεν είναι η εφεύρεση των primitives masking ή CKKS μεμονωμένα. Βρίσκεται στην ενοποιημένη, μετρήσιμη πολιτική που αποφασίζει δυναμικά πού θα δαπανηθεί το μεγαλύτερο κρυπτογραφικό κόστος, ενώ διατηρεί pairwise προστασία στο υπόλοιπο δίκτυο. Η σχεδίαση συνδέει ένα σήμα από τη συμπεριφορά της εκπαίδευσης με την κατανομή του security budget και καταγράφει σε κάθε γύρο τις συνέπειες αυτής της απόφασης.

7. Πειραματική μεθοδολογία και ακεραιότητα αποτελεσμάτων

Ο Πίνακας 7 διαχωρίζει validation, sensitivity και network demos ως προς το πλήθος εκτελέσεων και τον προϋπολογισμό εκπαίδευσης.

7.1 Σχεδιασμός της τελικής καμπάνιας

Η καμπάνια της 14ης Οκτωβρίου 2026 ολοκλήρωσε όλα τα προγραμματισμένα runs χωρίς αποτυχία. Οι 360 validation εκτελέσεις προκύπτουν από 3 datasets επί 3 seeds επί 2 πλήθη clients επί 2 τοπολογίες επί 2 splits επί 5 security modes. Τα 30 sensitivity runs προκύπτουν από 3 datasets επί 2 splits επί 5 HE ratios. Τα 12 network demos καλύπτουν 3 datasets, 2 splits και baseline ή masking.

Πίνακας 7 Σύνοψη εκτελέσεων

Σκέλος	Runs	Γύροι ανά run	Δεδομένα	Seeds
Validation	360	20	Πλήρη train και test	1, 2, 3
Sensitivity	30	20	Πλήρη train και test	42
Network	12	2	1.500 train και 500 test	42

7.2 Υπολογιστικό περιβάλλον και μετρικές

Οι εκτελέσεις έγιναν σε Windows με NVIDIA GeForce RTX 5070 Laptop GPU, PyTorch 2.11.0 με CUDA 12.8 και TenSEAL 0.3.16. Το environment.txt καταγράφει τις εκδόσεις εξαρτήσεων. Στα validation και sensitivity η εκπαίδευση και η αξιολόγηση χρησιμοποιούν CUDA, ενώ η CKKS και μέρος του orchestration εκτελούνται στην CPU. Οι clients εκτελούνται σειριακά στην ίδια διεργασία. Στη συμπληρωματική σειρά δύο workers εκτελούν ανεξάρτητα runs ταυτόχρονα, διατηρώντας σειριακούς clients μέσα σε κάθε run.

Η τελική accuracy είναι ο μέσος όρος των client accuracies στο κοινό test split, στον τελευταίο γύρο. Κάθε γραμμή αναφοράς με mean και sample standard deviation συγκεντρώνει μόνο ίδιες διαμορφώσεις και ανεξάρτητα seeds. Η επικοινωνία των validation είναι υπολογισμένος όγκος model states, masks, seed material και ciphertexts. Στα network είναι το άθροισμα πραγματικών σταλμένων και ληφθέντων bytes. Ο χρόνος γύρου περιλαμβάνει training, aggregation και global evaluation, καθώς και HTTP στα network demos.

7.3 Διακριτά προφίλ χρόνων

Τα πρώτα 27 ολοκληρωμένα runs διατηρούν το προφίλ legacy. Τα υπόλοιπα validation και sensitivity χρησιμοποιούν cached_gpu, που αποθηκεύει τα deterministic ToTensor images στη GPU και μεταφέρει συγκεντρωτικά τα scalar metrics. Οι έλεγχοι επιβεβαίωσαν ίδιες τιμές εικόνων, partitions, batches, CUDA weights, losses και accuracy στις δοκιμασμένες περιπτώσεις. Τρία πλήρη baseline runs 20 γύρων, ένα ανά dataset, συμφώνησαν ακριβώς με τις αρχικές μη χρονικές μετρικές σε όλους τους γύρους.

Η αναφορά συνδυάζει τα προφίλ μόνο για τις ελεγμένες μη χρονικές μετρικές. Οι χρόνοι legacy και cached_gpu παραμένουν χωριστοί. Η καταγραφή execution_profile σε CSV και manifest επιτρέπει έλεγχο της σύγκρισης. Οι μετρήσεις περιγράφουν το συγκεκριμένο laptop και δεν αποτελούν απομονωμένο CPU έναντι GPU benchmark. Για τη νέα σειρά διαχωρίζονται επιπλέον τα sessions και το περιβάλλον parallel_2_workers. Δεν συγχωνεύονται οι αρχικοί serial χρόνοι με τους χρόνους των δύο workers.

7.4 Ακεραιότητα των αριθμητικών αποτελεσμάτων

Κάθε completed run διαθέτει CSV με όλους τους προβλεπόμενους γύρους ακριβώς μία φορά. Η τελική accuracy και των 402 summaries διασταυρώθηκε με τον τελευταίο γύρο των αντίστοιχων raw CSV. Τα manifest.json και completion.json καταγράφουν 402 completed, 0 failed και 0 pending. Οι βασικές πηγές είναι summary.csv, grouped_summary.csv, performance_summary.csv και τα metrics_path του manifest. Οι αριθμοί προκύπτουν από τα CSV και τα σχήματα απεικονίζουν αυτές τις μετρήσεις. Για τη συμπληρωματική σειρά, το validation.json καταγράφει 228 ολοκληρωμένα runs, 76 ομάδες με n=3 και 20 γύρους ανά run. Επαληθεύτηκε ότι τα 119 προϋπάρχοντα metrics αρχεία διατήρησαν τους αρχικούς SHA-256 hashes [20], [21].

8. Συγκριτικά αποτελέσματα

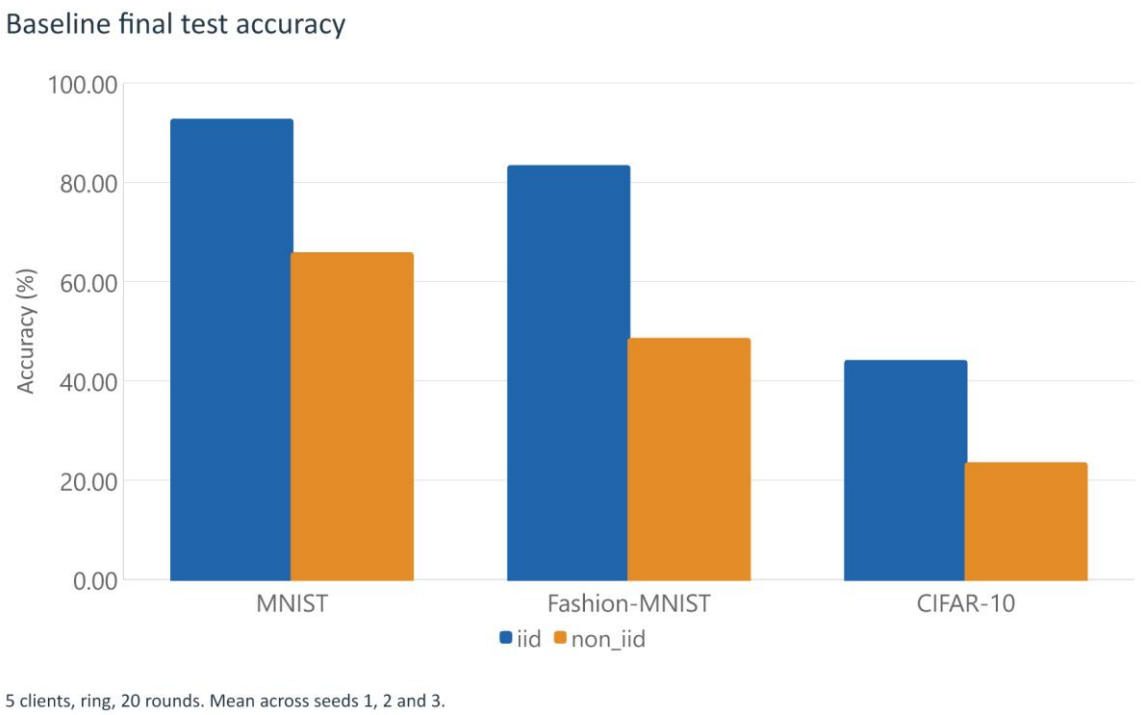
Ο Πίνακας 8 δίνει την τελική accuracy και ο Πίνακας 9 το αντίστοιχο loss. Το Σχήμα 13 συγκρίνει τα datasets και τα Σχήματα 14, 15 και 16 δείχνουν τις καμπύλες εκπαίδευσης. Το Σχήμα 17 παρουσιάζει την υπολογισμένη επικοινωνία και ο Πίνακας 10 την αντιστοιχισμένη σύγκριση κόστους HE.

8.1 Τελική accuracy σε κοινή διαμόρφωση

Ο επόμενος πίνακας χρησιμοποιεί 5 clients, ring, 20 γύρους και πλήρη datasets. Κάθε κελί περιέχει μέσο όρο και sample standard deviation σε ποσοστιαίες μονάδες από seeds 1, 2 και 3. Το n είναι 3 για κάθε κελί.

Πίνακας 8 Τελική test accuracy επί τοις εκατό

Dataset	Μέθοδος	IID mean ± SD	non-IID mean ± SD
MNIST	Baseline	92,51 ± 0,02	65,62 ± 2,10
MNIST	Simple masking	92,51 ± 0,02	65,62 ± 2,10
MNIST	Pairwise masking	92,51 ± 0,02	65,62 ± 2,10
MNIST	Selective HE	92,51 ± 0,02	65,62 ± 2,10
MNIST	Adaptive hybrid	92,51 ± 0,02	65,62 ± 2,10
Fashion-MNIST	Baseline	83,17 ± 0,04	48,37 ± 1,58
Fashion-MNIST	Simple masking	83,17 ± 0,04	48,37 ± 1,58
Fashion-MNIST	Pairwise masking	83,16 ± 0,04	48,37 ± 1,58
Fashion-MNIST	Selective HE	83,17 ± 0,03	48,37 ± 1,58
Fashion-MNIST	Adaptive hybrid	83,17 ± 0,03	48,37 ± 1,57
CIFAR-10	Baseline	43,93 ± 0,71	23,30 ± 0,74
CIFAR-10	Simple masking	43,94 ± 0,77	23,29 ± 0,78
CIFAR-10	Pairwise masking	43,97 ± 0,69	23,30 ± 0,75
CIFAR-10	Selective HE	43,92 ± 0,75	23,29 ± 0,76
CIFAR-10	Adaptive hybrid	43,95 ± 0,71	23,30 ± 0,76



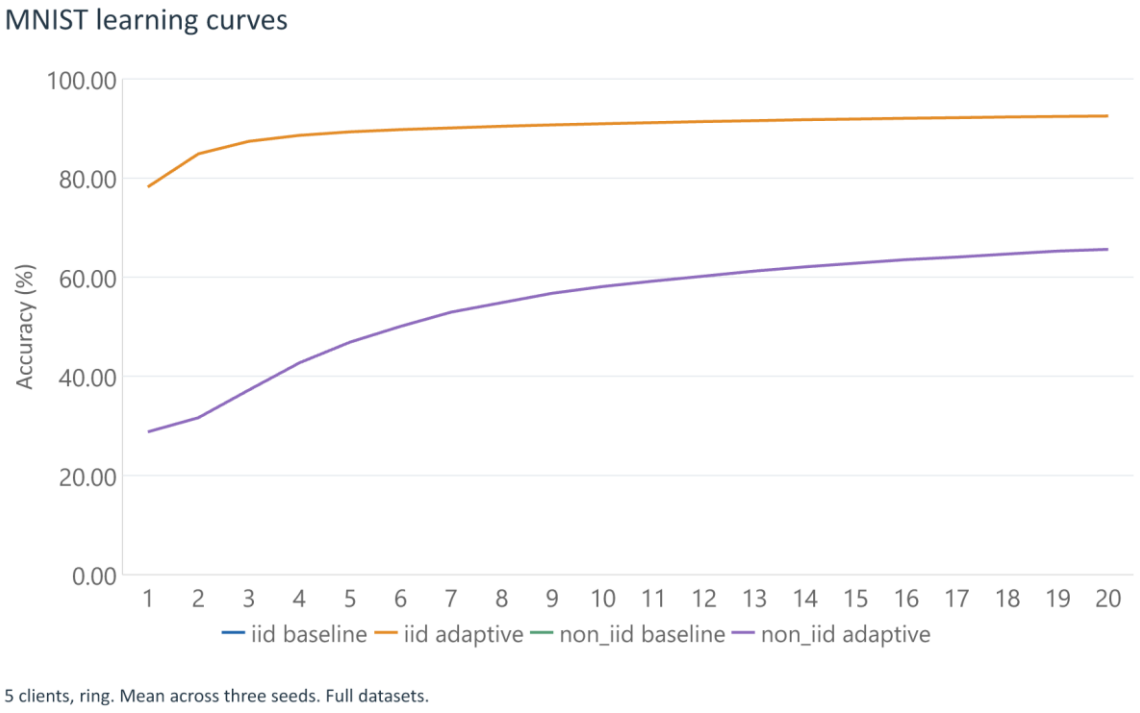
Σχήμα 13 Baseline accuracy στα τρία datasets για IID και non-IID

Στις 288 αντιστοιχισμένες συγκρίσεις των τεσσάρων protected modes με baseline, η μεγαλύτερη απόλυτη διαφορά τελικής accuracy είναι 0,23 ποσοστιαίες μονάδες. Το εύρημα υποστηρίζει μικρή μαθησιακή επίδραση των μηχανισμών στις δοκιμασμένες συνθήκες. Δεν συνιστά έλεγχο στατιστικής ισοδυναμίας ή τυπική απόδειξη ασφάλειας.

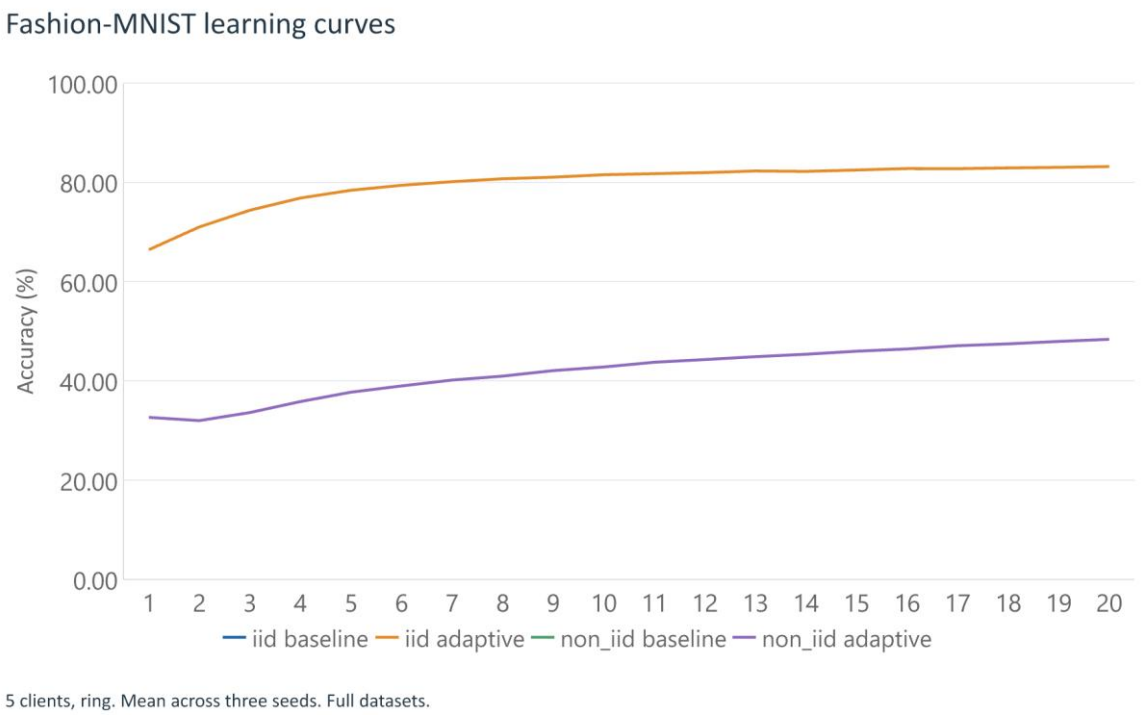
Πίνακας 9 Τελικό test loss στην ίδια διαμόρφωση

Dataset	Μέθοδος	IID mean ± SD	non-IID mean ± SD
MNIST	Baseline	0,269 ± 0,001	1,060 ± 0,048
MNIST	Simple masking	0,269 ± 0,001	1,060 ± 0,048
MNIST	Pairwise masking	0,269 ± 0,001	1,060 ± 0,048
MNIST	Selective HE	0,269 ± 0,001	1,060 ± 0,048
MNIST	Adaptive hybrid	0,269 ± 0,001	1,060 ± 0,048
Fashion-MNIST	Baseline	0,479 ± 0,001	1,934 ± 0,060
Fashion-MNIST	Simple masking	0,479 ± 0,001	1,934 ± 0,060
Fashion-MNIST	Pairwise masking	0,479 ± 0,001	1,934 ± 0,060
Fashion-MNIST	Selective HE	0,479 ± 0,001	1,934 ± 0,060
Fashion-MNIST	Adaptive hybrid	0,479 ± 0,001	1,934 ± 0,060

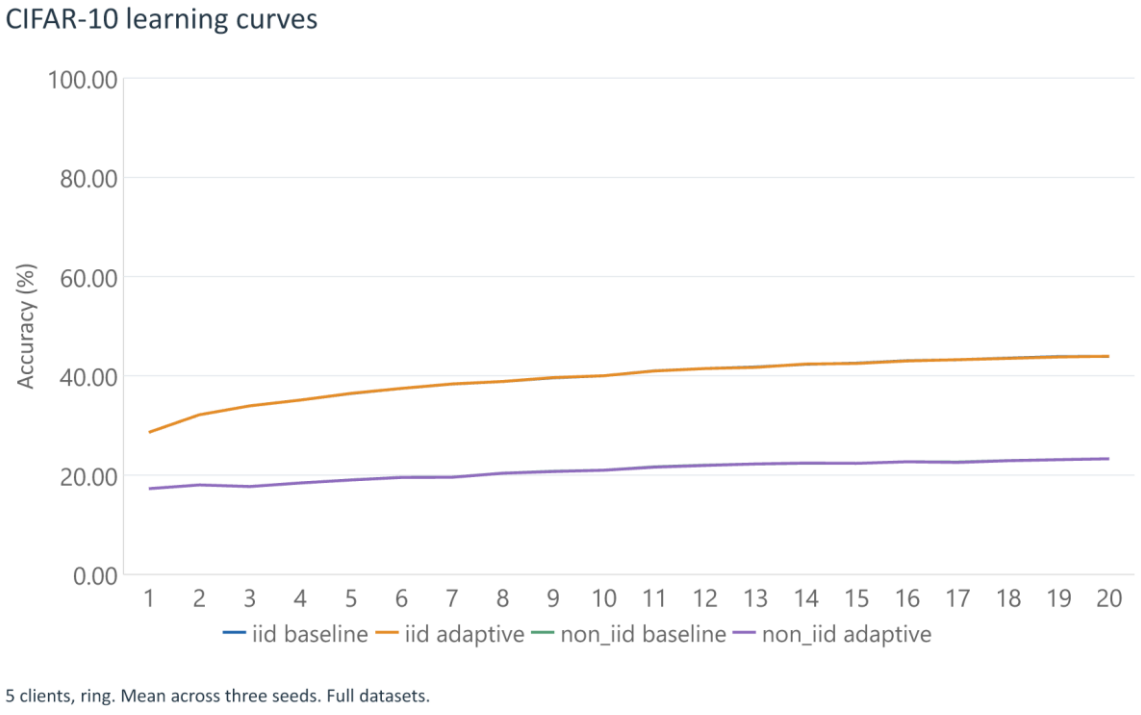
Dataset	Μέθοδος	IID mean ± SD	non-IID mean ± SD
CIFAR-10	Baseline	1,594 ± 0,012	2,825 ± 0,008
CIFAR-10	Simple masking	1,594 ± 0,013	2,825 ± 0,011
CIFAR-10	Pairwise masking	1,594 ± 0,012	2,823 ± 0,011
CIFAR-10	Selective HE	1,595 ± 0,014	2,825 ± 0,012
CIFAR-10	Adaptive hybrid	1,594 ± 0,013	2,825 ± 0,011



Σχήμα 14 Καμπύλες baseline και adaptive hybrid στο MNIST με μέση accuracy από τρία seeds

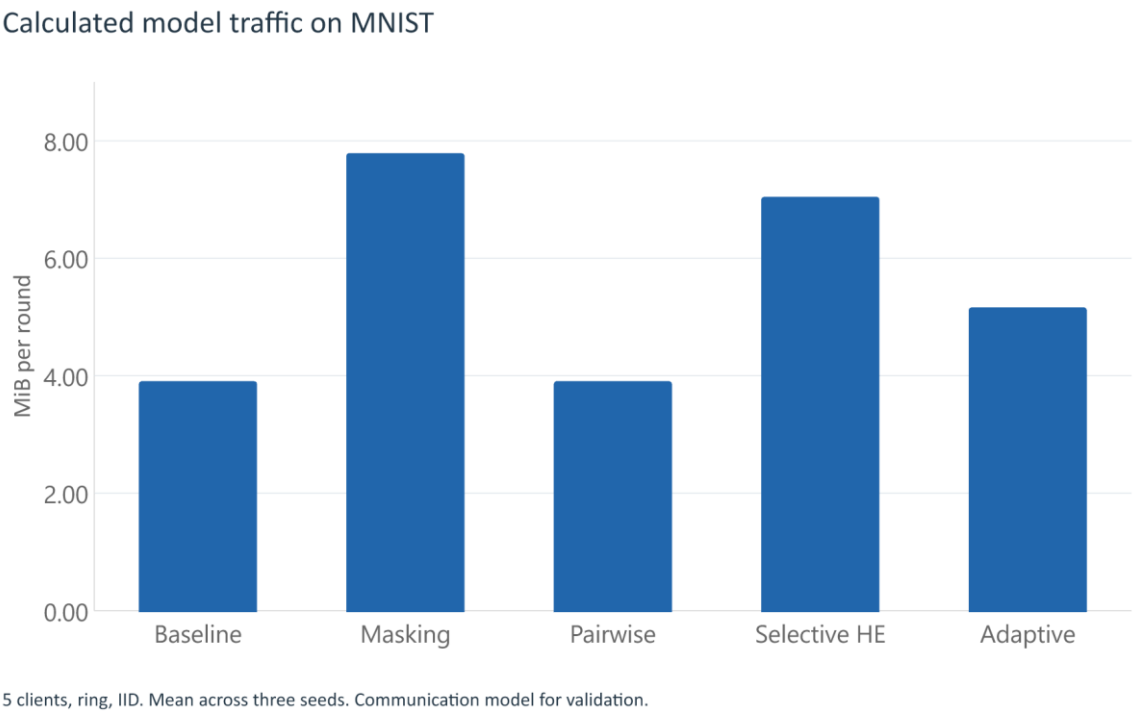


Σχήμα 15 Καμπύλες baseline και adaptive hybrid στο Fashion-MNIST με μέση accuracy από τρία seeds



Σχήμα 16 Καμπύλες baseline και adaptive hybrid στο CIFAR-10 με μέση accuracy από τρία seeds

8.2 Επικοινωνία και ειδικό κόστος HE



Σχήμα 17 Υπολογισμένη επικοινωνία στο MNIST IID με 5 clients και ring

Στο παραπάνω MNIST reference, οι μέσες τιμές είναι 3,882 MiB ανά γύρο για baseline, 7,764 για simple masking, 3,883 για pairwise masking, 7,021 για selective HE και 5,138 για adaptive hybrid. Η διπλάσια επικοινωνία του simple masking αφορά τη συγκεκριμένη λογιστική μεταφοράς πλήρους mask στη simulation. Το HTTP masking του network demo χρησιμοποιεί διαφορετικό μηχανισμό διανομής και καταγραφής, επομένως οι όγκοι των δύο workflows ερμηνεύονται ξεχωριστά.

Πίνακας 10 Adaptive hybrid ratio 0,4 σε σχέση με selective HE

Dataset	Αντιστοιχισμένα ζεύγη	Μείωση χρόνου HE %	Μείωση MiB %
CIFAR-10	22	60,3	10,3
Fashion-MNIST	22	59,9	26,8
MNIST	22	59,6	26,8

Κάθε ζεύγος του παραπάνω πίνακα έχει ίδιο seed, dataset, clients, τοπολογία και split και ανήκει στο cached_gpu. Το ποσοστό είναι μέσος όρος των επιμέρους ποσοστιαίων μειώσεων, με ίσο βάρος ανά ζεύγος. Τα 22 ζεύγη ανά dataset καλύπτουν τις επιλέξιμες διαμορφώσεις από τα 360 validation runs. Η μείωση περίπου 60% αφορά encryption, homomorphic aggregation και decryption του HE τμήματος. Ο συνολικός χρόνος γύρου περιλαμβάνει και τις υπόλοιπες εργασίες.

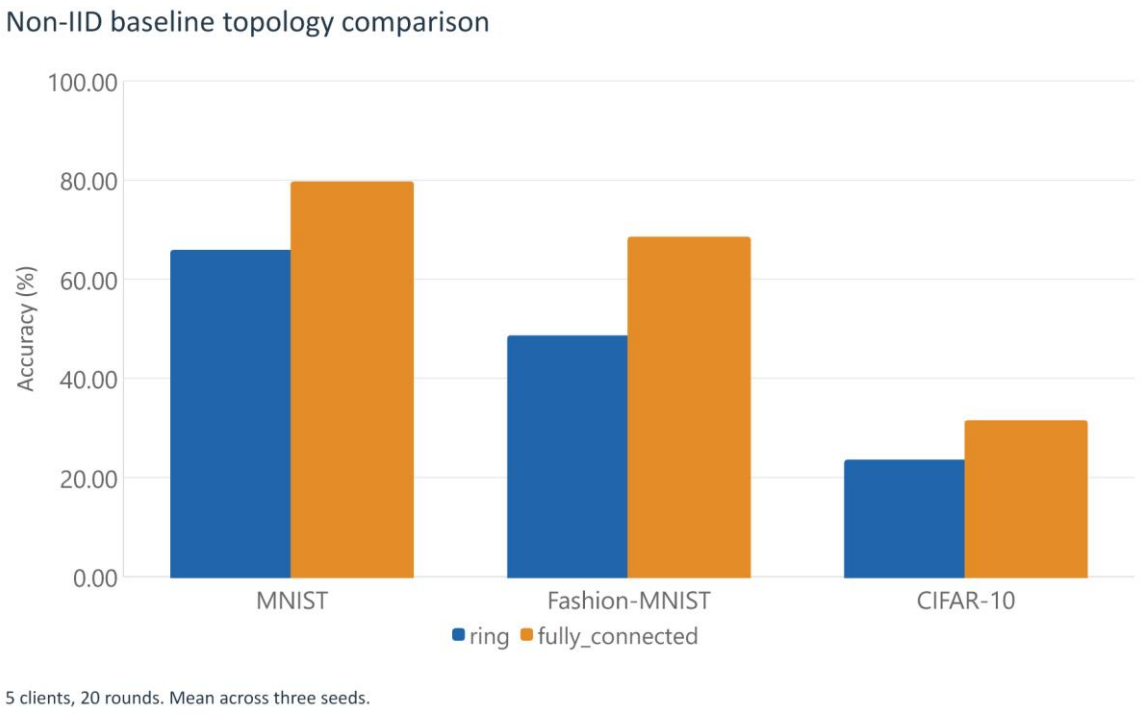
9. Ανάλυση IID έναντι non-IID

Ο Πίνακας 11 και το Σχήμα 18 συγκρίνουν τη baseline non-IID accuracy ανά τοπολογία, με ρητό διαχωρισμό του πλήθους clients.

Η non-IID κατανομή μειώνει την accuracy σε όλες τις δοκιμασμένες διαμορφώσεις. Με 5 clients και ring, το baseline πέφτει από 92,51% σε 65,62% στο MNIST, από 83,17% σε 48,37% στο Fashion-MNIST και από 43,93% σε 23,30% στο CIFAR-10. Η διαφορά αφορά το συγκεκριμένο label-skew partition με δύο shards ανά client.

Πίνακας 11 Baseline non-IID accuracy ανά τοπολογία και πλήθος clients

Dataset	Ring 5	Full 5	Ring 10	Full 10
MNIST	65,62 ± 2,10	79,44 ± 0,64	51,48 ± 6,53	81,31 ± 2,07
Fashion-MNIST	48,37 ± 1,58	68,29 ± 1,28	35,61 ± 4,11	71,42 ± 1,50
CIFAR-10	23,30 ± 0,74	31,26 ± 0,46	17,55 ± 0,67	34,09 ± 0,33



Σχήμα 18 Επίδραση της τοπολογίας στη non-IID baseline accuracy με 5 clients

Η fully connected τοπολογία αυξάνει τη μέση non-IID accuracy με 5 clients σε 79,44% για MNIST, 68,29% για Fashion-MNIST και 31,26% για CIFAR-10. Στα IID η διαφορά είναι πολύ μικρότερη. Η πυκνότερη επικοινωνία συνδέεται με καλύτερη διάδοση των ενημερώσεων στο ετερογενές partition, στο συγκεκριμένο όριο των 20 γύρων.

Το κόστος επικοινωνίας μεταβάλλεται μαζί με τη συνδεσιμότητα. Το ring έχει 2N κατευθυνόμενες μεταδόσεις ανά γύρο και το fully connected N(N−1). Για 5 clients το fully connected έχει διπλάσιες μεταδόσεις και για 10 clients 4,5 φορές περισσότερες από το ring. Η αύξηση clients αλλάζει επίσης το πλήθος local samples ανά model. Η γενίκευση του αποτελέσματος απαιτεί διαφορετικά training budgets και partitions.

Η σύγκριση πέντε και δέκα clients αναδεικνύει την αλληλεπίδραση partition και graph. Στο MNIST non-IID η ring baseline accuracy μειώνεται από 65,62% σε 51,48%, ενώ η fully connected μεταβάλλεται από 79,44% σε 81,31%. Στο Fashion-MNIST το ring μεταβάλλεται από 48,37% σε 35,61%, ενώ η πλήρης συνδεσιμότητα από 68,29% σε 71,42%. Οι μέσοι όροι αφορούν τρία seeds ανά διαμόρφωση και οι αντίστοιχες αποκλίσεις παρουσιάζονται στον πίνακα.

Στο CIFAR-10 non-IID, οι τιμές ring είναι 23,30% και 17,55% για πέντε και δέκα clients, ενώ οι fully connected είναι 31,26% και 34,09%. Η πυκνότερη επικοινωνία συνδέεται με υψηλότερη accuracy και στα δύο μεγέθη, αλλά το ίδιο MLP και το budget των 20 γύρων εξακολουθούν να περιορίζουν την απόλυτη επίδοση. Τα δεδομένα δεν καθορίζουν βέλτιστη τοπολογία για διαφορετικά μοντέλα ή όρια επικοινωνίας.

Η αλλαγή του πλήθους clients μεταβάλλει ταυτόχρονα το μέγεθος του local partition και τη διάδοση των ενημερώσεων. Επομένως, η διαφορά μεταξύ πέντε και δέκα clients δεν αποτελεί απομονωμένη μέτρηση κλιμάκωσης συστήματος. Αντίστοιχα, η βελτίωση utility από την πλήρη συνδεσιμότητα δεν αποτιμά την έκθεση πληροφοριών σε περισσότερους peers. Αυτή η διάσταση χρειάζεται χωριστό threat model και πειράματα επίθεσης.

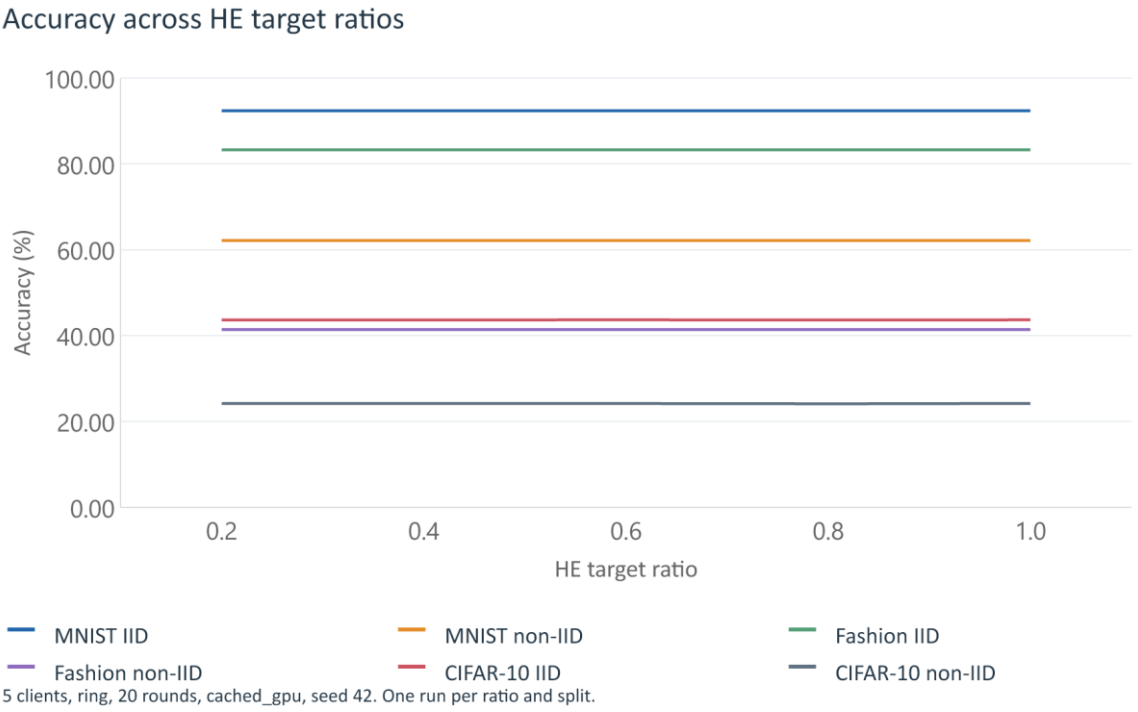
10. Ανάλυση ευαισθησίας Adaptive Hybrid

Ο Πίνακας 12 συνοψίζει το εύρος των διερευνητικών μετρήσεων. Το Σχήμα 19 δείχνει την τελική accuracy και το Σχήμα 20 τον ειδικό χρόνο HE καθώς μεταβάλλεται το target ratio.

Τα 30 sensitivity runs χρησιμοποιούν seed 42, 5 clients, ring, πλήρη datasets, 20 γύρους και HE target ratios 0,2 έως 1,0 με βήμα 0,2. Για κάθε dataset και split μεταβάλλεται μόνο το ratio. Τα δεδομένα περιγράφουν ένα διερευνητικό cost trade-off και δεν τεκμηριώνουν βέλτιστη επιλογή ratio για όλες τις συνθήκες.

Πίνακας 12 Εύρος accuracy και μεταβολή χρόνου HE στο sensitivity

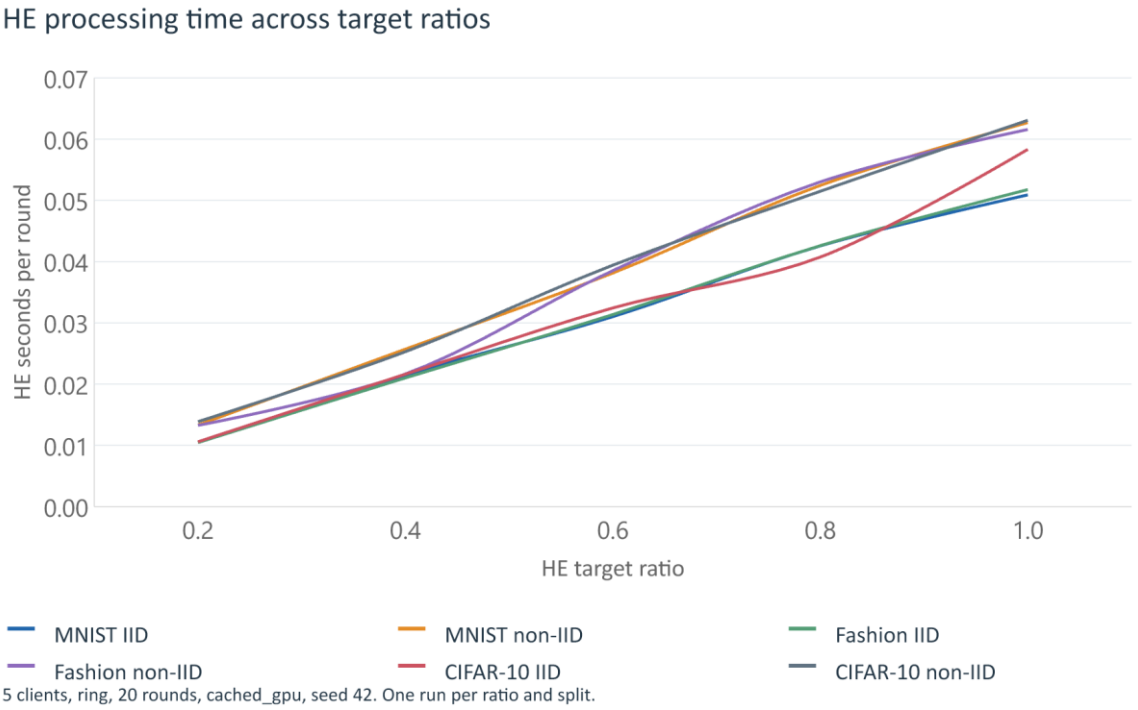
Dataset	Split	Accuracy 0,2 %	Accuracy 1,0 %	Εύρος pp	HE χρόνος 1,0 / 0,2
MNIST	iid	92,362	92,364	0,004	4,88×
Fashion-MNIST	iid	83,284	83,278	0,014	4,95×
CIFAR-10	iid	43,630	43,666	0,038	5,51×
MNIST	non_iid	62,146	62,146	0,000	4,71×
Fashion-MNIST	non_iid	41,402	41,402	0,000	4,64×
CIFAR-10	non_iid	24,190	24,204	0,084	4,55×



Σχήμα 19 Τελική accuracy ανά HE ratio με ένα seed και πλήρη datasets

Η αύξηση του ratio από 0,2 σε 1,0 αυξάνει τον ειδικό χρόνο HE κατά περίπου 4,5 έως 5,5 φορές. Το μεγαλύτερο εύρος τελικής accuracy μεταξύ ratios είναι 0,084 ποσοστιαίες μονάδες και παρατηρείται στο CIFAR-10 non-IID. Στα MNIST και Fashion-MNIST non-IID οι καταγεγραμμένες τελικές accuracies είναι ίδιες για όλα τα ratios. Η απουσία μαθησιακού κέρδους από υψηλότερο ratio δεν αποδεικνύει ίδιο επίπεδο προστασίας. Η επιλογή ratio πρέπει να συνδεθεί με μοντέλο απειλών και ελέγχους επίθεσης.

Η μεταβολή του ειδικού χρόνου HE με το ratio αποτυπώνεται επιπλέον στο ακόλουθο σχήμα. Κάθε καμπύλη αντιστοιχεί σε ένα dataset και split με seed 42. Η αύξηση του χρόνου είναι συμβατή με περισσότερα HE targets, χωρίς να τεκμηριώνει αντίστοιχο μαθησιακό ή security κέρδος.



Σχήμα 20 Ειδικός χρόνος HE ανά target ratio στα 30 sensitivity runs

11. Εκτεταμένη επικύρωση πολλαπλών seeds

Οι Πίνακες 13 και 14 διατηρούν χωριστά τους χρόνους αρχικής και γρήγορης εκτέλεσης, ενώ ο Πίνακας 15 τεκμηριώνει τα πλήρη baseline benchmarks. Ο Πίνακας 16 και το Σχήμα 21 αφορούν τα τοπικά HTTP demos. Στη συμπληρωματική σειρά, ο Πίνακας 17 ορίζει το εύρος, ο Πίνακας 18 και το Σχήμα 22 συγκρίνουν τοπολογίες, ο Πίνακας 19 και το Σχήμα 23 κατανομές CIFAR-10 και ο Πίνακας 20 με το Σχήμα 24 το ειδικό κόστος HE.

11.1 Μεταβλητότητα και χρονικές συγκρίσεις

Κάθε validation διαμόρφωση επαναλαμβάνεται με τρία seeds. Η sample SD αποτυπώνει τη διασπορά μεταξύ αυτών των επαναλήψεων. Το μικρό πλήθος seeds περιορίζει τους ισχυρισμούς στατιστικής σημαντικότητας. Οι ακόλουθοι χρόνοι παραμένουν χωριστοί ανά execution profile και αναφέρουν το n κάθε κελιού.

Πίνακας 13 Αρχική εκτέλεση χρόνοι γύρου σε s για 5 clients και ring

Dataset	Μέθοδος	IID mean ± SD	non-IID mean ± SD
MNIST	Baseline	6,18 (n=1)	6,28 (n=1)
MNIST	Simple masking	5,85 (n=1)	5,71 (n=1)
MNIST	Pairwise masking	5,97 (n=1)	5,61 (n=1)
MNIST	Selective HE	6,80 (n=1)	6,09 (n=1)
MNIST	Adaptive hybrid	6,74 (n=1)	Δεν εκτελέστηκε
Fashion-MNIST	Baseline	6,81 (n=1)	6,78 (n=1)
Fashion-MNIST	Simple masking	5,30 (n=1)	5,69 (n=1)
Fashion-MNIST	Pairwise masking	5,86 (n=1)	6,06 (n=1)
Fashion-MNIST	Selective HE	6,38 (n=1)	6,19 (n=1)
Fashion-MNIST	Adaptive hybrid	6,19 (n=1)	Δεν εκτελέστηκε
CIFAR-10	Baseline	5,74 (n=1)	6,32 (n=1)
CIFAR-10	Simple masking	6,23 (n=1)	5,88 (n=1)
CIFAR-10	Pairwise masking	6,23 (n=1)	6,39 (n=1)
CIFAR-10	Selective HE	6,80 (n=1)	6,27 (n=1)
CIFAR-10	Adaptive hybrid	5,86 (n=1)	Δεν εκτελέστηκε

Πίνακας 14 Γρήγορη εκτέλεση χρόνοι γύρου σε s για 5 clients και ring

Dataset	Μέθοδος	IID mean ± SD	non-IID mean ± SD
MNIST	Baseline	2,14 ± 0,01 (n=2)	2,09 ± 0,02 (n=2)
MNIST	Simple masking	2,12 ± 0,02 (n=2)	2,12 ± 0,04 (n=2)
MNIST	Pairwise masking	2,14 ± 0,02 (n=2)	2,14 ± 0,02 (n=2)
MNIST	Selective HE	2,19 ± 0,06 (n=2)	2,18 ± 0,05 (n=2)
MNIST	Adaptive hybrid	2,16 ± 0,01 (n=2)	2,18 ± 0,02 (n=3)
Fashion-MNIST	Baseline	2,12 ± 0,01 (n=2)	2,04 ± 0,07 (n=2)
Fashion-MNIST	Simple masking	2,14 ± 0,01 (n=2)	2,12 ± 0,02 (n=2)
Fashion-MNIST	Pairwise masking	2,14 ± 0,02 (n=2)	2,15 ± 0,00 (n=2)
Fashion-MNIST	Selective HE	2,21 ± 0,02 (n=2)	2,20 ± 0,02 (n=2)
Fashion-MNIST	Adaptive hybrid	2,15 ± 0,01 (n=2)	2,22 ± 0,05 (n=3)
CIFAR-10	Baseline	1,82 ± 0,03 (n=2)	1,83 ± 0,04 (n=2)
CIFAR-10	Simple masking	1,82 ± 0,10 (n=2)	1,85 ± 0,03 (n=2)
CIFAR-10	Pairwise masking	1,82 ± 0,07 (n=2)	1,85 ± 0,00 (n=2)
CIFAR-10	Selective HE	1,91 ± 0,03 (n=2)	1,93 ± 0,06 (n=2)
CIFAR-10	Adaptive hybrid	1,76 ± 0,01 (n=2)	1,90 ± 0,03 (n=3)

11.2 Έλεγχος της επιτάχυνσης

Πίνακας 15 Πλήρη baseline benchmarks 20 γύρων

Dataset	Αρχικός γύρος s	Cached GPU γύρος s	Λόγος χρόνων
MNIST	6,183	2,097	2,95×
Fashion-MNIST	6,806	2,116	3,22×
CIFAR-10	5,744	1,872	3,07×

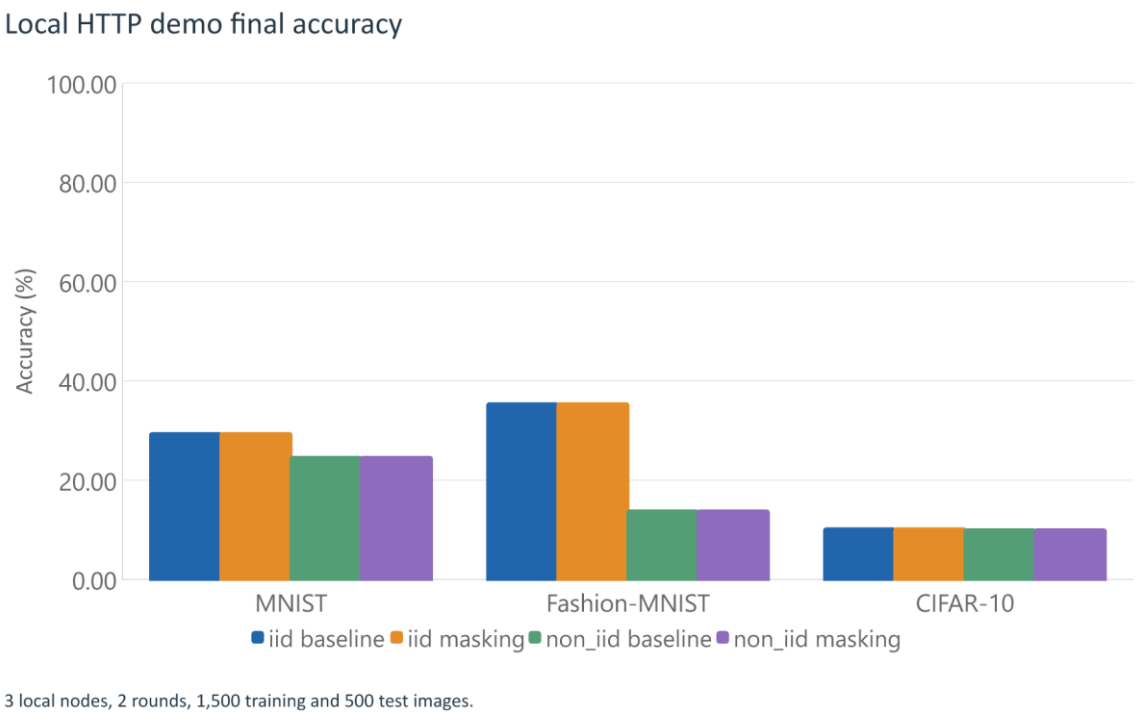
Τα τρία benchmarks συμφώνησαν ακριβώς στα μη χρονικά πεδία όλων των γύρων. Οι υπολογισμοί training διατήρησαν ίδιο model, batches, seeds, precision και optimizer. Οι μετρημένοι λόγοι χρόνων είναι περίπου 2,95 έως 3,22. Οι τιμές αφορούν τα συγκεκριμένα baseline runs και δεν εγγυώνται ίδια επιτάχυνση για όλα τα security modes ή άλλο hardware.

11.3 Τοπικά δικτυακά demos

Οι 12 network εκτελέσεις χρησιμοποίησαν 3 τοπικές διεργασίες με HTTP, 2 γύρους, 1.500 training και 500 test εικόνες, batch size 64 και learning rate 0,05. Κάθε εκτέλεση ολοκλήρωσε 6 node-round finalizations και κατέγραψε μηδενικές αποτυχημένες αποστολές. Τα σύνολα train και test και οι υπερπαράμετροι διαφέρουν από τα πλήρη validation runs.

Πίνακας 16 Αποτελέσματα network demos

Dataset	Split	Mode	Accuracy %	Γύρος s	MiB ανά γύρο
MNIST	iid	Baseline	29,40	0,838	4,310
Fashion-MNIST	iid	Baseline	35,40	0,767	4,313
CIFAR-10	iid	Baseline	10,20	1,182	16,714
MNIST	iid	Simple masking	29,40	1,197	4,310
Fashion-MNIST	iid	Simple masking	35,40	1,195	4,312
CIFAR-10	iid	Simple masking	10,20	3,058	16,713
MNIST	non_iid	Baseline	24,60	0,815	4,310
Fashion-MNIST	non_iid	Baseline	13,80	0,779	4,313
CIFAR-10	non_iid	Baseline	10,00	1,231	16,708
MNIST	non_iid	Simple masking	24,60	1,213	4,310
Fashion-MNIST	non_iid	Simple masking	13,80	1,244	4,313
CIFAR-10	non_iid	Simple masking	10,00	2,970	16,709



Σχήμα 21 Accuracy των τοπικών HTTP demos μετά από δύο γύρους

Baseline και masking δίνουν ίδια τελική accuracy σε κάθε αντιστοιχισμένο dataset και split. Ο μέσος χρόνος γύρου του masking είναι 1,4 έως 2,6 φορές ο αντίστοιχος baseline χρόνος. Το CIFAR-10 καταλήγει κοντά στο 10% σε αυτό το μικρό demo. Τα αποτελέσματα τεκμηριώνουν λειτουργική ανταλλαγή και aggregation στο localhost, με περιορισμένη αξιολόγηση μάθησης και χωρίς πραγματικό WAN ή διαφορετικές φυσικές συσκευές.

11.4 Συμπληρωματική αξιολόγηση με Dirichlet και νέες τοπολογίες

11.4.1 Σχεδιασμός και πλήθος εκτελέσεων

Η συμπληρωματική αξιολόγηση ολοκληρώθηκε στις 2 Νοεμβρίου 2026. Περιλαμβάνει 228 επιτυχείς εκτελέσεις και 76 συνδυασμούς ρυθμίσεων, με seeds 1, 2 και 3 σε κάθε συνδυασμό. Επαναχρησιμοποιήθηκαν 119 ολοκληρωμένα runs και προστέθηκαν 109. Η αρχική σειρά των 402 runs διατηρείται χωριστά· συνεπώς το σύνολο είναι 630 διακριτές εκτελέσεις. Οι 228 αποτελούν υποσύνολο του ευρύτερου σχεδιασμού 1.440 runs. Οι υπόλοιπες 1.212 εκτελέσεις αναβλήθηκαν λόγω του διαθέσιμου υπολογιστικού χρόνου [21].

Πίνακας 17 Εύρος της επιλεγμένης συμπληρωματικής σειράς

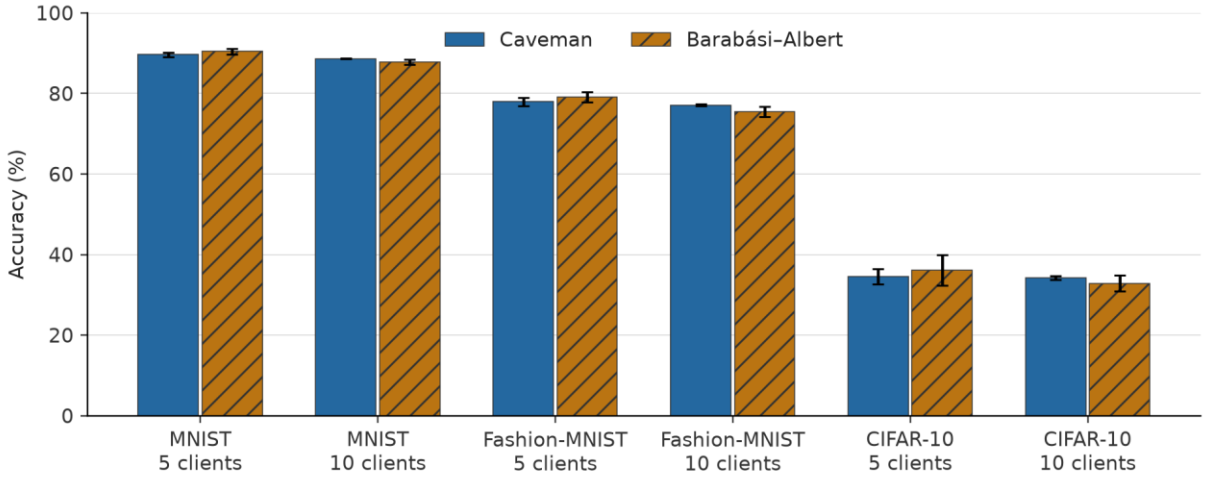
Σκέλος	Περιπτώσεις	Runs
Κύρια σύγκριση	3 datasets × 2 πλήθη clients × 2 τοπολογίες × 5 μέθοδοι × 3 seeds με Dirichlet α=0,5	180
CIFAR 10 και α	Baseline × 2 πλήθη clients × 2 τοπολογίες × α=0,1/1,0 × 3 seeds	24
CIFAR 10 και split	Baseline × 2 πλήθη clients × 2 τοπολογίες × IID/shards × 3 seeds	24

Τα MNIST και Fashion-MNIST χρησιμοποιούν 60.000 training και 10.000 test εικόνες, ενώ το CIFAR-10 50.000 training και 10.000 test εικόνες. Διατηρήθηκαν MLP 128 με ReLU, 20 communication rounds, ένα local epoch, batch size 32 και SGD learning rate 0,01. Η επιλογή περιορίζει τους συνδυασμούς ρυθμίσεων και διατηρεί ολόκληρα τα datasets. Η accuracy είναι ο μέσος όρος των client accuracies στο κοινό πλήρες test set, μετά τον 20ό γύρο.

Η Dirichlet κατανέμει τις κλάσεις στους clients με παράμετρο συγκέντρωσης α και ελάχιστο πλήθος 10 training δειγμάτων ανά client. Μικρότερο α παράγει κατά κανόνα εντονότερο label skew και μεταβάλλει τα πλήθη δειγμάτων. Η ακριβής δειγματοληψία ορίζεται στον κώδικα [21]. Η Caveman ακολουθεί τη connected-caveman κατασκευή [22], με επέκταση σε δύο ισορροπημένες κοινότητες διαφοράς το πολύ ενός κόμβου [21]. Για τη Barabási–Albert χρησιμοποιείται το NetworkX barabasi_albert_graph με preferential attachment και m=2 [23]. Τα seeds ορίζουν τις τυχαίες επιλογές partition και γράφου.

11.4.2 Baseline στις νέες τοπολογίες

Για Dirichlet α=0,5, οι δύο τοπολογίες συγκρίνονται με κοινό dataset, πλήθος clients, seed και training budget. Οι παρακάτω τιμές είναι mean ± sample SD από τρία seeds, με διαιρέτη n−1. Οι μπάρες σφάλματος δείχνουν SD μεταξύ seeds και δεν αποτελούν διαστήματα εμπιστοσύνης.



Σχήμα 22 Baseline accuracy με Dirichlet α=0,5 και 3 seeds ανά συνδυασμό με μπάρες sample SD

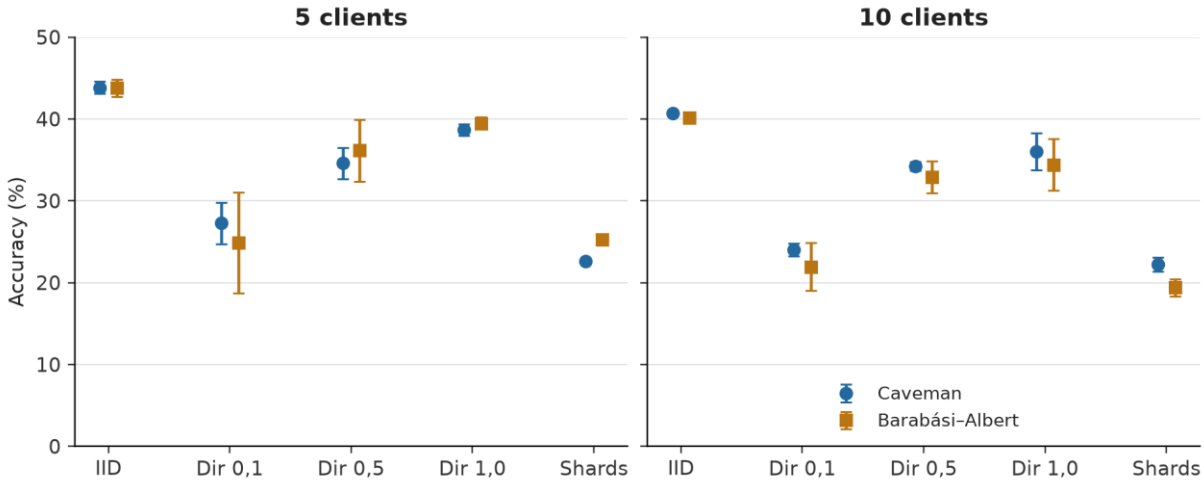
Πίνακας 18 Baseline accuracy στη συμπληρωματική σειρά με Dirichlet α=0,5

Dataset	Clients	Caveman %	Barabási–Albert %
MNIST	5	89,69 ± 0,55	90,46 ± 0,68
MNIST	10	88,67 ± 0,07	87,85 ± 0,68
Fashion-MNIST	5	77,97 ± 1,06	79,18 ± 1,25
Fashion-MNIST	10	77,14 ± 0,21	75,54 ± 1,29
CIFAR-10	5	34,60 ± 1,91	36,14 ± 3,79
CIFAR-10	10	34,24 ± 0,52	32,89 ± 1,95

Η διαφορά Barabási–Albert μείον Caveman κυμαίνεται από −1,60 έως +1,54 ποσοστιαίες μονάδες στις έξι περιπτώσεις. Η κατάταξη αλλάζει με το dataset και το πλήθος clients. Επομένως η συγκεκριμένη σύγκριση δεν υποστηρίζει γενική υπεροχή μίας τοπολογίας. Με τρία seeds και τόσο μικρούς γράφους, οι εκτιμήσεις περιορίζονται στις εξεταζόμενες ρυθμίσεις.

11.4.3 Κατανομή δεδομένων και accuracy στο CIFAR 10

Η πρόσθετη baseline σύγκριση εξετάζει IID, Dirichlet α=0,1/0,5/1,0 και non-IID με δύο shards ανά client. Οι ρυθμίσεις μοντέλου και εκπαίδευσης παραμένουν σταθερές. Έτσι αποτυπώνεται η ευαισθησία της ίδιας υλοποίησης στην κατανομή των training εικόνων.



Σχήμα 23 CIFAR-10 baseline ανά κατανομή και τοπολογία με mean και sample SD από 3 seeds

Πίνακας 19 CIFAR-10 baseline accuracy ως mean ± sample SD

Clients	Τοπολογία	IID %	Dir 0,1 %	Dir 0,5 %	Dir 1,0 %	Shards %
5	Caveman	43,85 ± 0,75	27,27 ± 2,55	34,60 ± 1,91	38,67 ± 0,70	22,60 ± 0,13
5	Barabási–Albert	43,78 ± 1,02	24,86 ± 6,17	36,14 ± 3,79	39,47 ± 0,75	25,30 ± 0,20
10	Caveman	40,68 ± 0,22	24,05 ± 0,78	34,24 ± 0,52	36,04 ± 2,25	22,24 ± 0,82
10	Barabási–Albert	40,16 ± 0,31	21,96 ± 2,94	32,89 ± 1,95	34,43 ± 3,17	19,41 ± 1,04

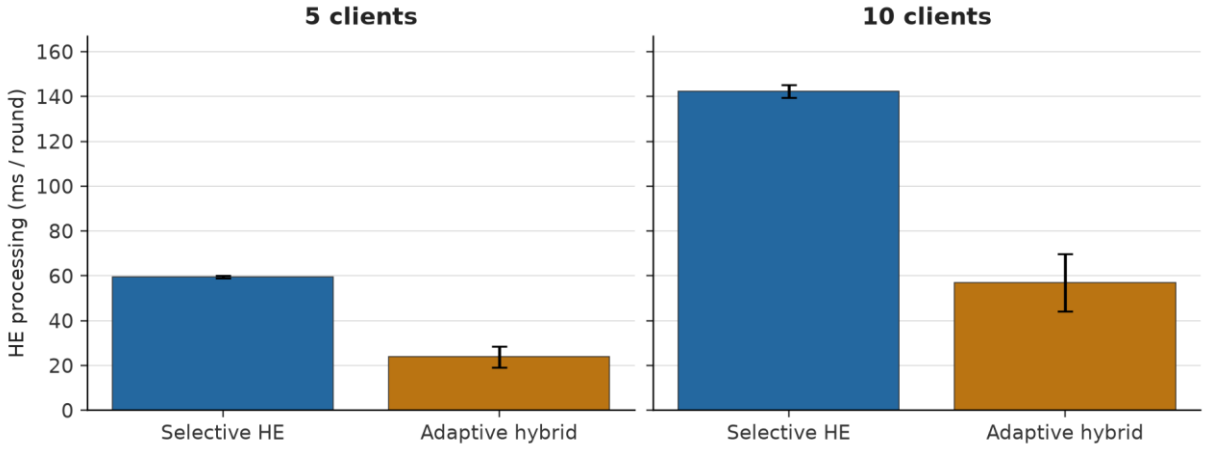
Η αύξηση του α από 0,1 σε 1,0 συνδέεται με βελτίωση 11,41 έως 14,61 ποσοστιαίων μονάδων. Η απόσταση IID από shards είναι 18,44 έως 21,25 μονάδες. Η έντονη πτώση στις πιο ετερογενείς κατανομές εμφανίζεται ήδη στο baseline και δεν μπορεί να αποδοθεί αποκλειστικά στον μηχανισμό προστασίας. Το α μεταβάλλει label skew και client sample counts, οπότε η σύγκριση δεν απομονώνει μόνο έναν τύπο ετερογένειας.

Οι απόλυτες τιμές αφορούν το συγκεκριμένο MLP και τους 20 γύρους. Για να αποδοθεί μέρος της πτώσης στην αρχιτεκτονική ή στη διάρκεια εκπαίδευσης, χρειάζεται χωριστή σύγκριση με CNN ή μεγαλύτερο training budget. Τέτοιος έλεγχος δεν περιλαμβάνεται στην παρούσα σειρά.

11.4.4 Μέθοδοι προστασίας και κόστος HE

Στα 180 runs του βασικού σκέλους α=0,5, κάθε προστατευμένη μέθοδος αντιστοιχίστηκε με baseline με ίδιο dataset, partition, seed, clients, τοπολογία και training budget. Στα 144 ζεύγη η μέγιστη απόλυτη διαφορά τελικής accuracy είναι 0,198 ποσοστιαίες μονάδες. Το εύρημα δείχνει μικρή αριθμητική επίδραση στις δοκιμασμένες περιπτώσεις και δεν αποτελεί στατιστικό έλεγχο ισοδυναμίας ή μέτρηση ιδιωτικότητας.

Η σύγκριση ειδικού χρόνου HE περιλαμβάνει 35 adaptive/selective ζεύγη με κοινό execution profile, παράλληλο περιβάλλον και session. Η μέση ποσοστιαία μείωση ανά ζεύγος είναι 58,7%. Ένα από τα 36 δυνατά ζεύγη αποκλείστηκε επειδή οι δύο μέθοδοι εκτελέστηκαν σε διαφορετικό session. Η παρακάτω απεικόνιση περιορίζεται σε CIFAR-10, Barabási–Albert και Dirichlet α=0,5, με τρία seeds ανά κελί από το session της 20ής Οκτωβρίου.



Σχήμα 24 Ειδικός χρόνος HE στο CIFAR-10 και Barabási–Albert στο ίδιο session με mean και sample SD από 3 seeds

Πίνακας 20 Χρόνος HE ανά γύρο στο συγκεκριμένο παράδειγμα

Clients	Selective HE s	Adaptive hybrid s	Μείωση από μέσους
5	0,0595 ± 0,0007	0,0239 ± 0,0046	59,9%
10	0,1423 ± 0,0028	0,0569 ± 0,0128	60,0%

Η τελευταία στήλη είναι ο λόγος των δύο μέσων χρόνων στο συγκεκριμένο παράδειγμα και διαφέρει ως υπολογισμός από τον μέσο όρο ποσοστιαίων μειώσεων στα 35 ζεύγη. Το όφελος αφορά αποκλειστικά την επεξεργασία HE. Δεν εκφράζει ίδια μείωση στον συνολικό χρόνο training και δεν τεκμηριώνει ισοδύναμο επίπεδο προστασίας. Το adaptive HE target ratio παραμένει 0,4.

11.4.5 Χρονικά περιβάλλοντα και όρια ερμηνείας

Τα 109 νέα runs ολοκληρώθηκαν σε περίπου 42,7 λεπτά με δύο persistent workers στο ίδιο laptop. Αυτός είναι ο συνολικός χρόνος της συγκεκριμένης συνεδρίας, η οποία επαναχρησιμοποίησε 119 αποτελέσματα. Δεν είναι χρόνος εκτέλεσης και των 228 runs από την αρχή. Οι clients κάθε run εκπαιδεύονται σειριακά. Η ταυτόχρονη εκτέλεση διαφορετικών runs μοιράζεται CPU και GPU και οι χρόνοι δεν αποτελούν απομονωμένο benchmark latency.

Οι χρόνοι legacy και cached_gpu της αρχικής σειράς, καθώς και τα sessions της 20ής Οκτωβρίου και της 2ας Νοεμβρίου με δύο workers, παρουσιάζονται χωριστά. Στο Fashion-MNIST με 10 clients και Caveman, μία ομάδα selective HE περιλαμβάνει δύο seeds από το πρώτο session και ένα από το δεύτερο. Η accuracy συνοψίζεται σε n=3, ενώ οι χρόνοι διατηρούν το πραγματικό n=2 ή n=1 ανά session. Δεν υπολογίζεται ενιαίος χρονικός μέσος όρος για αυτή την ομάδα.

Η συμπληρωματική σειρά καλύπτει όλες τις πέντε μεθόδους μόνο για Dirichlet α=0,5 στις δύο νέες τοπολογίες. Οι πρόσθετες συγκρίσεις α=0,1/1,0, IID και shards αφορούν μόνο CIFAR-10 baseline. Δεν προκύπτουν συμπεράσματα για όλους τους συνδυασμούς των 1.440 runs. Το μικρό πλήθος seeds, τα μικρά δίκτυα 5/10 clients και το σταθερό MLP περιορίζουν τη γενίκευση. Οι υπόλοιποι συνδυασμοί και η αξιολόγηση μεγαλύτερων μοντέλων παραμένουν μελλοντική εργασία.

Τα αποτελέσματα υποστηρίζουν τρία συγκεκριμένα συμπεράσματα: μικρή μεταβολή accuracy από τις μεθόδους προστασίας στις αντιστοιχισμένες περιπτώσεις, αισθητή επίδραση της κατανομής δεδομένων στο CIFAR-10 και μείωση του ειδικού κόστους HE με adaptive επιλογή. Η υπεροχή τοπολογίας, η στατιστική ισοδυναμία και η ανθεκτικότητα έναντι επιθέσεων απαιτούν πρόσθετη τεκμηρίωση.

12. Lightweight Blockchain Audit Layer

Οι Πίνακες 21, 22 και 23 περιγράφουν τη δομή και την επαλήθευση του χωριστού audit demo. Τα Σχήματα 25, 26, 27 και 28 παρουσιάζουν τις καταγεγραμμένες μετρικές ανά γύρο, το Σχήμα 29 τα hash prefixes και το Σχήμα 30 τη συνολική κατάσταση επαλήθευσης.

Οι έλεγχοι του παρόντος κεφαλαίου είναι προγενέστερα audit demos και δεν προσμετρώνται στα 402 runs της τελικής καμπάνιας. Οι καταγεγραμμένες υπογραφές, Merkle proofs και δοκιμές αλλοίωσης τεκμηριώνουν τα συγκεκριμένα audit artifacts.

Το lightweight blockchain προστέθηκε ως προαιρετικό επίπεδο ακεραιότητας και ιχνηλασιμότητας. Δεν συμμετέχει στο aggregation, δεν αποθηκεύει τα model tensors και δεν αντικαθιστά τους μηχανισμούς privacy. Ο ρόλος του είναι να δημιουργεί ένα επαληθεύσιμο ιστορικό των communication rounds.

12.1 Δομή και περιεχόμενο block

Πίνακας 21 Βασικά πεδία του lightweight blockchain block.

Πεδίο	Ρόλος
round / timestamp	Χρονική και λογική ταυτότητα του block
previous_hash / hash	SHA256 σύνδεση με το προηγούμενο block
model_hashes	Hashes των client model states, όχι model parameters
client_signatures	Deterministic SHA256-based simulated signatures
security metadata	security_mode, clients, topology, split, adaptive policy
round metrics	accuracy, loss, communication και generation time
verification_status	VALID ή συγκεκριμένη κατηγορία αποτυχίας

Κάθε client διαθέτει deterministic simulated private/public key identity. Η υπογραφή υπολογίζεται με SHA256 πάνω στα client_id, round και model_hash και αποθηκεύεται μαζί με public_key_id. Η επιλογή είναι σκόπιμα εκπαιδευτική: επιτρέπει διάκριση INVALID_SIGNATURE από INVALID_HASH_CHAIN, αλλά δεν παρουσιάζεται ως πραγματική ασύμμετρη κρυπτογραφική υπογραφή.

12.2 Export, επαναφόρτωση και επαλήθευση

Η αλυσίδα εξάγεται σε JSON και CSV. Μετά το export, το JSON επαναφορτώνεται, ανακατασκευάζεται η αλυσίδα και επαναλαμβάνεται ο πλήρης έλεγχος. Έτσι δεν αρκεί να είναι έγκυρο το in-memory object: ελέγχεται ότι και το αποθηκευμένο artifact μπορεί να επαληθευτεί ανεξάρτητα.

Πίνακας 22 Αποτελέσματα επαλήθευσης του blockchain_polish_3r.

Έλεγχος	Αποτέλεσμα
Experiment	blockchain_polish_3r
Blocks	4: genesis + 3 round blocks
In-memory verification	VALID
Reloaded export verification	VALID
Genesis	OK
Hash continuity	OK
Simulated signatures	OK
Broken blocks	None

12.3 Round-level αποτελέσματα

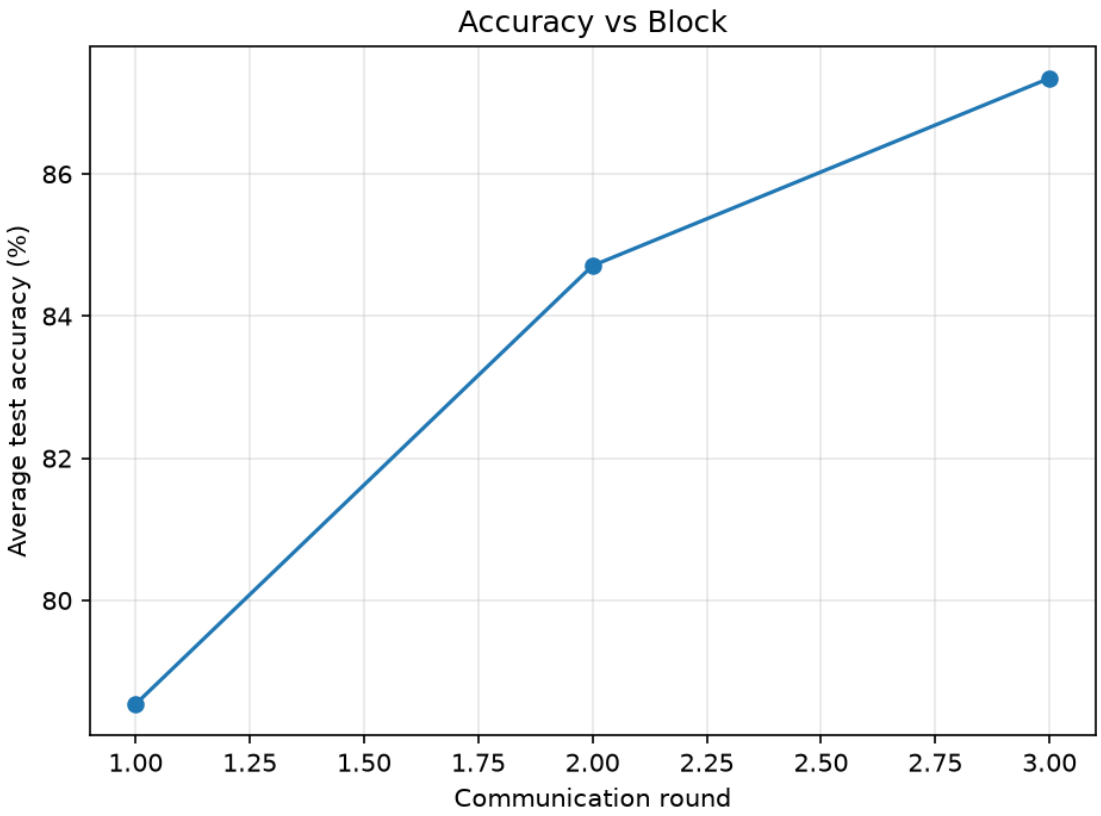
Πίνακας 23 Περιεχόμενο και κατάσταση των τεσσάρων blocks.

Block	Round	Accuracy %	Loss	Comm. bytes	Gen. s	Status
0	0	0,00	0,000	0	0,022966	VALID
1	1	78,54	1,212	5388365	0,000874	VALID
2	2	84,71	0,684	5388067	0,000712	VALID
3	3	87,35	0,522	5387903	0,000776	VALID

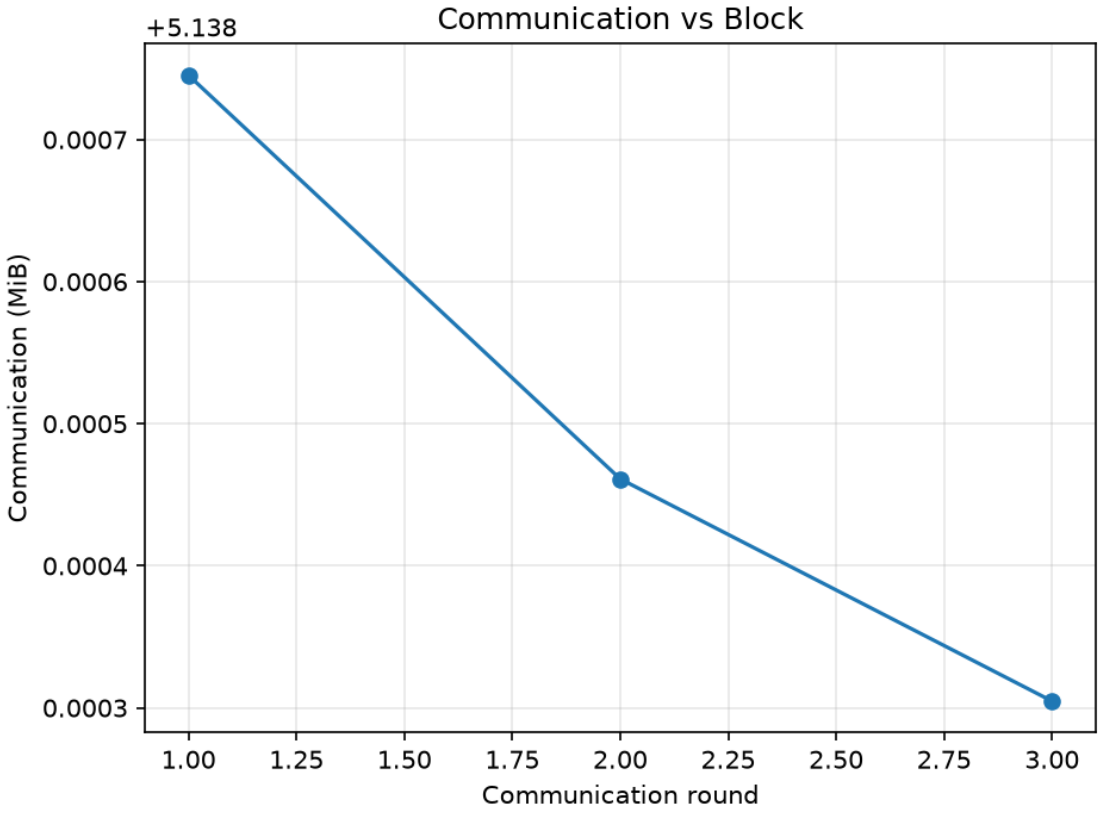
Το αποθηκευμένο statistics report καταγράφει μέσο block size 2.020,75 bytes, μέσο hash length 64 χαρακτήρες και συνολικό generation time 0,025328 s. Το μεγαλύτερο μέρος του χρόνου αφορά το genesis/configuration block, ενώ τα round blocks δημιουργούνται σε λιγότερο από ένα millisecond.

12.4 Threat model και περιορισμοί

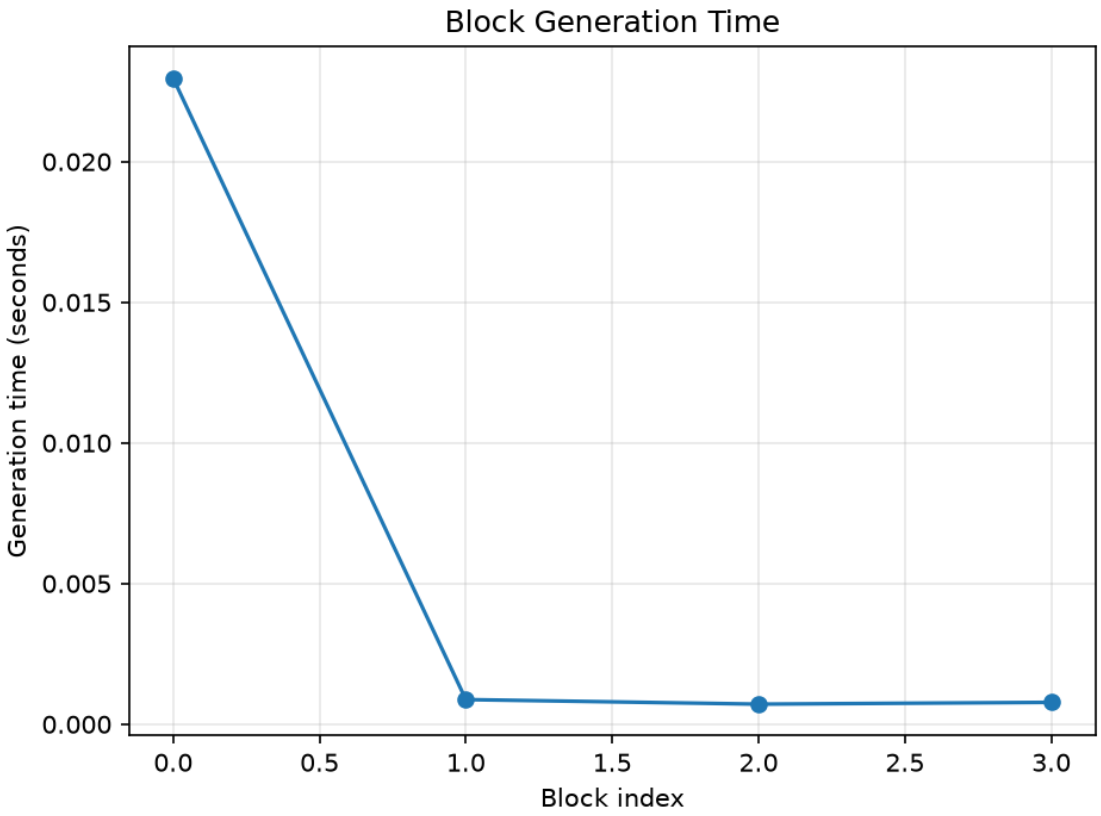
Το layer εντοπίζει μεταβολές σε exported records, model hashes, previous hashes και simulated signatures. Δεν προστατεύει από πλήρως compromised host που μπορεί να αναδημιουργήσει ολόκληρη την αλυσίδα και δεν υλοποιεί consensus, peer-to-peer replication, wallets, mining ή smart contracts. Επομένως ο σωστός όρος είναι lightweight educational blockchain audit layer και όχι production blockchain.



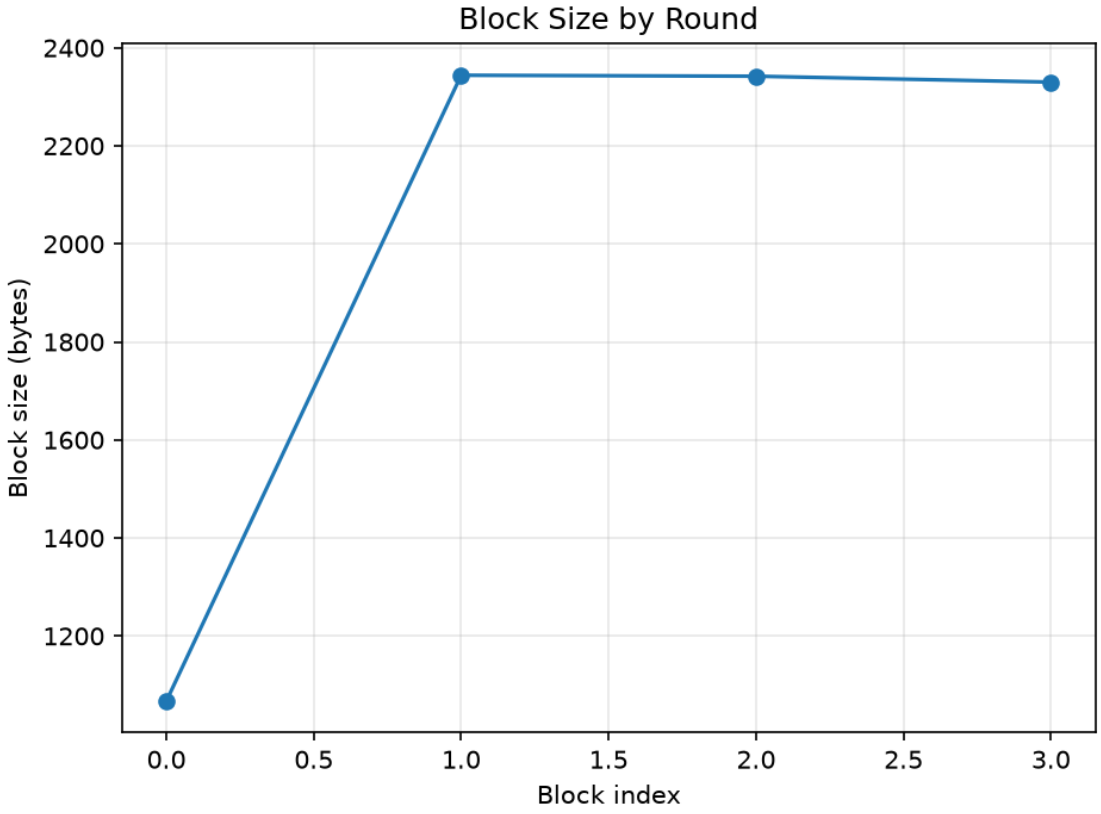
Σχήμα 25 Accuracy που καταγράφηκε ανά blockchain round.



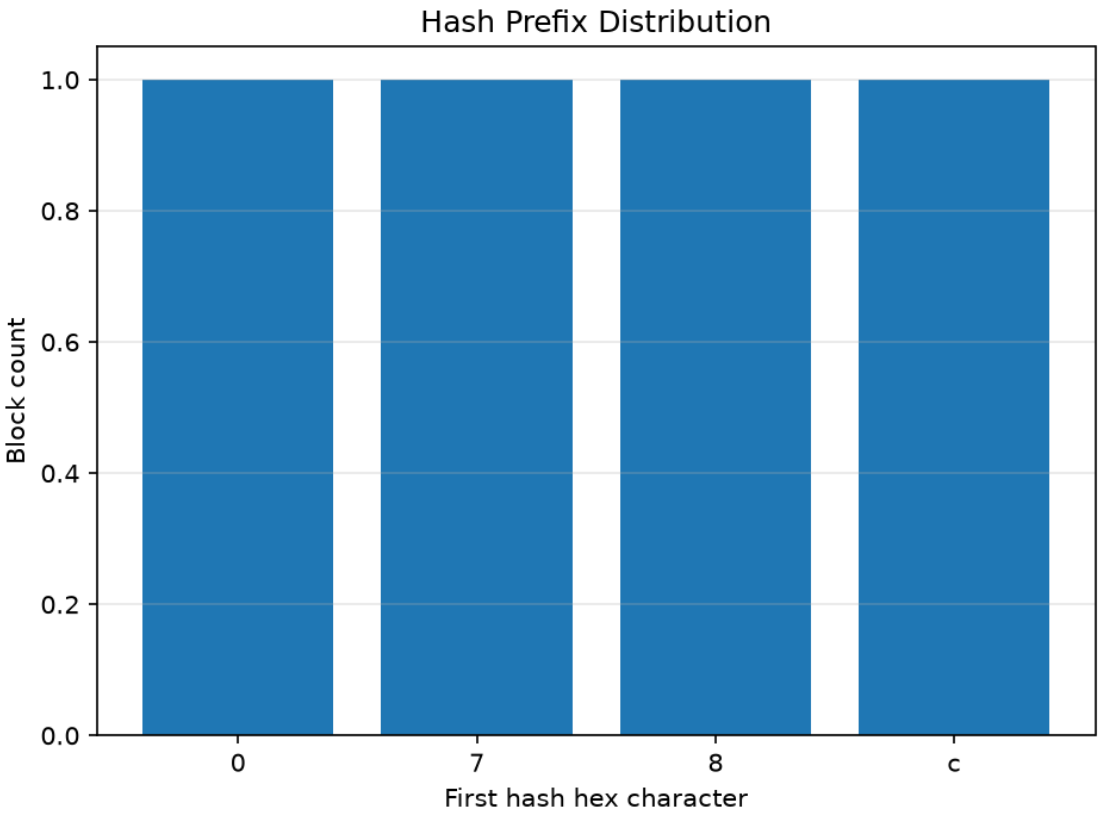
Σχήμα 26 Communication bytes ανά blockchain round.



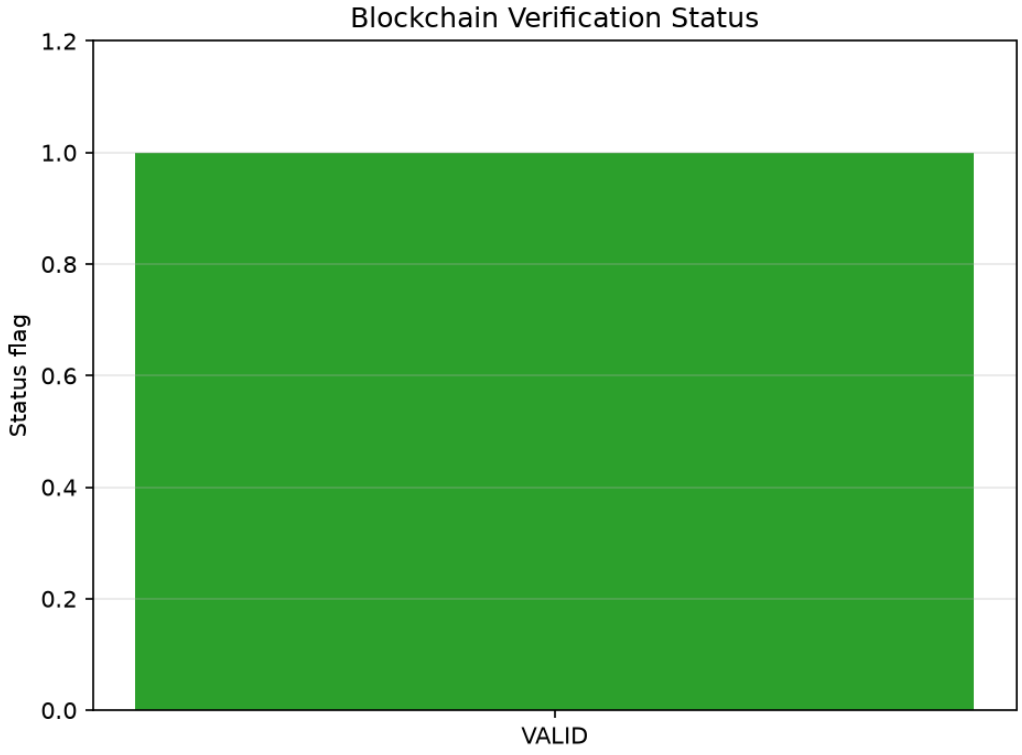
Σχήμα 27 Χρόνος δημιουργίας block.



Σχήμα 28 Μέγεθος block ανά round.



Σχήμα 29 Κατανομή των hash prefixes.



Σχήμα 30 Συνολική κατάσταση blockchain verification.

13. Advanced Audit Layer με Ed25519 και Merkle proofs

Οι Πίνακες 24 και 25 ορίζουν modules και όρια του audit package. Οι Πίνακες 26, 27 και 28 καταγράφουν τη δοκιμή και τα tampering αποτελέσματα. Τα Σχήματα 31, 32, 33, 34 και 35 απεικονίζουν τις μετρικές του audited experiment και ο Πίνακας 29 συγκρίνει τα δύο επίπεδα ακεραιότητας.

Οι έλεγχοι του παρόντος κεφαλαίου είναι προγενέστερα audit demos και δεν προσμετρώνται στα 402 runs της τελικής καμπάνιας. Οι καταγεγραμμένες υπογραφές, Merkle proofs και δοκιμές αλλοίωσης τεκμηριώνουν τα συγκεκριμένα audit artifacts.

Το Advanced Audit Layer υλοποιήθηκε για να ξεπεράσει τους σκόπιμους περιορισμούς του simulated blockchain. Παραμένει ανεξάρτητο από το training pipeline, αλλά χρησιμοποιεί πραγματικές Ed25519 ψηφιακές υπογραφές, public-key manifest, Merkle tree και append-only JSONL ledger.

13.1 Αρχιτεκτονική και modules

Πίνακας 24 Modules του Advanced Audit Layer.

Module	Ρόλος
src/audit/signing.py	Deterministic Ed25519 key pairs, payload signing και verification
src/audit/merkle.py	Merkle root, tree construction και proof verification
src/audit/ledger.py	Experiment start/end και round records σε append-only JSONL
src/audit/verifier.py	Hash chain, signatures, Merkle proofs και configuration checks
src/audit/reporting.py	Summary CSV, statistics, verification report και plots
src/audit_cli.py	verify, report, inspect-round και tamper-demo commands

13.2 Υπογεγραμμένο payload και Merkle structure

Σε κάθε γύρο, κάθε client υπογράφει κανονικοποιημένο payload που συνδέει client_id, round_number, model_hash και security_mode. Το public_key_id συνδέει την υπογραφή με το exported public key manifest. Τα πέντε client model hashes μετατρέπονται σε Merkle leaves και συμπυκνώνονται σε ένα Merkle root. Για κάθε client αποθηκεύεται proof που επιτρέπει ανεξάρτητο membership verification.

Πίνακας 25 Όρια και περιεχόμενο του audit package.

Κατηγορία	Περιεχόμενο
Αποθηκεύεται	Client model hashes, signatures, Merkle root/proofs, metrics, metadata
Δεν αποθηκεύεται	Model parameters, private keys, raw MNIST data, training batches
Προστατεύεται	Ακεραιότητα και μεταγενέστερη ιχνηλασιμότητα των audit artifacts

Κατηγορία	Περιεχόμενο
Δεν προστατεύεται	Privacy model updates ή ορθότητα του ίδιου του training computation

13.3 Πραγματικό experiment thesis_audit_demo_3r

Πίνακας 26 Συνοπτικά στοιχεία του Advanced Audit demo.

Μετρική	Τιμή
Security mode	adaptive_hybrid
Topology / split	ring / IID
Clients / rounds	5 / 3
Audit records	5: experiment_start, 3 rounds, experiment_end
Checked Ed25519 signatures	15
Checked Merkle proofs	15
Final accuracy	87,35%
Verification status	VALID
Broken record	None

Πίνακας 27 Round-level audit summary.

Round	Accuracy %	Loss	Comm. bytes	Signatures	Status
1	78,54	1,2116	5387888	5	VALID
2	84,71	0,6837	5387909	5	VALID
3	87,35	0,5224	5387645	5	VALID

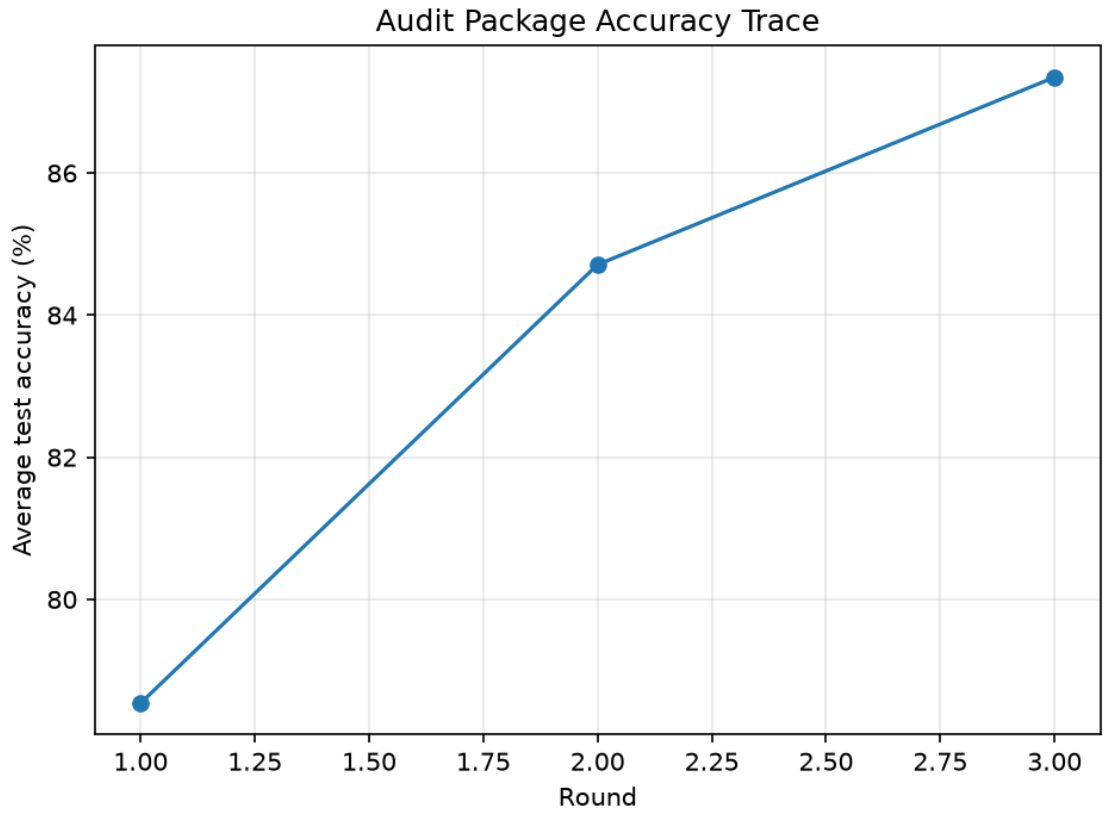
Το package είχε μέσο record size 2.850,40 bytes, average hash length 64 χαρακτήρες και συνολικό audit generation time 0,004862 s. Και οι 15 υπογραφές και τα 15 Merkle proofs επαληθεύτηκαν επιτυχώς μετά το export.

13.4 Tamper detection

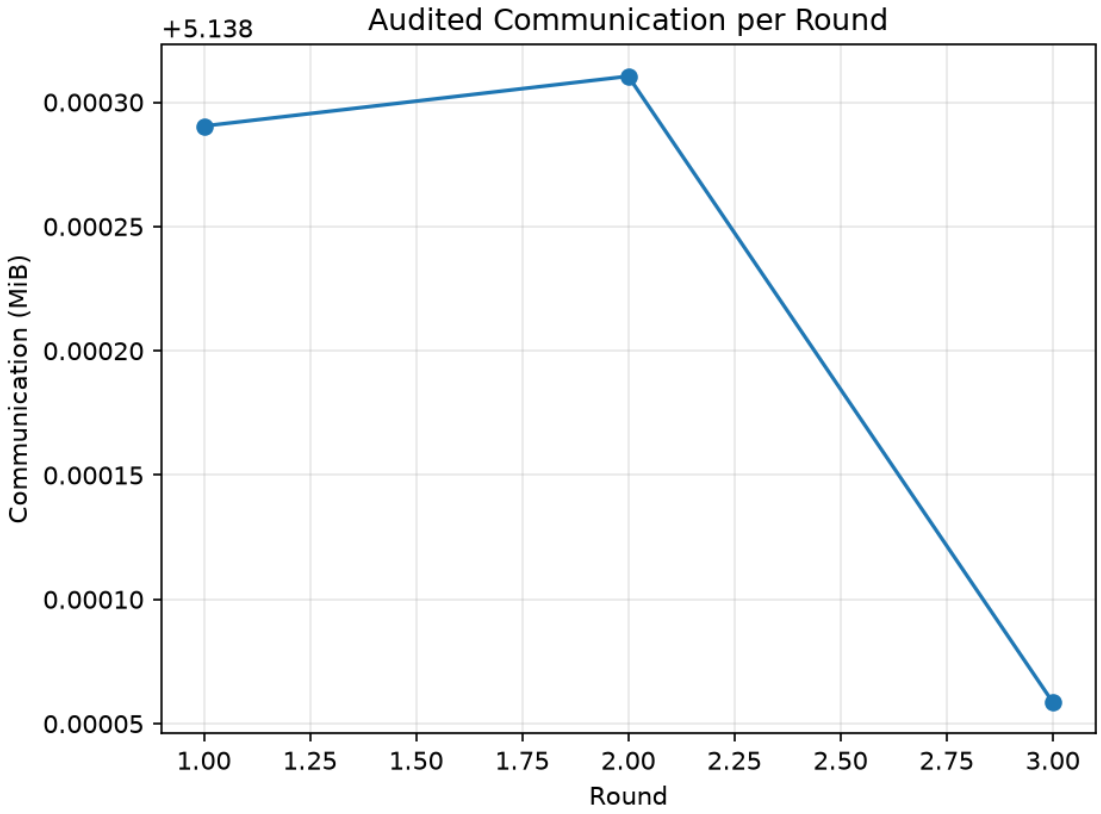
Πίνακας 28 Αποτελέσματα των ελεγχόμενων tampering demonstrations.

Σενάριο	Αποτέλεσμα	Ερμηνεία
Κανονικό audit package	VALID	Όλοι οι έλεγχοι περνούν
Αλλοίωση metric χωρίς νέο hash	INVALID_HASH_CHAIN	Αποτυχία record hash / continuity
Αλλοίωση signature με νέο record hash	INVALID_SIGNATURE	Αποτυχία Ed25519 verification

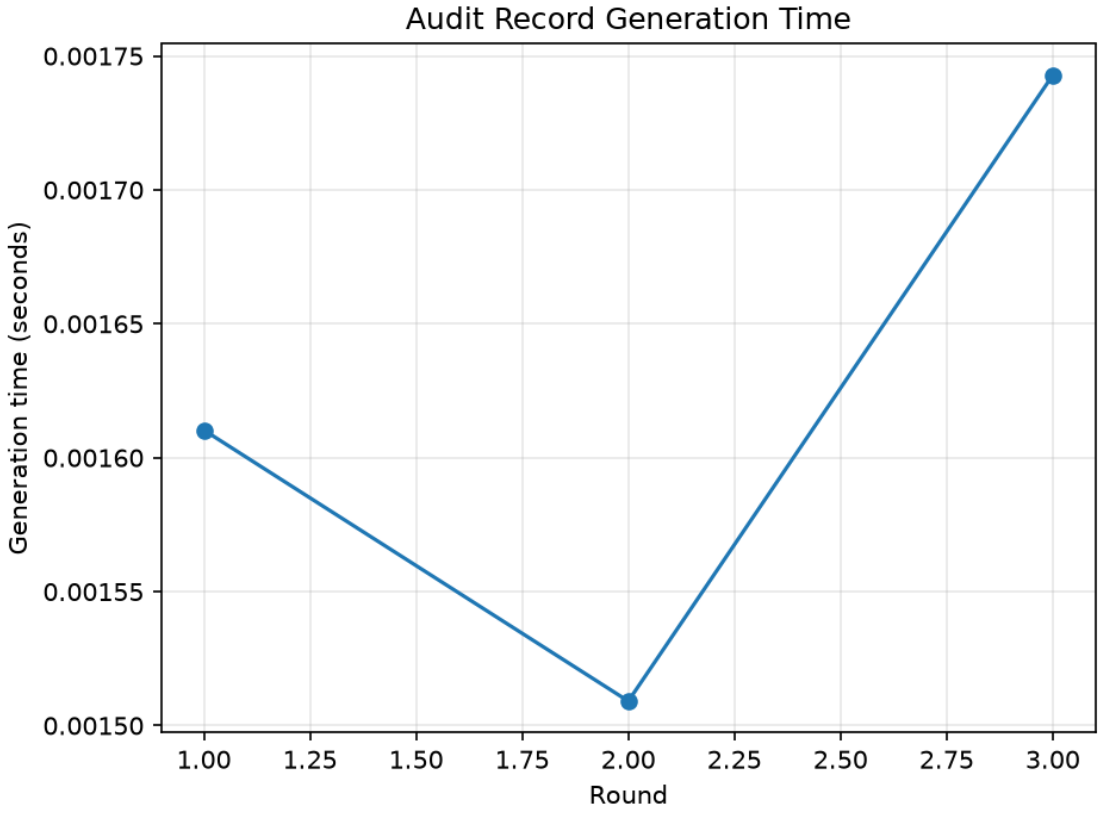
Το δεύτερο tamper test είναι ιδιαίτερα σημαντικό: ο record hash επανυπολογίζεται μετά την αλλοίωση, ώστε η hash chain να φαίνεται εσωτερικά συνεπής. Παρ' όλα αυτά η πλαστή signature δεν μπορεί να παραχθεί χωρίς το private key και ο verifier επιστρέφει INVALID_SIGNATURE.



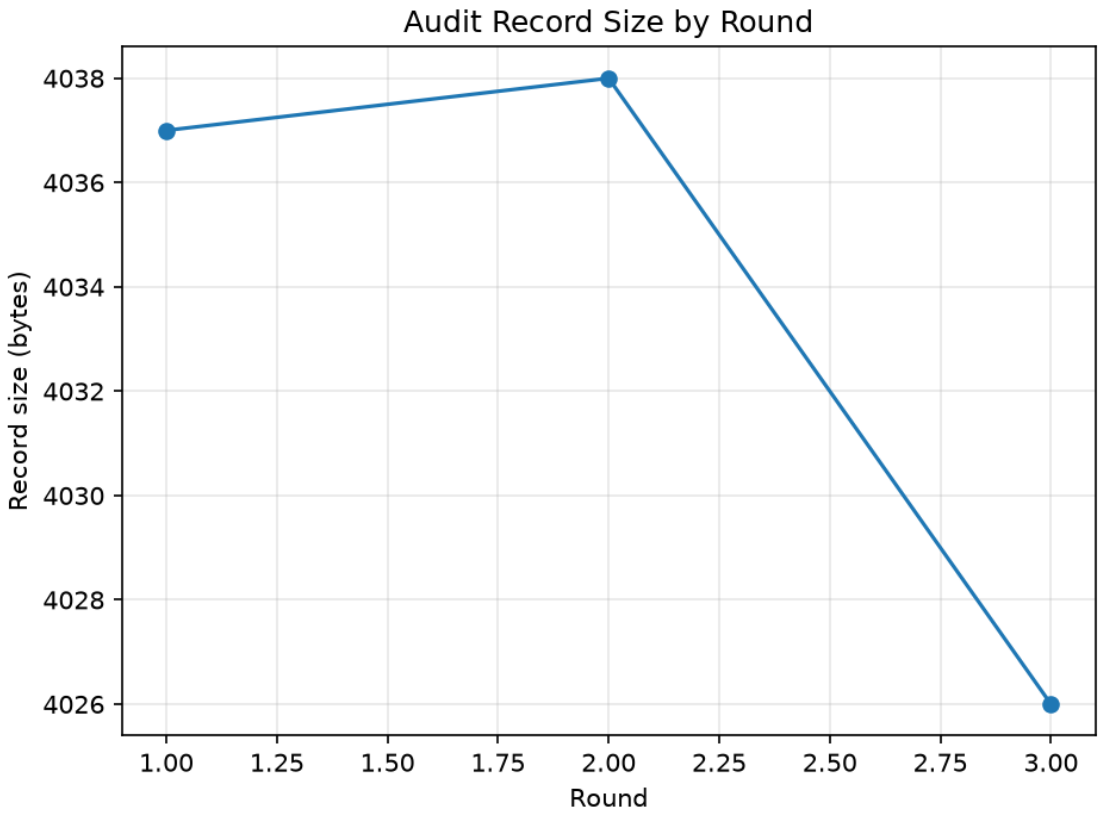
Σχήμα 31 Accuracy trace του audited experiment.



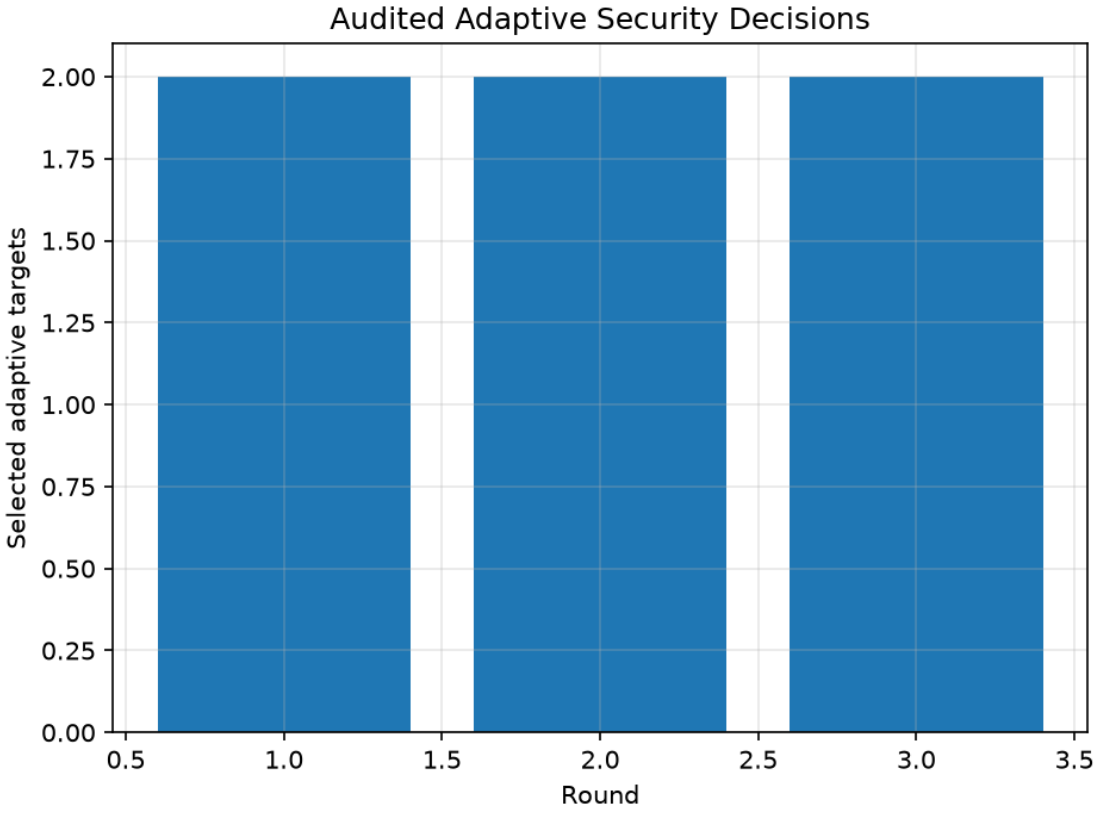
Σχήμα 32 Communication bytes ανά audited round.



Σχήμα 33 Χρόνος δημιουργίας audit record.



Σχήμα 34 Μέγεθος audit record ανά round.



Σχήμα 35 Adaptive HE targets που καταγράφηκαν στο ledger.

13.5 Σχέση με το lightweight blockchain

Πίνακας 29 Σύγκριση των δύο audit επιπέδων.

Διάσταση	Lightweight blockchain	Advanced audit
Υπογραφές	SHA256 simulation	Πραγματικές Ed25519
Δομή	Blocks σε JSON/CSV	Append-only JSONL records
Client hashes	Λίστα model hashes	Merkle root και individual proofs
Στόχος	Εκπαιδευτική hash-chain επίδειξη	Ισχυρότερη ερευνητική audit απόδειξη
Consensus/network	Δεν υλοποιείται	Δεν υλοποιείται
Privacy	Δεν παρέχεται	Δεν παρέχεται

14. Ενοποιημένη αποτίμηση της συνεισφοράς

Η αρχική σειρά εξετάζει τρία datasets, ring και fully connected και δύο μεγέθη δικτύου. Η συμπληρωματική σειρά προσθέτει Caveman, Barabási–Albert και κατανομές Dirichlet στο ρητά δηλωμένο εύρος των 228 runs. Η αξία της υλοποίησης είναι η ελεγχόμενη σύγκριση μαθησιακής συμπεριφοράς και λειτουργικού κόστους. Το risk score παραμένει heuristic που οργανώνει το HE budget.

Στις δοκιμασμένες διαμορφώσεις, οι protected μέθοδοι αποκλίνουν ελάχιστα από την αντίστοιχη baseline accuracy. Η ετερογένεια labels και η συνδεσιμότητα μεταβάλλουν περισσότερο τα αποτελέσματα. Ο adaptive hybrid με ratio 0,4 περιορίζει τον ειδικό χρόνο HE κατά περίπου 60% και τον υπολογισμένο όγκο επικοινωνίας σε σχέση με το selective HE, με σχεδόν ίδια accuracy.

Οι αριθμητικοί έλεγχοι cancellation και τα audit tampering demos τεκμηριώνουν συγκεκριμένες λειτουργικές ιδιότητες: ανακατασκευή aggregate και επαλήθευση αποθηκευμένων στοιχείων. Η ποσοτικοποίηση προστασίας έναντι επιθέσεων, collusion ή membership inference παραμένει χωριστό ερευνητικό ερώτημα.

15. Περιορισμοί και απειλές εγκυρότητας

- Προσομοίωση και τοπικό δίκτυο. Τα validation και sensitivity εκτελούν σειριακά τους clients στην ίδια διεργασία. Τα network χρησιμοποιούν πολλαπλές διεργασίες στον ίδιο υπολογιστή. Latency, packet loss, bandwidth limitations και ανεξάρτητες φυσικές συσκευές χρειάζονται ξεχωριστή αξιολόγηση.
- Μοντέλο και training budget. Τα δεδομένα αφορούν MLP 128 hidden units, τρία datasets και 20 γύρους. Η περίπου 44% IID accuracy του CIFAR-10 χαρακτηρίζει αυτό το baseline. Μεγαλύτερα μοντέλα, διαφορετική προεπεξεργασία και περισσότερα rounds μπορεί να αλλάξουν learning και crypto overhead.
- Περιορισμένες επαναλήψεις. Τα validation έχουν 3 seeds και το sensitivity ένα seed. Τα mean ± SD είναι περιγραφικά. Η βέλτιστη επιλογή HE ratio και η στατιστική ισοδυναμία απαιτούν πρόσθετα πειράματα.
- Περιορισμένο συμπληρωματικό εύρος. Η νέα σειρά ολοκλήρωσε 228 από τα 1.440 runs του ευρύτερου σχεδιασμού. Οι 1.212 υπόλοιπες εκτελέσεις αναβλήθηκαν. Οι συγκρίσεις α=0,1/1,0, IID και shards στις νέες τοπολογίες αφορούν μόνο CIFAR-10 baseline. Η κάλυψη αυτή δεν υποστηρίζει γενίκευση σε όλο το πλάνο.
- Χρονικές μετρήσεις. Οι χρόνοι αφορούν ένα laptop και διαχωρίζονται ανά legacy/cached_gpu, σειριακό ή παράλληλο περιβάλλον και execution session. Ομάδες που περιέχουν διαφορετικά sessions διατηρούν χωριστούς χρονικούς μέσους και το πραγματικό n. Η μείωση περίπου 60% στην αρχική σειρά και 58,7% στα 35 ίδια-session ζεύγη της συμπληρωματικής σειράς αφορά μόνο τις πράξεις HE.
- Μοντέλο απειλών. Το simple masking προϋποθέτει ελεγχόμενη διανομή mask. Το pairwise masking απαιτεί πλήρες contributor set. Το heuristic risk score δεν ορίζει πιθανότητα επίθεσης ή formal privacy guarantee. Dropouts, collusion και κακόβουλοι peers χρειάζονται ειδικούς ελέγχους.
- Διαχείριση κλειδιών και audit. Το prototype χρησιμοποιεί κεντρική διαχείριση CKKS keys χωρίς distributed key generation ή threshold decryption. Τα τοπικά audit layers ελέγχουν ακεραιότητα, με προϋποθέσεις για την εμπιστοσύνη στο manifest και τη φύλαξη κλειδιών. Η παραγωγική διανομή, TLS ή mTLS και εξωτερικό anchoring παραμένουν μελλοντική εργασία.

16. Συμπεράσματα και επόμενα βήματα

Ολοκληρώθηκαν 630 διακριτές εκτελέσεις σε δύο σειρές χωρίς αποτυχία: 402 αρχικές και 228 συμπληρωματικές. Τα raw CSV, τα manifests και οι έλεγχοι validation επιτρέπουν αντιστοίχιση των ευρημάτων με dataset, seed και διαμόρφωση. Η συμπληρωματική σειρά καλύπτει 76 συνδυασμούς με τρία seeds, ενώ οι υπόλοιπες 1.212 εκτελέσεις του ευρύτερου πλάνου παραμένουν αναβληθείσες.

Η εμπειρική αξιολόγηση υποστηρίζει ότι οι εξεταζόμενες μέθοδοι aggregation διατηρούν σχεδόν αμετάβλητη την accuracy του baseline. Η κατανομή labels και η τοπολογία επηρεάζουν περισσότερο τη μαθησιακή συμπεριφορά. Η fully connected τοπολογία βελτιώνει τη non-IID accuracy στο συγκεκριμένο training budget, με υψηλότερο communication cost.

Ο adaptive hybrid με ratio 0,4 προσφέρει οικονομικότερη χρήση της CKKS στις δοκιμασμένες συνθήκες. Η μείωση περίπου 60% στον ειδικό χρόνο HE συνυπάρχει με σχεδόν ίδια accuracy. Η επιλογή ratio παραμένει απόφαση που χρειάζεται σύνδεση με μοντέλο απειλών. Τα 30 sensitivity runs αποτυπώνουν το κόστος αυτής της επιλογής, με περιορισμένη στατιστική τεκμηρίωση λόγω ενός seed.

Στις νέες τοπολογίες δεν εμφανίζεται σταθερή υπεροχή Caveman ή Barabási–Albert. Στο CIFAR-10, το μεγαλύτερο α της Dirichlet συνδέεται με υψηλότερη accuracy στο σταθερό training budget. Οι προστατευμένες μέθοδοι παραμένουν κοντά στο baseline, με μέγιστη απόκλιση 0,198 ποσοστιαίων μονάδων στα 144 νέα ζεύγη. Το συμπέρασμα αφορά τις εξεταζόμενες περιπτώσεις και παραμένει περιγραφικό.

Επόμενα βήματα είναι η επέκταση στους αναβληθέντες συνδυασμούς του ευρύτερου πλάνου, η επανάληψη του sensitivity σε περισσότερα seeds και η σύγκριση με CNN ή μεγαλύτερο training budget. Ανεξάρτητες συσκευές και έλεγχοι επιθέσεων, collusion και dropout θα επιτρέψουν αποτίμηση πέρα από την παρούσα τοπική αξιολόγηση. Αυτές οι επεκτάσεις διαχωρίζονται από τα ολοκληρωμένα εμπειρικά ευρήματα.

16.1 Απαντήσεις στα ερευνητικά ερωτήματα

Για τα RQ1 και RQ3, οι protected μέθοδοι διατηρούν κοντά στο baseline την τελική accuracy και το pairwise aggregate έχει μέγιστο cancellation error κάτω από 10^{-6}. Το μέγιστο αντιστοιχισμένο accuracy delta είναι 0,23 ποσοστιαίες μονάδες σε 288 συγκρίσεις. Αυτό υποστηρίζει utility και αριθμητική συνέπεια στις εξεταζόμενες διαμορφώσεις. Στη συμπληρωματική σειρά η μέγιστη απόκλιση είναι 0,198 μονάδες σε 144 πρόσθετες αντιστοιχίσεις.

Για τα RQ2 και RQ4, ο adaptive hybrid με ratio 0,4 μειώνει περίπου 60% τον ειδικό χρόνο HE έναντι selective HE σε αντιστοιχισμένα cached_gpu runs. Η μείωση υπολογισμένου communication είναι 26,8% στα grayscale datasets και 10,3% στο CIFAR-10. Το όφελος αφορά συγκεκριμένο HE budget και δεν αποδεικνύει ίδιο επίπεδο προστασίας. Στη συμπληρωματική σειρά η μέση μείωση ειδικού χρόνου HE είναι 58,7% σε 35 ζεύγη του ίδιου session.

Για το RQ5, το label skew και η τοπολογία επηρεάζουν ουσιαστικά τη μάθηση. Η fully connected τοπολογία βελτιώνει τη non-IID baseline accuracy στο συγκεκριμένο budget, με περισσότερες αποστολές. Για το RQ6, οι προγενέστεροι signed audit έλεγχοι επαληθεύουν συγκεκριμένα records και ανιχνεύουν τις δοκιμασμένες αλλοιώσεις. Δεν βεβαιώνουν την ορθότητα της εκπαίδευσης ή την απουσία κακόβουλου περιεχομένου. Στις δύο νέες τοπολογίες η κατάταξη μεταβάλλεται ανά περίπτωση. Η σύγκριση CIFAR-10 συνδέει την αύξηση του α με βελτίωση accuracy, χωρίς να απομονώνει label skew από διαφορές στο πλήθος δειγμάτων ανά client.

Παράρτημα Α — Αναπαραγωγιμότητα

Α.1 Πηγές της τελικής αξιολόγησης

- results/campaign_20261014/manifest.json: μοναδικά IDs, ακριβείς εντολές, διαμορφώσεις, status και paths raw CSV.
- results/campaign_20261014/summary.csv: τελικές μετρικές και execution_profile ανά run.
- results/campaign_20261014/grouped_summary.csv: mean, sample SD και count με χωριστά timing profiles.
- results/campaign_20261014/performance_summary.csv και learning_curves.csv: συγκεντρωτικές μη χρονικές μετρικές.
- results/campaign_20261014/environment.txt: εκδόσεις εξαρτήσεων. EXECUTION_PROFILES.txt: περιγραφή της αλλαγής εκτέλεσης.
- results/campaign_20261014/execution_profile_validation/: paired baseline CSV που τεκμηριώνουν τη δοκιμή caching.
- results/logs/ και results/campaign_20261014/network/: raw round-level μετρήσεις. completion.json: ολοκλήρωση 402 από 402 runs.

Α.2 Παραδείγματα αναπαραγωγής

- python src/main.py --dataset fashion_mnist --num_clients 5 --num_rounds 20 --batch_size 32 --split_type iid --topology ring --security_mode none --seed 1 --device cuda --execution_profile cached_gpu --experiment_name reproduce_fashion_mnist_iid_seed1
- python src/main.py --dataset cifar10 --num_clients 5 --num_rounds 20 --batch_size 32 --split_type non_iid --topology ring --security_mode adaptive_hybrid --adaptive_policy topk_risk --adaptive_he_target_ratio 0.4 --seed 42 --device cuda --execution_profile cached_gpu --experiment_name reproduce_cifar10_sensitivity_ratio04
- python platform_mvp/mnist_network_demo.py --dataset cifar10 --split-type iid --security-mode masking --rounds 2 --device cuda --max-train-samples 1500 --max-test-samples 500 --experiment-id reproduce_network_cifar10 --output-dir results/reproduce_network
- python src/audit_cli.py verify --package results/audit_packages/thesis_audit_demo_3r
- python src/audit_cli.py tamper-demo --package results/audit_packages/thesis_audit_demo_3r --mode signature

Οι εντολές εκτελούνται από τη ρίζα του repository με τις καταγεγραμμένες εξαρτήσεις. Νέο experiment_name και χωριστό output directory διατηρούν τα προηγούμενα αποτελέσματα. Για ακριβή αναπαραγωγή κάθε αρχικού run χρησιμοποιείται η δική του command από το manifest, συμπεριλαμβανομένου του αρχικού execution profile.

Α.3 Πηγές της συμπληρωματικής σειράς

Το results/campaign_20261102_reduced/scope.json ορίζει τους 228 επιλεγμένους run IDs. Τα summary.csv και grouped_summary.csv καταγράφουν τις τελικές μετρικές και τα mean/sample SD των 76 ομάδων. Τα grouped_learning_curves.csv, accuracy_pairs.csv και he_pairs.csv τεκμηριώνουν καμπύλες και αντιστοιχισμένες συγκρίσεις. Το timing_by_session.csv διατηρεί χωριστά τα χρονικά περιβάλλοντα και το πραγματικό n. Τα validation.json και stopped.json καταγράφουν την ολοκλήρωση της επιλεγμένης σειράς [21].

Τα πρωτογενή metrics και metadata παραμένουν στο results/campaign_20261020_full/, με τα paths του manifest. Η συμπληρωματική σειρά αποτελεί υποσύνολο αυτού του manifest και δεν πρέπει να προστεθεί δεύτερη φορά στο πλήθος των runs. Οι οκτώ διερευνητικές δοκιμές CIFAR-10 και τα διαγνωστικά benchmarks του Diogenis παραμένουν χωριστά από τις 630 εκτελέσεις.

Για επαλήθευση των υπαρχόντων αποτελεσμάτων εκτελούνται από τη ρίζα του repository οι εντολές python src/summarize_bounded_campaign.py και python src/write_reduced_findings.py. Αυτές παράγουν summaries και κείμενο ευρημάτων χωρίς να ξεκινούν training. Η επανάληψη συγκεκριμένου run χρησιμοποιεί την εντολή του manifest και νέο experiment_name. Η αναπαραγωγή χρονικών μετρήσεων απαιτεί καταγραφή του περιβάλλοντος και νέου session.

Παράρτημα Β Προγενέστεροι έλεγχοι πλατφόρμας και Docker

Ο Πίνακας 30 συνοψίζει τους προγενέστερους ελέγχους Docker. Τα Σχήματα 36, 37 και 38 συνδέουν το operator dashboard, την επαλήθευση artifacts και την κατάσταση ανεξάρτητου κόμβου.

Τα αποτελέσματα του παραρτήματος προέρχονται από προηγούμενους ελέγχους της πλατφόρμας Docker. Διαφέρουν από τα 12 HTTP demos της τελικής καμπάνιας ως προς το περιβάλλον, το training budget και τα artifacts.

Secure Decentralized Federated Learning Prototype

In the final stage of the project, a more realistic platform-level demonstration was added. This extension does not modify the core thesis training pipeline. It improves the communication, control, auditability and presentation layer around the Secure DFL prototype.

The new demo runs three independent Secure DFL nodes inside Docker, generates real Ed25519 deployment keys, uses a trusted public-key manifest, executes signed decentralized rounds and verifies the signed audit logs after execution.

B.1 Implemented platform additions

- Docker real-key demo with three independent Secure DFL nodes.
- Automatic generation of real Ed25519 deployment keys.
- Trusted public-key manifest for peer verification.
- Signed model-state envelopes and payload hash verification.
- New security mode: pairwise_masking with target-specific mask cancellation.
- Operator dashboard for node status, finalized rounds and masking metrics.
- Evidence export folder with demo summary, audit verification, Docker logs and per-node audit logs.

B.2 Pairwise masking

The new security mode is DFL_SECURITY_MODE=pairwise_masking. In this mode, raw masks are not transported inside the update envelope.

Each contributor derives target-specific pairwise masks. During finalization, the target node applies its own local target-specific mask and then aggregates the masked contributor states. The pairwise masks cancel over the complete contributor set, so the final aggregate remains valid.

This is stronger than the earlier controlled masking mode, where the mask was transported to the receiver for reconstruction.

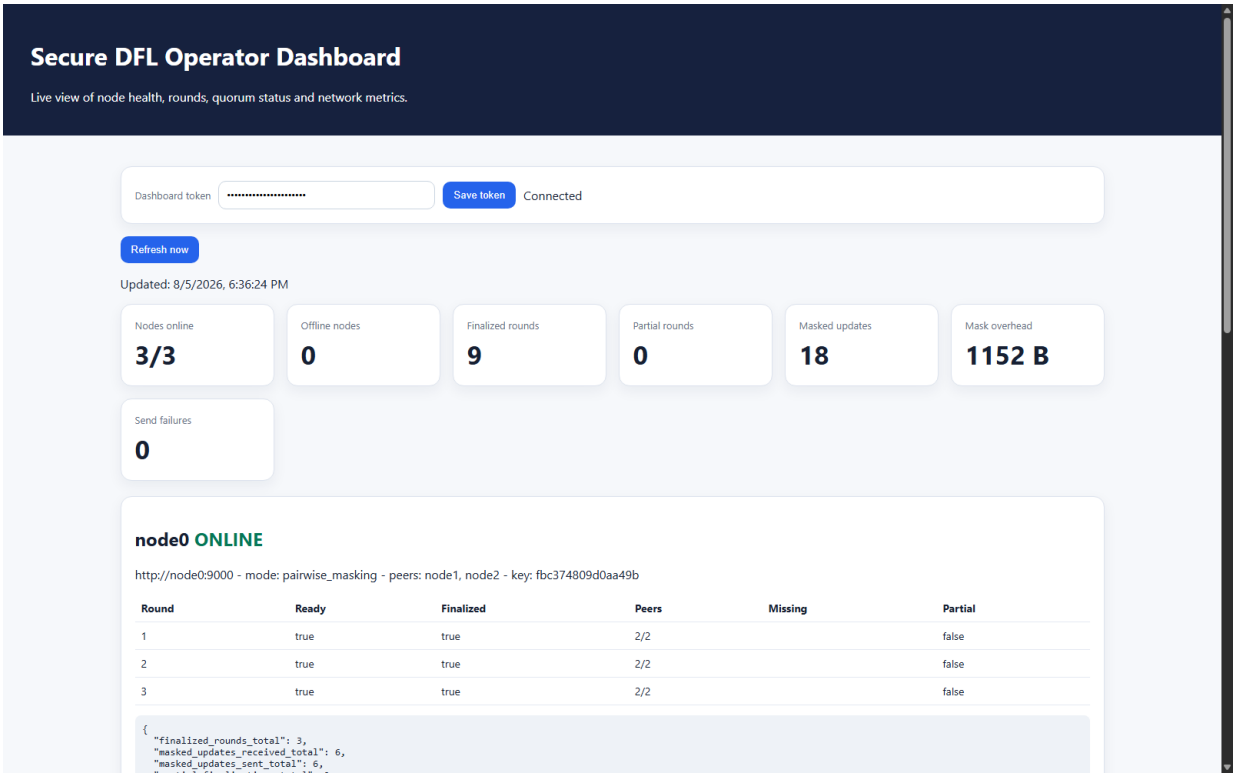
B.3 Final validation and evidence

Πίνακας 30 Σύνοψη προγενέστερων ελέγχων Docker

Check	**Result**
Platform validation matrix	8/8 PASS
Unit tests	12/12 OK
Docker real-key demo	PASS
Audit logs checked	3
Total audit records	39
Partial finalizations	0
Nodes online	3/3
Finalized rounds	9
Masked updates	18
Mask overhead	1152 B
Security mode	pairwise_masking

Evidence folder: platform_mvp/results/docker_real_key_demo_latest/

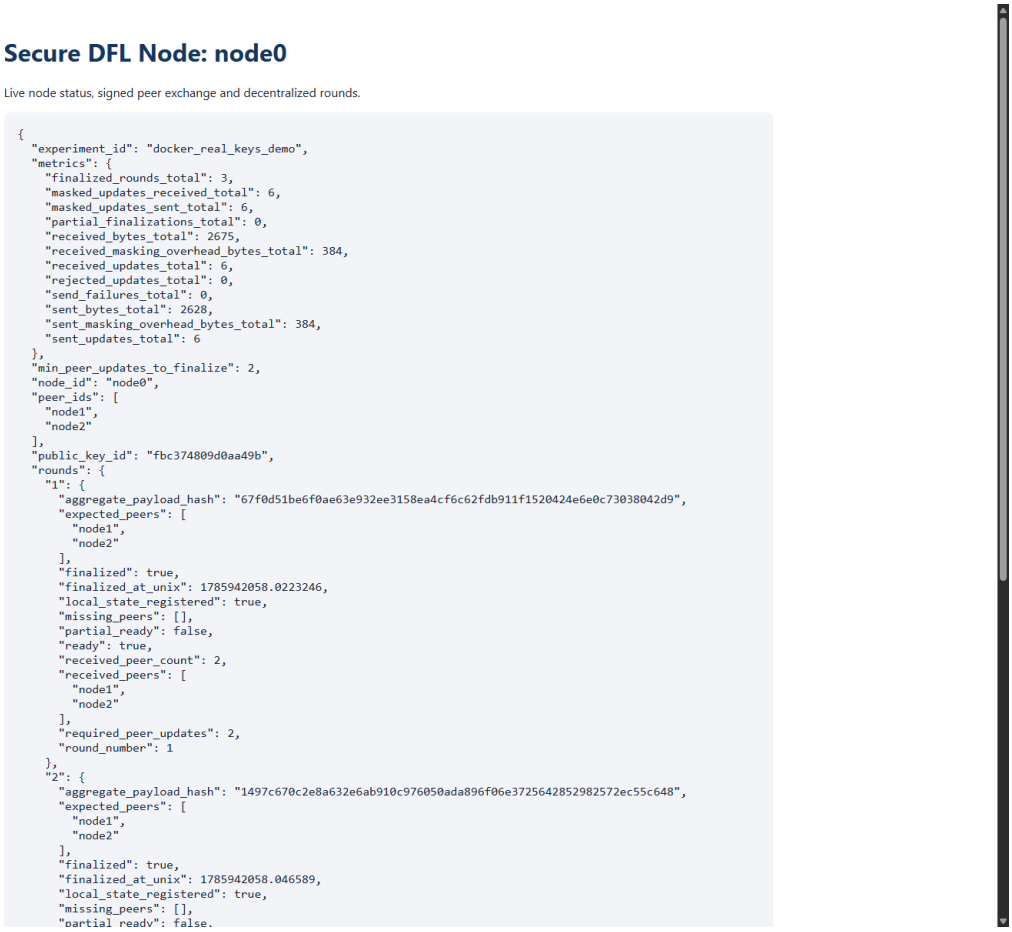
B.4 Figures from generated Docker results



Σχήμα 36 Προγενέστερο operator dashboard με τρεις online κόμβους και pairwise masking



Σχήμα 37 Σύνοψη επαλήθευσης των προγενέστερων Docker audit artifacts



Σχήμα 38 Κατάσταση ανεξάρτητου κόμβου στο προγενέστερο Docker demo

B.5 Limitations and next step

- The Docker demo uses local HTTP rather than production TLS or mTLS.
- The dashboard token is appropriate for demonstration, not enterprise authentication.
- The current pairwise_masking implementation requires the complete contributor set.
- Dropout-resilient pairwise masking and external audit anchoring remain future work.

Conclusion. With this extension, the project includes both the research experiment layer and a practical platform-level demo with real deployment keys, signed communication, pairwise masked payload exchange, a live dashboard and verifiable audit logs.

Παράρτημα Γ — Χαρτογράφηση λογισμικού και modules

Ο Πίνακας 31 αντιστοιχίζει τα βασικά modules στον ρόλο τους και ο Πίνακας 32 συγκεντρώνει τις παραδοχές ασφαλείας.

Το παράρτημα αυτό λειτουργεί ως τεχνικός χάρτης του repository. Σκοπός του δεν είναι να αντικαταστήσει την ανάγνωση του κώδικα, αλλά να συνδέσει τα θεωρητικά στάδια της διπλωματικής με συγκεκριμένα modules. Η διάσπαση σε μικρά αρχεία βοηθά τόσο την αναπαραγωγιμότητα όσο και την ανεξάρτητη δοκιμή των security components.

Πίνακας 31 Χαρτογράφηση βασικών modules.

Module	Ρόλος
src/config.py	Default experiment parameters και command-line configuration.
src/model.py	SimpleMLP και προσαρμογή input shape ανά dataset.
src/data_utils.py	Φόρτωση datasets και seeded IID shard-based και Dirichlet partitions.
src/client.py	Local SGD training, CrossEntropyLoss, evaluation και state management.
src/topology.py	Δημιουργία γειτονιών με την επιλεγμένη τοπολογία και seed.
src/aggregation.py	Plain averaging και βοηθητικές state_dict πράξεις.
src/masking.py	Simple και pairwise-canceling masking, seed derivation και correctness checks.
src/he_utils.py	CKKS contexts, final-layer selection, encryption, homomorphic average και decryption.
src/adaptive.py	Update norms, neighborhood risk scores και HE target selection policies.
src/metrics.py	Round-level metrics και CSV logging.
src/main.py	End-to-end experiment orchestration.
src/compare_results.py	Συγκεντρωτικά summaries και comparison plots.
src/run_adaptive_sensitivity.py	Sensitivity analysis για το adaptive HE target ratio.
src/run_validation_experiments.py	Multi-seed / multi-configuration validation runner.
src/blockchain/*	Lightweight hash-chain audit demonstration.

Module	Ρόλος
src/audit/*	Ed25519, Merkle, append-only ledger και verification package.
platform_mvp/secure_dfl_platform/*	Networked node runtime, protocol, crypto, masking και orchestration.
platform_mvp/operator_dashboard.py	Live operational dashboard για το Docker demo.
platform_mvp/run_platform_validation.py	Platform validation matrix και evidence checks.

Γ.1 Pseudocode ενός communication round

Ο παρακάτω ψευδοκώδικας συνοψίζει τη λογική του core experiment. Η διάκριση round_start_states και trained_states είναι αυτή που επιτρέπει τον υπολογισμό update norms, ενώ το previous_states snapshot χρησιμοποιείται για order-independent aggregation.

1. snapshot_before = {client: client.state()}
2. for client in clients: client.train_local(local_epochs)
3. trained_states = {client: client.state()}
4. if adaptive: risk = score(snapshot_before, trained_states, topology)
5. if adaptive: he_targets = select_topk(risk, target_ratio)
6. freeze previous_states = trained_states
7. for target in clients:
   contributors = [target] + neighbors(target)
   choose protection according to security_mode / he_targets
   new_state[target] = protected_neighborhood_average(contributors)
8. commit all new_state values to clients
9. evaluate all clients on the common test set
10. write round metrics and optional audit record

Γ.2 Pseudocode pairwise masking

Για κάθε target neighborhood, κάθε unordered contributor pair μοιράζεται deterministic seed. Το sign convention είναι σταθερό ώστε η συνολική μάσκα να μηδενίζεται όταν συμμετέχει το πλήρες contributor set.

```
for each pair (i, j) in contributors with i < j:
  m_ij = PRG(seed(target, round, i, j), tensor_shapes)
  masked_state[i] += m_ij
  masked_state[j] -= m_ij
aggregate = average(masked_state[contributors])
```

```
assert max_abs(aggregate - plaintext_average) < tolerance
```

Γ.3 Pseudocode Selective CKKS

```
selected = [output.weight, output.bias]
for contributor in contributors:
   vector = flatten(contributor.state[selected])
   ciphertext[contributor] = CKKS_encrypt(public_context[target], vector)
encrypted_avg = (sum(ciphertexts) * (1 / num_contributors))
decrypted = CKKS_decrypt(secret_key[target], encrypted_avg)
new_state[selected] = reconstruct(decrypted)
new_state[non_selected] = plaintext_average(non_selected)
```

Γ.4 Security assumptions του prototype

Πίνακας 32 Κύριες παραδοχές ασφαλείας.

Μηχανισμός	Κύρια παραδοχή / όριο
Pairwise masking	Πλήρες contributor set για ακύρωση· δεν υλοποιείται dropout recovery.
Selective CKKS	Target-specific key context· δεν υλοποιείται threshold decryption ή distributed key generation.
Adaptive risk	Heuristic update magnitude· δεν είναι attack detector.
Ed25519 audit	Private keys θεωρούνται μη εκτεθειμένα· compromise host δεν καλύπτεται πλήρως.
Hash chain	Παρέχει tamper evidence για αποθηκευμένα artifacts, όχι distributed consensus.
Docker demo	Local HTTP και demo token, όχι production TLS/mTLS ή enterprise IAM.

Παράρτημα Δ — Αναλυτικά αποτελέσματα και validation tables

Οι Πίνακες 33, 34 και 35 δίνουν τα αναλυτικά validation αποτελέσματα για MNIST, Fashion-MNIST και CIFAR-10 αντίστοιχα. Οι Πίνακες 36, 37 και 38 δίνουν τις αντίστοιχες sensitivity μετρήσεις.

Δ.1 Αναλυτικά validation summaries

Οι ακόλουθοι πίνακες συνοψίζουν και τις 120 μοναδικές validation διαμορφώσεις, με τρία seeds ανά γραμμή και 360 runs συνολικά. Οι τιμές είναι τελική test accuracy επί τοις εκατό και sample SD. Οι χρόνοι δεν περιλαμβάνονται στους πίνακες, ώστε να μην συγχωνεύονται διαφορετικά execution profiles. Τα 402 μοναδικά run IDs και τα round-level αρχεία παραμένουν στο manifest και στα CSV [20].

Πίνακας 33 Πλήρη validation αποτελέσματα MNIST

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
5	Ring	IID	Baseline	92,51 ± 0,02	3
5	Ring	IID	Simple masking	92,51 ± 0,02	3
5	Ring	IID	Pairwise masking	92,51 ± 0,02	3
5	Ring	IID	Selective HE	92,51 ± 0,02	3
5	Ring	IID	Adaptive hybrid	92,51 ± 0,02	3
5	Ring	non-IID	Baseline	65,62 ± 2,10	3
5	Ring	non-IID	Simple masking	65,62 ± 2,10	3
5	Ring	non-IID	Pairwise masking	65,62 ± 2,10	3
5	Ring	non-IID	Selective HE	65,62 ± 2,10	3
5	Ring	non-IID	Adaptive hybrid	65,62 ± 2,10	3
5	Full	IID	Baseline	92,53 ± 0,04	3
5	Full	IID	Simple masking	92,53 ± 0,04	3
5	Full	IID	Pairwise masking	92,53 ± 0,04	3
5	Full	IID	Selective HE	92,53 ± 0,04	3
5	Full	IID	Adaptive hybrid	92,53 ± 0,04	3
5	Full	non-IID	Baseline	79,44 ± 0,64	3
5	Full	non-IID	Simple masking	79,44 ± 0,64	3

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
5	Full	non-IID	Pairwise masking	79,44 ± 0,64	3
5	Full	non-IID	Selective HE	79,44 ± 0,64	3
5	Full	non-IID	Adaptive hybrid	79,44 ± 0,64	3
10	Ring	IID	Baseline	90,97 ± 0,02	3
10	Ring	IID	Simple masking	90,97 ± 0,02	3
10	Ring	IID	Pairwise masking	90,97 ± 0,02	3
10	Ring	IID	Selective HE	90,97 ± 0,02	3
10	Ring	IID	Adaptive hybrid	90,97 ± 0,02	3
10	Ring	non-IID	Baseline	51,48 ± 6,53	3
10	Ring	non-IID	Simple masking	51,48 ± 6,53	3
10	Ring	non-IID	Pairwise masking	51,48 ± 6,53	3
10	Ring	non-IID	Selective HE	51,48 ± 6,53	3
10	Ring	non-IID	Adaptive hybrid	51,48 ± 6,53	3
10	Full	IID	Baseline	91,05 ± 0,03	3
10	Full	IID	Simple masking	91,05 ± 0,03	3
10	Full	IID	Pairwise masking	91,05 ± 0,03	3
10	Full	IID	Selective HE	91,06 ± 0,03	3
10	Full	IID	Adaptive hybrid	91,05 ± 0,03	3
10	Full	non-IID	Baseline	81,31 ± 2,07	3
10	Full	non-IID	Simple masking	81,31 ± 2,07	3
10	Full	non-IID	Pairwise masking	81,31 ± 2,07	3
10	Full	non-IID	Selective HE	81,31 ± 2,07	3
10	Full	non-IID	Adaptive hybrid	81,31 ± 2,07	3

Πίνακας 34 Πλήρη validation αποτελέσματα Fashion-MNIST

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
5	Ring	IID	Baseline	83,17 ± 0,04	3
5	Ring	IID	Simple masking	83,17 ± 0,04	3
5	Ring	IID	Pairwise masking	83,16 ± 0,04	3
5	Ring	IID	Selective HE	83,17 ± 0,03	3
5	Ring	IID	Adaptive hybrid	83,17 ± 0,03	3
5	Ring	non-IID	Baseline	48,37 ± 1,58	3
5	Ring	non-IID	Simple masking	48,37 ± 1,58	3
5	Ring	non-IID	Pairwise masking	48,37 ± 1,58	3
5	Ring	non-IID	Selective HE	48,37 ± 1,58	3
5	Ring	non-IID	Adaptive hybrid	48,37 ± 1,57	3
5	Full	IID	Baseline	83,26 ± 0,08	3
5	Full	IID	Simple masking	83,26 ± 0,09	3
5	Full	IID	Pairwise masking	83,27 ± 0,10	3
5	Full	IID	Selective HE	83,27 ± 0,10	3
5	Full	IID	Adaptive hybrid	83,27 ± 0,10	3
5	Full	non-IID	Baseline	68,29 ± 1,28	3
5	Full	non-IID	Simple masking	68,29 ± 1,28	3
5	Full	non-IID	Pairwise masking	68,29 ± 1,28	3
5	Full	non-IID	Selective HE	68,29 ± 1,28	3
5	Full	non-IID	Adaptive hybrid	68,29 ± 1,28	3
10	Ring	IID	Baseline	81,38 ± 0,13	3
10	Ring	IID	Simple masking	81,39 ± 0,12	3
10	Ring	IID	Pairwise masking	81,39 ± 0,13	3
10	Ring	IID	Selective HE	81,38 ± 0,13	3
10	Ring	IID	Adaptive hybrid	81,38 ± 0,13	3

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
10	Ring	non-IID	Baseline	35,61 ± 4,11	3
10	Ring	non-IID	Simple masking	35,61 ± 4,11	3
10	Ring	non-IID	Pairwise masking	35,61 ± 4,11	3
10	Ring	non-IID	Selective HE	35,61 ± 4,11	3
10	Ring	non-IID	Adaptive hybrid	35,61 ± 4,11	3
10	Full	IID	Baseline	81,55 ± 0,11	3
10	Full	IID	Simple masking	81,55 ± 0,11	3
10	Full	IID	Pairwise masking	81,55 ± 0,12	3
10	Full	IID	Selective HE	81,55 ± 0,12	3
10	Full	IID	Adaptive hybrid	81,55 ± 0,11	3
10	Full	non-IID	Baseline	71,42 ± 1,50	3
10	Full	non-IID	Simple masking	71,42 ± 1,50	3
10	Full	non-IID	Pairwise masking	71,42 ± 1,50	3
10	Full	non-IID	Selective HE	71,42 ± 1,50	3
10	Full	non-IID	Adaptive hybrid	71,42 ± 1,50	3

Πίνακας 35 Πλήρη validation αποτελέσματα CIFAR-10

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
5	Ring	IID	Baseline	43,93 ± 0,71	3
5	Ring	IID	Simple masking	43,94 ± 0,77	3
5	Ring	IID	Pairwise masking	43,97 ± 0,69	3
5	Ring	IID	Selective HE	43,92 ± 0,75	3
5	Ring	IID	Adaptive hybrid	43,95 ± 0,71	3
5	Ring	non-IID	Baseline	23,30 ± 0,74	3
5	Ring	non-IID	Simple masking	23,29 ± 0,78	3
5	Ring	non-IID	Pairwise masking	23,30 ± 0,75	3

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
5	Ring	non-IID	Selective HE	23,29 ± 0,76	3
5	Ring	non-IID	Adaptive hybrid	23,30 ± 0,76	3
5	Full	IID	Baseline	44,41 ± 0,75	3
5	Full	IID	Simple masking	44,41 ± 0,78	3
5	Full	IID	Pairwise masking	44,34 ± 0,74	3
5	Full	IID	Selective HE	44,31 ± 0,79	3
5	Full	IID	Adaptive hybrid	44,44 ± 0,69	3
5	Full	non-IID	Baseline	31,26 ± 0,46	3
5	Full	non-IID	Simple masking	31,20 ± 0,46	3
5	Full	non-IID	Pairwise masking	31,18 ± 0,42	3
5	Full	non-IID	Selective HE	31,31 ± 0,36	3
5	Full	non-IID	Adaptive hybrid	31,27 ± 0,26	3
10	Ring	IID	Baseline	39,94 ± 0,42	3
10	Ring	IID	Simple masking	39,93 ± 0,44	3
10	Ring	IID	Pairwise masking	39,91 ± 0,44	3
10	Ring	IID	Selective HE	39,90 ± 0,43	3
10	Ring	IID	Adaptive hybrid	39,95 ± 0,44	3
10	Ring	non-IID	Baseline	17,55 ± 0,67	3
10	Ring	non-IID	Simple masking	17,55 ± 0,67	3
10	Ring	non-IID	Pairwise masking	17,55 ± 0,65	3
10	Ring	non-IID	Selective HE	17,54 ± 0,67	3
10	Ring	non-IID	Adaptive hybrid	17,54 ± 0,66	3
10	Full	IID	Baseline	41,22 ± 0,19	3
10	Full	IID	Simple masking	41,14 ± 0,19	3
10	Full	IID	Pairwise masking	41,13 ± 0,21	3

Clients	Graph	Split	Μέθοδος	Accuracy % ± SD	n
10	Full	IID	Selective HE	41,18 ± 0,18	3
10	Full	IID	Adaptive hybrid	41,15 ± 0,23	3
10	Full	non-IID	Baseline	34,09 ± 0,33	3
10	Full	non-IID	Simple masking	34,08 ± 0,23	3
10	Full	non-IID	Pairwise masking	34,05 ± 0,22	3
10	Full	non-IID	Selective HE	34,08 ± 0,24	3
10	Full	non-IID	Adaptive hybrid	34,07 ± 0,30	3

Δ.2 Αναλυτικά sensitivity αποτελέσματα

Κάθε γραμμή προέρχεται από μία εκτέλεση με seed 42, 5 clients, ring και 20 γύρους. Ο χρόνος HE είναι μέσος χρόνος ανά γύρο στο cached_gpu profile. Τα στοιχεία παραμένουν διερευνητικά, χωρίς εκτίμηση διασποράς μεταξύ seeds.

Πίνακας 36 Sensitivity MNIST

Split	Ratio	Accuracy %	Test loss	HE s ανά γύρο	MiB ανά γύρο
IID	0,2	92,362	0,27002	0,01044	4,511
IID	0,4	92,366	0,27002	0,02149	5,138
IID	0,6	92,364	0,27002	0,03101	5,766
IID	0,8	92,366	0,27002	0,04257	6,394
IID	1,0	92,364	0,27002	0,05089	7,022
non-IID	0,2	62,146	1,19887	0,01332	4,510
non-IID	0,4	62,146	1,19887	0,02571	5,138
non-IID	0,6	62,146	1,19887	0,03814	5,766
non-IID	0,8	62,146	1,19887	0,05244	6,394
non-IID	1,0	62,146	1,19887	0,06270	7,021

Πίνακας 37 Sensitivity Fashion-MNIST

Split	Ratio	Accuracy %	Test loss	HE s ανά γύρο	MiB ανά γύρο
IID	0,2	83,284	0,48000	0,01045	4,510

Split	Ratio	Accuracy %	Test loss	HE s ανά γύρο	MiB ανά γύρο
IID	0,4	83,270	0,48000	0,02102	5,138
IID	0,6	83,274	0,48000	0,03135	5,766
IID	0,8	83,270	0,47999	0,04261	6,394
IID	1,0	83,278	0,47999	0,05176	7,022
non-IID	0,2	41,402	2,25358	0,01327	4,510
non-IID	0,4	41,402	2,25358	0,02166	5,138
non-IID	0,6	41,402	2,25358	0,03853	5,766
non-IID	0,8	41,402	2,25358	0,05302	6,394
non-IID	1,0	41,402	2,25358	0,06157	7,021

Πίνακας 38 Sensitivity CIFAR-10

Split	Ratio	Accuracy %	Test loss	HE s ανά γύρο	MiB ανά γύρο
IID	0,2	43,630	1,59755	0,01059	15,682
IID	0,4	43,642	1,59752	0,02162	16,310
IID	0,6	43,668	1,59717	0,03244	16,938
IID	0,8	43,632	1,59749	0,04074	17,566
IID	1,0	43,666	1,59760	0,05833	18,193
non-IID	0,2	24,190	2,81750	0,01387	15,682
non-IID	0,4	24,198	2,81321	0,02529	16,310
non-IID	0,6	24,178	2,81681	0,03942	16,938
non-IID	0,8	24,120	2,81909	0,05148	17,565
non-IID	1,0	24,204	2,81456	0,06308	18,193

Παράρτημα Ε Έλεγχος και αντιστοίχιση πειραματικών τεκμηρίων

Ε.1 Διαχωρισμός πλήθους runs και φίλτρων

Το σύνολο των ολοκληρωμένων σειρών είναι 630 διακριτά runs: 402 αρχικά και 228 της επιλεγμένης επέκτασης. Η επέκταση είναι υποσύνολο του πλάνου 1.440 runs, από το οποίο παραμένουν 1.212 αναβληθέντα. Το dashboard εμφανίζει 228/228 για το επιλεγμένο εύρος και 630/1.842 για το άθροισμα των αρχικών και του ευρύτερου σχεδιασμού. Το δεύτερο κλάσμα δεν δηλώνει εκκρεμότητες μέσα στην ολοκληρωμένη επιλεγμένη σειρά. Οι αρχικοί μετρητές παραμένουν 360 validation, 30 sensitivity και 12 network.

Ε.2 Έλεγχοι συνέπειας και provenance

Η τελική αντιπαραβολή έλεγξε ότι κάθε completed run διαθέτει raw CSV, ότι οι γύροι εμφανίζονται μία φορά και ότι η τελική accuracy του summary συμφωνεί με την τελευταία round-level μέτρηση. Τα validation και sensitivity περιέχουν 20 γύρους ανά run και τα network δύο. Συνολικά προκύπτουν 7.824 run-round εγγραφές, με διαφορετική σημασία επικοινωνίας ανά workflow. Δεν αθροίζονται ως ομοιογενές traffic benchmark. Η συμπληρωματική σειρά προσθέτει 4.560 εγγραφές, 228 runs επί 20 γύρους, για σύνολο 12.384 run-round εγγραφών στις δύο σειρές.

Τα πρώτα 27 legacy validation CSV διατηρήθηκαν με τους αρχικούς SHA-256 hashes. Η επιτάχυνση εφαρμόστηκε στα εκκρεμή runs και αποτυπώνεται στο execution_profile. Οι legacy χρόνοι δεν αντικαταστάθηκαν από μεταγενέστερες μετρήσεις. Τα paired benchmarks αποθηκεύουν χωριστά την αρχική και την optimized εκτέλεση.

Ε.3 Αναφορά σε πίνακες και διαγράμματα

Κάθε αριθμητικό εύρημα αναφέρεται σε workflow, dataset, split, clients, topology, security mode και seed ή πλήθος seeds. Οι συγκρίσεις adaptive έναντι selective HE χρησιμοποιούν κοινό execution profile, timing environment και session. Οι καμπύλες learning συνοψίζουν τα seeds ανά γύρο, ενώ τα sensitivity διατηρούν το seed 42. Τα audit plots προέρχονται από προγενέστερα demos και δεν αποτελούν τέταρτο σκέλος της καμπάνιας.

Ε.4 Αρχεία παράδοσης

Το κύριο κείμενο, η τεχνική αναφορά, η παρουσίαση και το dashboard διακρίνουν την αρχική σειρά 402 runs από τη συμπληρωματική σειρά 228 runs. Τα raw δεδομένα και τα manifests αποτελούν την αριθμητική πηγή αναφοράς. Οι πίνακες και τα διαγράμματα αναφέρουν το εύρος και το πλήθος seeds, ενώ τα μη εκτελεσμένα σκέλη του ευρύτερου σχεδιασμού δηλώνονται ως αναβληθέντα.

Παράρτημα ΣΤ — Αναλυτικός τεχνικός οδηγός υλοποίησης

Ο Πίνακας 39 συγκεντρώνει τα invariants που συνδέουν τα επιμέρους layers της υλοποίησης με την ορθή λειτουργία τους.

Το παράρτημα αυτό επεκτείνει τη χαρτογράφηση του κώδικα και εξηγεί πώς τα θεωρητικά βήματα της διπλωματικής μεταφράζονται σε πραγματικές software responsibilities. Η παρουσίαση παραμένει σε επίπεδο αρχιτεκτονικής και αλγοριθμικής ροής και δεν αποτελεί line-by-line documentation. Στόχος είναι ένας αναγνώστης να μπορεί να εντοπίσει γρήγορα το module που υλοποιεί κάθε έννοια και να κατανοήσει ποιες μεταβλητές είναι κρίσιμες για την ορθότητα του experiment.

Η διάκριση μεταξύ core experiment και Platform MVP παραμένει θεμελιώδης. Ο φάκελος src/ περιέχει το controlled research pipeline από το οποίο παράγονται τα συγκριτικά CSV και plots. Ο φάκελος platform_mvp/ επεκτείνει την ιδέα με ανεξάρτητους networked nodes, protocol envelopes και operational evidence. Τα συμπεράσματα accuracy και communication των κύριων πειραμάτων πρέπει επομένως να συσχετίζονται με τον core runner και όχι να αποδίδονται αυτόματα στο Docker demo.

ΣΤ.1 Configuration και command-line reproducibility

Το src/config.py ορίζει τις default τιμές του experiment. Η dataclass Config λειτουργεί ως single source of defaults: πέντε clients, είκοσι rounds, μία local epoch, batch size 32, learning rate 0.01, MNIST, IID split, ring topology, security_mode none και CUDA ως preferred device. Η ίδια config περιέχει και τις CKKS παραμέτρους: polynomial modulus degree 8192, scale bits 40 και coefficient modulus chain 60,40,40,60. Για την Adaptive Hybrid ορίζονται topk_risk policy, target ratio 0.4, threshold 0.0, periodic interval 5 και minimum ένα HE target.

Η ύπαρξη κεντρικής configuration περιορίζει τον κίνδυνο να εκτελεστούν δύο experiments με κρυφές διαφορές. Το command-line interface μπορεί να υπερισχύσει των defaults και κάθε experiment_name χρησιμοποιείται για ξεχωριστό output. Ερευνητικά, αυτή η πρακτική είναι σημαντική επειδή επιτρέπει να αποθηκεύονται δίπλα-δίπλα baseline και protected runs χωρίς overwrite.

Οι security modes δεν αλλάζουν optimizer, local epochs ή model architecture. Επομένως, όταν ένα experiment εμφανίζει μεγαλύτερο communication ή dedicated HE time, η διαφορά μπορεί να αποδοθεί με μεγαλύτερη βεβαιότητα στο security path. Αντίστοιχα, η accuracy σχεδόν ταυτίζεται όταν ο protected aggregation path αναπαράγει το plaintext numerical result.

```
Config(num_clients=5, num_rounds=20, local_epochs=1, batch_size=32,
    learning_rate=0.01, dataset="mnist", split_type="iid",
    topology="ring", security_mode="none", device="cuda")
Adaptive: policy="topk_risk", he_target_ratio=0.4, min_he_targets=1
CKKS: poly_modulus_degree=8192, scale_bits=40, coeff_mod_bits="60,40,40,60"
```

ΣΤ.2 Dataset loading και deterministic partitioning

Το data_utils.py είναι υπεύθυνο για dataset metadata, downloading, random seeds και client partitions. Το DATASET_SPECS διαχωρίζει το input shape και τον αριθμό classes από το ίδιο το model. Με αυτό τον τρόπο το SimpleMLP μπορεί να προσαρμόσει αυτόματα το input_features για 28×28 grayscale datasets ή 32×32 RGB CIFAR-10, ενώ η κύρια training logic παραμένει κοινή.

Η set_seed() ρυθμίζει random, NumPy και torch seeds και, εάν υπάρχει CUDA, όλα τα CUDA seeds. Επιπλέον, cudnn.deterministic ενεργοποιείται και cudnn.benchmark απενεργοποιείται. Οι επιλογές αυτές προτιμούν repeatability έναντι μέγιστου throughput. Δεν εξαλείφουν κάθε πιθανή πηγή nondeterminism σε όλες τις hardware/software εκδόσεις, αλλά δημιουργούν σημαντικά πιο ελεγχόμενο experimental environment.

Το IID partition δημιουργείται με torch.randperm πάνω στα training indices και balanced partition sizes. Η ισορροπία αφορά το πλήθος samples, ενώ η class distribution γίνεται περίπου αντιπροσωπευτική λόγω random shuffle. Κάθε client DataLoader λαμβάνει ξεχωριστό generator seed ώστε το local shuffle να είναι reproducible.

Το non-IID partition ακολουθεί διαφορετική λογική. Τα labels εξάγονται, τα indices ταξινομούνται σταθερά κατά label και χωρίζονται σε num_clients × shards_per_client shards. Με πέντε clients και δύο shards/client δημιουργούνται δέκα shards. Τα shards ανακατεύονται ως units και κάθε client λαμβάνει δύο. Επειδή κάθε shard προέρχεται από sorted labels, οι clients αποκτούν έντονο label specialization. Αυτός ο deterministic label-skew μηχανισμός είναι η βασική αιτία της πολύ δυσκολότερης non-IID σύγκλισης.

ΣΤ.3 Client object και local optimization

Το Client encapsulates model, optimizer, criterion και DataLoaders. Κάθε client έχει πλήρες model replica και SGD optimizer. Η train_local() περνά από όλα τα local batches για τον ζητούμενο αριθμό epochs. Σε κάθε batch μεταφέρει inputs και targets στο device, μηδενίζει gradients, υπολογίζει outputs, CrossEntropyLoss, backpropagation και optimizer step. Το returned train loss είναι sample-weighted mean και όχι απλός μέσος όρος batch losses.

Η evaluate() λειτουργεί σε torch.no_grad() και υπολογίζει sample-weighted loss και classification accuracy. Το get_state_dict() επιστρέφει independent CPU clone των tensors. Αυτό είναι κρίσιμο: εάν κρατούσαμε references στα live model tensors, ένα subsequent optimizer step θα μπορούσε να μεταβάλει και το supposed snapshot. Η explicit clone semantics επιτρέπει αξιόπιστη σύγκριση before/after και synchronous aggregation.

Το set_state_dict() φορτώνει το aggregated state με strict=True. Η strict φόρτωση λειτουργεί ως επιπλέον structural check: όλοι οι clients πρέπει να έχουν ακριβώς τα ίδια parameter names και compatible shapes. Αυτός είναι ένας από τους λόγους που το DFL prototype προϋποθέτει κοινή model architecture μεταξύ participants.

ΣΤ.4 Topology abstraction

Το topology module επιστρέφει mapping target_client_id προς neighbor IDs. Το security layer χρησιμοποιεί τη γειτονιά για να ορίσει τους contributors κάθε target. Η αρχική σειρά αξιολογεί ring και fully connected. Η συμπληρωματική σειρά προσθέτει Caveman και Barabási–Albert στο εύρος της ενότητας 11.4.

Σε ring πέντε clients, κάθε target neighborhood έχει τρεις contributors. Η contributor set περιλαμβάνει τον target επειδή το νέο local state πρέπει να συνδυάζει και τη γνώση που απέκτησε ο ίδιος. Ένα average μόνο των δύο γειτόνων θα διέγραφε τη local contribution του target μετά από κάθε round και θα αντιστοιχούσε σε διαφορετικό learning protocol.

Η πλήρης συνδεσιμότητα διαδίδει τη γνώση σε περισσότερους peers ανά γύρο. Στη συγκεκριμένη καμπάνια βελτιώνει τη non-IID baseline accuracy, με 2 φορές περισσότερες κατευθυνόμενες αποστολές για 5 clients και 4,5 φορές για 10 clients σε σχέση με το ring. Οι λόγοι προκύπτουν από N(N−1) έναντι 2N αποστολών και αφορούν τα εξεταζόμενα μεγέθη.

ΣΤ.5 Plain aggregation ως reference

Το aggregation.py υλοποιεί state_dict averaging. Η λειτουργία traverses τα ίδια keys και υπολογίζει element-wise average για floating tensors. Η reference αυτή χρησιμοποιείται όχι μόνο στο baseline αλλά και για correctness tests των protected paths. Για pairwise masking, το decrypted/uncancelled aggregate συγκρίνεται με plaintext reference. Για Selective HE, το decrypted selected layer συγκρίνεται με plaintext selected average και καταγράφεται reconstruction max error.

Η χρήση reference implementation είναι καλή πειραματική πρακτική. Ένα security mechanism μπορεί να φαίνεται λειτουργικό αλλά να έχει μικρό bias από λάθος scaling, duplicated contributor ή missing tensor. Η direct numerical σύγκριση εντοπίζει τέτοια προβλήματα πριν μετατραπούν σε learning divergence μετά από πολλούς rounds.

ΣΤ.6 Pairwise masking implementation details

Το masking module δημιουργεί tensors ίδιου shape και dtype με το μοντέλο. Στην pairwise εκδοχή, το seed derivation περιλαμβάνει το target context ώστε το ίδιο pair να μην επαναχρησιμοποιεί απαραιτήτως το ίδιο mask σε διαφορετικά neighborhoods. Το sign convention βασίζεται στην ordering των client IDs. Το αποτέλεσμα είναι deterministic given the same experiment context, γεγονός που διευκολύνει testing και reproducibility.

Η ακύρωση ελέγχεται στο επίπεδο aggregate, καθώς τα individual masked states είναι σκόπιμα μετατοπισμένα. Τα αντίθετα masks ακυρώνονται εντός της ακρίβειας κινητής υποδιαστολής. Το μέγιστο σφάλμα σε όλες τις σχετικές validation διαμορφώσεις είναι $6{,}482\times10^{-7}$, κάτω από την ανοχή 10^{-6}.

Τα 480 bytes seed overhead ανά γύρο αφορούν το παράδειγμα πέντε clients και ring. Το μέγεθος εξαρτάται από contributor sets και topology. Πρόκειται για λογιστική μετρική του experimental protocol, η οποία δεν περιλαμβάνει πλήρες transport framing, authentication ή πραγματικά key-agreement messages.

ΣΤ.7 CKKS context, packing και selected layer

Το he_utils.py εισάγει το TenSEAL only when HE path απαιτείται. Η καθυστερημένη εισαγωγή αποτρέπει το baseline από το να εξαρτάται λειτουργικά από κρυπτογραφική βιβλιοθήκη. Η build_ckks_context δημιουργεί private context, secret key και public copy. Το public context απογυμνώνεται από secret material πριν δοθεί στους contributors.

Η get_final_layer_param_names αναζητά το τελευταίο floating-point weight tensor με ndim≥2 και προσθέτει matching bias εάν υπάρχει. Στο SimpleMLP επιλέγονται output.weight και output.bias. Η flatten_selected_params μετατρέπει αυτά τα tensors σε contiguous float64 vector και αποθηκεύει metadata ώστε να ανακατασκευαστούν μετά την decryption.

Η CKKS κωδικοποιεί πολλές τιμές σε ένα vector και το prototype μετρά το πραγματικό serialized ciphertext. Η διόγκωση του επιλεγμένου layer δεν ταυτίζεται με τη διόγκωση ολόκληρου του μοντέλου. Ο τελικός classifier έχει 1.290 παραμέτρους σε όλα τα datasets, ενώ το μεγαλύτερο input layer του CIFAR-10 μεταβάλλει το σχετικό βάρος του HE payload στο συνολικό communication.

Μετά το homomorphic average, η decrypt_selected_state επιστρέφει tensors στο requested device/dtype. Η reconstruction error συγκρίνεται με plaintext reference. Η approximate arithmetic είναι αναμενόμενη ιδιότητα CKKS και όχι bug, εφόσον το error παραμένει πολύ μικρό σε σχέση με το scale των parameters.

ΣΤ.8 Adaptive risk scoring implementation details

Το adaptive.py διαχωρίζει δύο προβλήματα: measurement και selection. Η compute_selected_update_norm υπολογίζει μία scalar norm ανά client. Η compute_target_risk_scores χρησιμοποιεί αυτές τις norms και την topology για να δημιουργήσει score ανά target. Η select_he_targets εφαρμόζει policy πάνω στα scores.

Αυτός ο διαχωρισμός επιτρέπει εύκολη αντικατάσταση του heuristic στο μέλλον. Για παράδειγμα, το update norm θα μπορούσε να αντικατασταθεί ή να συμπληρωθεί από cosine drift, historical anomaly score, privacy leakage estimator ή client reputation χωρίς να αλλάξει ο κώδικας CKKS. Αντίστοιχα, η top-k policy μπορεί να αντικατασταθεί από threshold ή budget optimization.

Η topk_risk επιλογή είναι deterministic. Η deterministic συμπεριφορά είναι χρήσιμη για experiments επειδή δύο runs με ίδια client states και scores δεν διαφέρουν τυχαία στην επιλογή HE target. Όταν υπάρχει tie, το μικρότερο client ID προηγείται. Με ratio 0.4, ceil εφαρμόζεται ώστε πέντε clients να δίνουν δύο HE targets και όχι truncation σε ένα.

ΣΤ.9 Metrics και separation of costs

Οι round-level μετρικές αποθηκεύουν accuracy, test και train loss, communication, χρόνους aggregation και ειδικές μετρήσεις των μηχανισμών. Το summary διατηρεί τις παραμέτρους και το execution_profile. Τα μη χρονικά summaries συνδυάζουν τα τρία seeds ανά κοινή διαμόρφωση, ενώ οι χρόνοι συνοψίζονται χωριστά ανά profile με το αντίστοιχο n.

Το cached_gpu profile αποθηκεύει την ίδια μετατροπή ToTensor σε cache και περιορίζει τις scalar μεταφορές από GPU, διατηρώντας batches, precision, accumulation order και optimizer. Οι 15 regression έλεγχοι και τα τρία πλήρη paired baseline benchmarks συμφώνησαν στα ελεγχόμενα μη χρονικά πεδία. Η παρατήρηση αυτή δεν εγγυάται ίδια επιτάχυνση ή bitwise ισότητα σε κάθε μελλοντικό mode και περιβάλλον.

ΣΤ.10 Blockchain και advanced audit implementation

Ο lightweight blockchain layer οργανώνει one genesis block plus one block per communication round. Κάθε block συνδέεται με previous_hash και περιλαμβάνει configuration hash, model hashes, metrics και simulated signatures. Το verification ξαναϋπολογίζει hashes και ελέγχει continuity. Το layer είναι σκόπιμα εκπαιδευτικό: δεν υπάρχει consensus, mining, wallets ή peer-to-peer ledger.

Το advanced audit package είναι σημαντικά πιο ρεαλιστικό. Το signing.py δημιουργεί deterministic Ed25519 key pairs για reproducible demo και παρέχει sign/verify. Το merkle.py δημιουργεί root και membership proofs για client model hashes. Το ledger.py γράφει experiment_start, round και experiment_end records σε append-only JSONL. Το verifier.py ελέγχει record hash chain, signatures, Merkle proofs και configuration consistency. Το reporting.py παράγει summary CSV, statistics, verification report και plots.

Το tamper-demo διαχωρίζει δύο περιπτώσεις. Εάν αλλάξει metric χωρίς επανυπολογισμό record hash, η hash chain αποτυγχάνει. Εάν αλλοιωθεί signature και ο attacker επανυπολογίσει το record hash ώστε να «διορθώσει» την chain, η Ed25519 verification εξακολουθεί να αποτυγχάνει. Αυτό δείχνει γιατί hash linking και signatures καλύπτουν διαφορετικές πτυχές integrity/authenticity.

ΣΤ.11 Platform MVP architecture

Το Platform MVP εισάγει runtime node process, HTTP server, message codec, protocol envelopes, key management, masking και orchestrator. Κάθε Docker container λειτουργεί ως ξεχωριστός Secure DFL node. Τα deployment keys παράγονται πριν από το demo και τα public keys διανέμονται μέσω trusted manifest. Τα outgoing envelopes υπογράφονται και ο receiver ελέγχει identity, signature και payload hash πριν δεχθεί update.

Η pairwise_masking mode του MVP είναι target-specific και δεν μεταφέρει raw mask μέσα στο update envelope. Ο target εφαρμόζει το local contribution του και συνθέτει masked contributor states. Η validation ελέγχει ότι complete contributor set οδηγεί σε σωστή cancellation. Η προσέγγιση είναι ισχυρότερη από το αρχικό controlled simple masking demo, αλλά εξακολουθεί να μην υλοποιεί dropout recovery.

Το operator dashboard παρέχει operational visibility και όχι security proof. Εμφανίζει nodes online, finalized rounds, masked updates και runtime metrics. Τα cryptographic evidence βρίσκονται στα signed logs και verification outputs. Αυτή η διάκριση ανάμεσα σε observability και proof είναι σημαντική για production thinking.

ΣΤ.12 Failure modes και debugging strategy

Σε distributed security prototype, πολλές αποτυχίες μπορούν να εμφανιστούν με ίδιο symptom, όπως divergence ή invalid aggregate. Για αυτό η debugging strategy πρέπει να ξεκινά από deterministic invariants. Πρώτο invariant είναι ότι όλα τα state_dict keys και shapes είναι κοινά. Δεύτερο είναι ότι contributor IDs είναι μοναδικά και περιλαμβάνουν τον target. Τρίτο είναι ότι pairwise aggregate ταιριάζει με plaintext reference εντός tolerance. Τέταρτο είναι ότι HE decrypted selected average ταιριάζει με plaintext reference. Μόνο αφού αυτά περάσουν έχει νόημα να εξετάζεται learning accuracy.

Για audit, τα invariants είναι διαφορετικά: κάθε record hash πρέπει να αναπαράγεται από canonical serialization, previous_hash να ταιριάζει με προηγούμενο record, signatures να επαληθεύονται με manifest public keys και Merkle proofs να οδηγούν στο stored root. Η απομόνωση των invariants κάνει πιο εύκολο να διαχωριστεί implementation bug από αναμενόμενη machine-learning variance.

Πίνακας 39 Βασικά invariants ανά layer.

Layer	Primary invariant	Typical failure signal
Model structure	Ίδια parameter names/shapes	load_state_dict failure
Plain aggregation	Same contributor set and denominator	Accuracy drift / reference mismatch
Pairwise masking	Συμμετρικό +m/−m	Cancellation error > tolerance
CKKS	Decrypt ≈ plaintext selected average	HE reconstruction error
Adaptive policy	Deterministic rank/ratio	Unexpected HE target count
Audit hash chain	Recomputed hash = stored hash	INVALID_HASH_CHAIN
Ed25519	Signature valid for canonical payload	INVALID_SIGNATURE
Merkle proof	Leaf proof → stored root	Invalid proof

Παράρτημα Z — Threat-model matrix και ασφαλής ερμηνεία αποτελεσμάτων

Ο Πίνακας 40 διαχωρίζει τις απειλές, τις παραδοχές προστασίας και τα διαθέσιμα πειραματικά τεκμήρια.

Η τελική αξιολόγηση μίας security-oriented διπλωματικής απαιτεί σαφή διάκριση ανάμεσα σε μηχανισμό, απειλή, evidence και claim. Ο παρακάτω πίνακας συνοψίζει τι μπορεί να ειπωθεί με βάση την πραγματική υλοποίηση και τι παραμένει εκτός scope. Η συντηρητική διατύπωση είναι προτιμότερη από την υπερβολική γενίκευση, ειδικά όταν δεν έχει εκτελεστεί dedicated attack benchmark.

Πίνακας 40 Threat-model matrix και evidence.

Απειλή / ιδιότητα	**Μηχανισμός**	**Evidence στο prototype**	**Επιτρεπτό claim**
Exposure individual updates	Pairwise masking	Cancellation correctness, protected exchange logic	Μειώνει την άμεση έκθεση individual values υπό τις assumptions του protocol.
Exposure selected final layer	CKKS	Real ciphertext processing και decryption	Selected parameters μπορούν να aggregated χωρίς plaintext exposure στον aggregation computation.
Membership inference	Έμμεση προστασία μέσω hidden updates	Δεν υπάρχει attack benchmark	Δεν αποδεικνύεται empirical resistance.
Gradient inversion	HE/masking ως barrier	Δεν υπάρχει reconstruction benchmark	Δεν ποσοτικοποιείται reconstruction success.
Model poisoning	Κανένα robust aggregator	Δεν έχει δοκιμαστεί	Δεν παρέχεται poisoning robustness.
Backdoor	Κανένα dedicated defense	Δεν έχει δοκιμαστεί	Εκτός scope.
Sybil	Identity handling μόνο στο MVP	Δεν υπάρχει Sybil admission test	Δεν παρέχεται Sybil resistance.
Collusion	Limited assumptions	Δεν υπάρχει collusion experiment	Δεν παρέχεται formal collusion resistance.
Dropout	Complete-set pairwise masking	Known limitation	Dropout recovery future work.

Απειλή / ιδιότητα	Μηχανισμός	Evidence στο prototype	Επιτρεπτό claim
Record tampering	Hash chain	Tamper demo	Ανιχνεύεται αλλαγή saved record χωρίς συνεπή regeneration.
Signature tampering	Ed25519	Tamper demo	Ανιχνεύεται αλλοιωμένη/μη έγκυρη signature.
Audit membership	Merkle proofs	15/15 valid proofs στο thesis demo	Recorded model hashes μπορούν να ελεγχθούν έναντι Merkle root.

Ζ.1 Πώς να ερμηνεύεται η ίδια accuracy των security modes

Η σχεδόν ίδια accuracy μεταξύ baseline, pairwise masking, Selective HE και Adaptive Hybrid δεν σημαίνει ότι όλοι οι μηχανισμοί παρέχουν ίδια ασφάλεια. Σημαίνει ότι στο evaluated setup οι προστατευμένοι aggregation paths αναπαράγουν αρκετά καλά το ίδιο numerical model average ώστε να μην αλλάζει αισθητά η learning utility. Η accuracy είναι metric utility, όχι metric confidentiality.

Αντίστροφα, μεγαλύτερο communication overhead δεν αποδεικνύει ισχυρότερη ασφάλεια. Το overhead προκύπτει από representation και protocol design. Η security strength εξαρτάται από cryptographic assumptions, threat model και exposed information. Για αυτό το thesis παρουσιάζει communication και HE time ως efficiency metrics, ενώ οι security claims παραμένουν περιορισμένες στα implemented mechanisms.

Ζ.2 Γιατί το non-IID αποτέλεσμα είναι χαμηλότερο

Το label-skew partitioning δημιουργεί διαφορετικές local distributions και δυσκολεύει τη διάχυση κοινής γνώσης στο ring με 20 γύρους. Η fully connected τοπολογία μετριάζει την πτώση στις εξεταζόμενες διαμορφώσεις. Η επίδραση του shard assignment αποτυπώνεται και στη διασπορά των τριών seeds. Πρόκειται για εμπειρική ερμηνεία του συγκεκριμένου budget και μοντέλου.

Η μέγιστη αντιστοιχισμένη διαφορά τελικής accuracy μεταξύ protected mode και baseline είναι 0,23 ποσοστιαίες μονάδες. Η πολύ μεγαλύτερη πτώση IID προς non-IID και η μεταβολή με την τοπολογία υποστηρίζουν ότι η ετερογένεια και η διάχυση πληροφορίας είναι οι κυρίαρχοι μαθησιακοί παράγοντες σε αυτή την καμπάνια.

Ζ.3 Τι αποδεικνύει και τι δεν αποδεικνύει το audit

Το audit package αποδεικνύει ότι συγκεκριμένα stored records σχηματίζουν συνεπή hash chain, ότι οι stored signatures επαληθεύονται με συγκεκριμένα public keys και ότι τα model hashes συμμετέχουν στο stored Merkle root. Επιπλέον, τα controlled tampering scenarios αποδεικνύουν ότι οι verification routines αντιδρούν στις συγκεκριμένες αλλοιώσεις.

Δεν αποδεικνύει ότι το local training computation ήταν ορθό, ότι το dataset ήταν αυθεντικό, ότι ο client δεν ήταν malicious πριν την υπογραφή ή ότι ένας πλήρως compromised host δεν μπορεί να δημιουργήσει νέα self-consistent artifacts. Αυτές οι ιδιότητες απαιτούν ισχυρότερα primitives όπως remote attestation, zero-knowledge proofs, external anchoring ή independent replicated ledger. Για αυτό ο όρος auditability χρησιμοποιείται με σαφή όρια.

Z.4 Production gaps

Η μετάβαση από prototype σε production σύστημα θα απαιτούσε τουλάχιστον transport security, authenticated service discovery, credential rotation, robust key storage, authorization policies, retry/replay protection, dropout handling, durable distributed state, health management και observability. Το local HTTP Docker demo δεν υλοποιεί αυτά τα στοιχεία και δεν πρέπει να αντιμετωπίζεται ως enterprise security boundary.

Στο cryptographic layer, distributed key generation ή threshold decryption θα περιόριζαν την εξάρτηση από target-held secret key. Στο secure aggregation layer, secret sharing θα επέτρεπε recovery από dropouts. Στο learning layer, clipping, anomaly detection ή robust aggregation θα αντιμετώπιζαν malicious model updates. Η modular αρχιτεκτονική του prototype παρέχει σημεία επέκτασης, αλλά οι λειτουργίες αυτές παραμένουν future work.

Παράρτημα Η — Γλωσσάριο, συμβολισμοί και ερμηνευτικές σημειώσεις

Ο Πίνακας 41 επεξηγεί τους βασικούς όρους και ο Πίνακας 42 τους συμβολισμούς των εξισώσεων.

Το γλωσσάριο συγκεντρώνει τους όρους που χρησιμοποιούνται συχνότερα στην αναφορά και τους συνδέει με τη συγκεκριμένη υλοποίηση. Η ίδια λέξη μπορεί στη γενική βιβλιογραφία να χρησιμοποιείται με περισσότερες από μία σημασίες· για αυτό εδώ δίνεται η ακριβής ερμηνεία που ακολουθεί το prototype.

Πίνακας 41 Γλωσσάριο βασικών όρων.

Όρος	**Ερμηνεία στην εργασία**
Aggregation	Συνδυασμός αντίστοιχων model parameters από contributors. Στο prototype είναι απλός arithmetic average.
Client / Peer	Συμμετέχων που διαθέτει local dataset και πλήρες model replica.
Contributor	Client του οποίου το state συμμετέχει στο aggregate συγκεκριμένου target neighborhood.
Target	Client για τον οποίο υπολογίζεται νέο aggregated state.
Neighborhood	Target μαζί με τους topology neighbors του. Στο 5-client ring έχει τρεις contributors.
Model state	Το πλήρες state_dict του PyTorch model: weights και biases.
Model update	Η μεταβολή ενός model state μετά το local training σε σχέση με το snapshot πριν το training.
Weight	Trainable scalar parameter συγκεκριμένης σύνδεσης. Δεν είναι probability και δεν περιορίζεται στο [0,1].
Gradient	Παράγωγος του loss ως προς trainable parameter. Οδηγεί την κατεύθυνση του optimizer update.
Loss	Scalar measure prediction error. Στην υλοποίηση χρησιμοποιείται CrossEntropyLoss.
Logit	Raw output score του final layer πριν από probability normalization.

Όρος	Ερμηνεία στην εργασία
Softmax	Μετατροπή logits σε probability distribution με άθροισμα 1.
Batch	Μικρή ομάδα samples που χρησιμοποιείται σε ένα optimizer step.
Local epoch	Πλήρες πέρασμα από το local dataset ενός client.
Communication round	Local training όλων, security/aggregation, commit, evaluation και logging.
IID	Partitions που προσεγγίζουν την ίδια συνολική distribution.
non-IID	Heterogeneous local distributions με label shards ή Dirichlet.
Consensus	Τάση των peer models να γίνονται περισσότερο συμβατά μέσω επαναλαμβανόμενης neighbor averaging.
Pairwise mask	Τυχαίο/ψευδοτυχαίο tensor που προστίθεται με + σε έναν contributor και − σε άλλον.
Cancellation error	Max numerical difference masked aggregate και plaintext reference aggregate.
HE	Κρυπτογραφική τεχνική που επιτρέπει πράξεις σε encrypted values.
CKKS	Approximate-number HE scheme κατάλληλο για vector arithmetic πραγματικών τιμών.
Ciphertext expansion	Λόγος serialized encrypted bytes προς αντίστοιχα plaintext bytes.
Selective HE	HE μόνο σε subset model parameters. Εδώ: final layer.
Adaptive Hybrid	Pairwise masking ως default και Selective HE σε top-risk target neighborhoods.
Update norm	L2 magnitude της before/after μεταβολής selected parameters.
Risk score	Heuristic neighborhood score 0.7·max + 0.3·mean, με split multiplier.
HE target ratio	Fraction των target neighborhoods που επιλέγονται για HE.

Όρος	Ερμηνεία στην εργασία
Hash	Fixed-size digest για integrity checking.
Digital signature	Cryptographic proof ότι συγκεκριμένο private key υπέγραψε συγκεκριμένο payload.
Merkle root	Root digest που συνοψίζει set leaf hashes.
Merkle proof	Μικρό σύνολο sibling hashes που αποδεικνύει membership ενός leaf.
Audit ledger	Append-only sequence records για post-experiment integrity verification.
Tamper evidence	Ικανότητα να γίνει εμφανής η μεταγενέστερη αλλοίωση αποθηκευμένου artifact.
Platform MVP	Networked Docker proof-of-concept γύρω από το core research pipeline.

Η.1 Βασικοί συμβολισμοί

Πίνακας 42 Συμβολισμοί που χρησιμοποιούνται στις εξισώσεις.

Σύμβολο	Σημασία
W_i	Model state του client i.
W_i^before	Snapshot πριν από local training.
W_i^after	State μετά από local training.
u_i	L2 norm selected-layer update του client i.
N(t)	Γείτονες του target t.
C(t)	Contributors του target: {t} ∪ N(t).
R_t	Adaptive risk score του target neighborhood.
m_split	1.0 στο IID και 1.2 στο non-IID prototype.
r	Configured HE target ratio.
S	Set selected parameter names για HE/risk calculation.
Enc(x)	CKKS encryption του x.
H(x)	Cryptographic hash του x.

Η.2 Ερμηνευτικές διακρίσεις που αποφεύγουν συχνά λάθη

Weight και probability είναι διαφορετικές έννοιες. Ένα weight μπορεί να είναι αρνητικό, θετικό, μικρό ή μεγαλύτερο από 1 και δεν εκφράζει ποσοστό βεβαιότητας. Οι probabilities εμφανίζονται μόνο όταν τα output logits μετατρέπονται σε normalized distribution. Αντίστοιχα, gradient και loss δεν είναι συνώνυμα: το loss είναι scalar objective, ενώ το gradient είναι derivative information για κάθε parameter.

Local training και aggregation είναι επίσης διαφορετικά στάδια. Η εκπαίδευση περιλαμβάνει forward pass, loss, backpropagation και optimizer step πάνω σε local data. Το aggregation δεν κάνει backpropagation μεταξύ clients. Απλώς συνδυάζει ήδη εκπαιδευμένα model states. Μετά το aggregation ξεκινά νέο round και πραγματοποιείται νέο local training.

Το ring topology καθορίζει ποιος επικοινωνεί με ποιον, όχι μία σειριακή «σειρά εκτέλεσης» γύρω από τον κύκλο. Όλοι οι targets του round χρησιμοποιούν snapshots του ίδιου logical stage. Η synchronous semantics αποτρέπει ένα target από το να χρησιμοποιήσει already-updated state άλλου target μέσα στο ίδιο round.

Τέλος, auditability δεν ισοδυναμεί με privacy. Ένα signed record μπορεί να περιέχει plaintext data εάν ο σχεδιαστής το επιλέξει· η signature δεν τα κρύβει. Στο prototype τα audit records αποθηκεύουν hashes και metadata, ενώ privacy protection των model values είναι ευθύνη masking/HE.

Η.3 Σύντομη end-to-end αφήγηση της εφαρμογής

Στο ενδεικτικό παράδειγμα πέντε clients και ring, κάθε client διαθέτει κοινή αρχιτεκτονική και διαφορετικό local partition. Οι εικόνες MNIST, Fashion-MNIST ή CIFAR-10 παραμένουν στο local dataset και δεν μεταφέρονται ως πρωτογενή δεδομένα στους peers. Κάθε γύρος αρχίζει με ένα local epoch. Η αρχιτεκτονική εισόδου προσαρμόζεται στο dataset, ενώ το final layer παραμένει 128 → 10.

Μετά το local training υπάρχουν πέντε διαφορετικά model states. Στην Adaptive Hybrid mode υπολογίζεται πόσο άλλαξε το selected final layer κάθε client. Για κάθε ring neighborhood υπολογίζεται risk score και τα δύο υψηλότερα targets, όταν r=0.4, επιλέγονται για Selective CKKS. Τα υπόλοιπα neighborhoods χρησιμοποιούν pairwise masking.

Κάθε target συνδυάζει το local state και τα states των δύο γειτόνων του. Στο pairwise path οι masks ακυρώνονται στο aggregate. Στο HE path το selected layer αθροίζεται ως ciphertext και αποκρυπτογραφείται μόνο μετά το homomorphic average. Τα non-selected parameters averaged σε plaintext. Αφού υπολογιστούν όλα τα target states, πραγματοποιείται synchronous commit.

Τέλος, τα πέντε νέα models αξιολογούνται στο ίδιο test set, οι metrics αποθηκεύονται και προαιρετικά δημιουργείται audit record με model hashes, signatures, Merkle evidence και round metadata. Στη συνέχεια ξεκινά ο επόμενος communication round. Η επανάληψη local learning και neighbor aggregation διαχέει σταδιακά τη γνώση σε ολόκληρο τον ring graph.

Βιβλιογραφία

[1] Yuan, L., Wang, Z., Sun, L., Yu, P. S., & Brinton, C. G. (2023). Decentralized Federated Learning: A Survey and Perspective. arXiv:2306.01603v1. https://arxiv.org/abs/2306.01603v1

[2] Mothukuri, V., Parizi, R. M., Pouriyeh, S., Huang, Y., Dehghantanha, A., & Srivastava, G. (2021). A Survey on Security and Privacy of Federated Learning. Future Generation Computer Systems, 115, 619–640. https://doi.org/10.1016/j.future.2020.10.007

[3] Bonawitz, K., Ivanov, V., Kreuter, B., Marcedone, A., McMahan, H. B., Patel, S., Ramage, D., Segal, A., & Seth, K. (2017). Practical Secure Aggregation for Privacy-Preserving Machine Learning. ACM CCS 2017, 1175–1191. https://doi.org/10.1145/3133956.3133982

[4] Cheon, J. H., Kim, A., Kim, M., & Song, Y. (2017). Homomorphic Encryption for Arithmetic of Approximate Numbers. ASIACRYPT 2017, 409–437. https://doi.org/10.1007/978-3-319-70694-8_15

[5] Zhang, C., Li, S., Xia, J., Wang, W., Yan, F., & Liu, Y. (2020). BatchCrypt: Efficient Homomorphic Encryption for Cross-Silo Federated Learning. USENIX ATC 2020, 493–506. https://www.usenix.org/conference/atc20/presentation/zhang-chengliang

[6] Benaissa, A., Retiat, B., Cebere, B., & Belfedhal, A. E. (2021). TenSEAL: A Library for Encrypted Tensor Operations Using Homomorphic Encryption. arXiv:2104.03152. https://arxiv.org/abs/2104.03152

[7] Josefsson, S., & Liusvaara, I. (2017). Edwards-Curve Digital Signature Algorithm (EdDSA). RFC 8032. https://www.rfc-editor.org/rfc/rfc8032

[8] Merkle, R. C. (1988). A Digital Signature Based on a Conventional Encryption Function. Advances in Cryptology — CRYPTO ’87, LNCS 293, 369–378. https://doi.org/10.1007/3-540-48184-2_32

[9] McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-Efficient Learning of Deep Networks from Decentralized Data. Proceedings of AISTATS 2017, PMLR 54, 1273–1282. https://proceedings.mlr.press/v54/mcmahan17a.html

[10] Kairouz, P., McMahan, H. B., Avent, B., et al. (2021). Advances and Open Problems in Federated Learning. Foundations and Trends in Machine Learning, 14(1–2), 1–210. https://doi.org/10.1561/2200000083

[11] Zhu, L., Liu, Z., & Han, S. (2019). Deep Leakage from Gradients. Advances in Neural Information Processing Systems 32. https://papers.nips.cc/paper/2019/hash/60a6c4002cc7b29142def8871531281a-Abstract.html

[12] Shokri, R., Stronati, M., Song, C., & Shmatikov, V. (2017). Membership Inference Attacks Against Machine Learning Models. IEEE Symposium on Security and Privacy, 3–18. https://doi.org/10.1109/SP.2017.41

[13] Bagdasaryan, E., Veit, A., Hua, Y., Estrin, D., & Shmatikov, V. (2020). How To Backdoor Federated Learning. Proceedings of AISTATS 2020, PMLR 108, 2938–2948. https://proceedings.mlr.press/v108/bagdasaryan20a.html

[14] Jiang, C., Xu, C., Cao, C., & Chen, K. (2023). GAIN: Decentralized Privacy-Preserving Federated Learning. Journal of Information Security and Applications, 78, 103615. https://doi.org/10.1016/j.jisa.2023.103615

[15] Hu, C., & Li, B. (2025). MaskCrypt: Federated Learning With Selective Homomorphic Encryption. IEEE Transactions on Dependable and Secure Computing, 22(1), 221–233. https://doi.org/10.1109/TDSC.2024.3392424

[16] Kalapaaking, A. P., Khalil, I., Yi, X., Lam, K.-Y., Huang, G.-B., & Wang, N. (2025). Auditable and Verifiable Federated Learning Based on Blockchain-Enabled Decentralization. IEEE Transactions on Neural Networks and Learning Systems, 36(1), 102–115. https://doi.org/10.1109/TNNLS.2024.3407670

[17] Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747. https://arxiv.org/abs/1708.07747

[18] Krizhevsky, A. (2009). Learning Multiple Layers of Features from Tiny Images. Technical report, University of Toronto. https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf Dataset: https://www.cs.toronto.edu/~kriz/cifar.html

[19] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-Based Learning Applied to Document Recognition. Proceedings of the IEEE, 86(11), 2278–2324. https://doi.org/10.1109/5.726791

[20] Μυλωνάς, Δ. (2026). Secure DFL final evaluation campaign, 14 October 2026. Κώδικας και πειραματικά τεκμήρια, commit a602e28c12e668eb1beb241a67fe1b9c5879c362 (ιδιωτικό repository). https://github.com/Dionisis09/secure-dfl-thesis/tree/a602e28c12e668eb1beb241a67fe1b9c5879c362/results/campaign_20261014

[21] Μυλωνάς, Δ. (2026). Secure DFL supplementary evaluation: 228 runs and 76 configurations. Κώδικας, scope και αποτελέσματα, commit 3abb58eecd6cef8f2b4529bede2f2c6d760e1892 (ιδιωτικό repository). https://github.com/Dionisis09/secure-dfl-thesis/tree/3abb58eecd6cef8f2b4529bede2f2c6d760e1892/results/campaign_20261102_reduced

[22] NetworkX Developers. (χ.χ.). connected_caveman_graph. NetworkX documentation. Πρόσβαση: 2 Νοεμβρίου 2026. https://networkx.org/documentation/stable/reference/generated/networkx.generators.community.connected_caveman_graph.html

[23] NetworkX Developers. (χ.χ.). barabasi_albert_graph. NetworkX documentation. Πρόσβαση: 2 Νοεμβρίου 2026. https://networkx.org/documentation/stable/reference/generated/networkx.generators.random_graphs.barabasi_albert_graph.html